

课程笔记

PG Loss 详解：Policy Gradient 的核心组件

基于公开课程资料整理

2025

Policy Gradient Loss
ppo-clip/dual-clip
entropy/KL
agg_loss

视频作者/频道：五道口纳什

发布日期：2025

视频时长：约 24 分钟

项目主页：<https://github.com/hqh1025/ai-course-notes>

目录

1 引言	2
2 Policy Gradient 基础	2
2.1 期望奖励不可直接求导	2
2.2 PPO Clip 目标	2
2.3 本章小结	2
3 定制化 veRL	2
3.1 主要定制点	2
3.2 本章小结	3
4 总结与延伸	3
4.1 拓展阅读	3

1 引言

本期正式开启 Agentic RL Training 系列，围绕 veRL 框架展开。本期介绍 Policy Gradient Loss 的核心组件。

强化学习的真正目标

RL 的目标是最大化**奖励回报的期望** (Expected Reward)。PPO Clip 等目标函数只是一个**代理** (surrogate)，间接优化这个期望。训练时更应关注 **Rewards Curve** 而非 Loss Curve。

2 Policy Gradient 基础

2.1 期望奖励不可直接求导

真正的目标函数 $J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta}[R(\tau)]$ 涉及对策略分布的采样，无法直接对 θ 求导。因此我们使用 PG Loss 作为代理损失函数。

2.2 PPO Clip 目标

PPO Clip 是当前最常用的 PG 方法：

$$L^{\text{CLIP}}(\theta) = \mathbb{E} \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right]$$

其中 $r_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)}$ 是重要性采样比率， $\hat{A}_t$ 是优势函数估计。

Loss vs. Rewards

训练过程中 PG Loss 往往围绕 0 上下震荡，没有明显的下降趋势。这是正常的——因为 PG Loss 是代理目标，真正的训练信号体现在 Rewards Curve 上。

2.3 本章小结

PG Loss 是间接优化期望奖励的工具。训练时应以 Rewards Curve 为主要监控指标。

3 定制化 veRL

3.1 主要定制点

基于 veRL 做 Agentic RL Post-training 时，主要定制几个部分：

- **Reward Function**：定义任务的奖励函数
- **Environment**：定义 Agent 交互的环境
- **Data Pipeline**：准备训练数据
- **Training Config**：调整超参数

3.2 本章小结

veRL 提供了灵活的定制接口，核心工作在于定义合适的 reward function 和 environment。

4 总结与延伸

1. RL 真正的目标是最大化期望奖励，PG Loss 只是代理
2. 训练时关注 Rewards Curve 而非 Loss Curve
3. PPO Clip 通过重要性采样比率和 clip 机制保证稳定训练
4. veRL 框架提供了 Agentic RL Training 的完整 pipeline

4.1 拓展阅读

- Schulman et al., “Proximal Policy Optimization Algorithms” (2017)
- veRL GitHub 仓库及文档