

课程笔记

从 PG 到 TRPO 到 PPO

基于公开课程资料整理

2025

RL4LLM 基石

Policy Gradient

TRPO

PPO-Clip

视频作者/频道：五道口纳什

发布日期：2025

视频时长：约 15 分钟

项目主页：<https://github.com/hqh1025/ai-course-notes>

目录

1	引言	2
2	PPO Clip 目标函数	2
3	从 PG 到 TRPO 到 PPO	2
3.1	Vanilla PG	2
3.2	TRPO: 信任域约束	2
3.3	PPO: Clip 替代 KL 约束	2
3.4	本章小结	2
4	总结与延伸	3

1 引言

本期主线：从 Policy Gradient (PG) 到 TRPO 到 PPO，串联核心公式之间的过渡关系。

核心概念链

Reward $\rightarrow$ 期望 $\rightarrow$ 状态价值函数 $V(s) \rightarrow$ 状态动作价值函数 $Q(s, a) \rightarrow$ Advantage $A(s, a) \rightarrow$ On-policy / Off-policy $\rightarrow$ 重要性采样

2 PPO Clip 目标函数

PPO Clip 是策略优化 (Policy Optimization) 方法。优化对象是**策略** (Policy Network)：输入状态，输出动作的概率分布。

$$L^{\text{CLIP}} = \mathbb{E} \left[\min \left(r_t \hat{A}_t, \text{clip}(r_t, 1-\epsilon, 1+\epsilon) \hat{A}_t \right) \right]$$

策略 vs. 价值

- **策略网络** $\pi_\theta(a|s)$ ：输入状态，输出动作概率分布
- **DQN**：输入状态 + 动作，输出 $Q(s, a)$
- PPO 属于策略优化方法，DQN 属于价值方法

3 从 PG 到 TRPO 到 PPO

3.1 Vanilla PG

$$\nabla_\theta J(\theta) = \mathbb{E}_{\pi_\theta} \left[\nabla_\theta \log \pi_\theta(a|s) \cdot \hat{A}(s, a) \right]$$

3.2 TRPO: 信任域约束

TRPO 在 PG 基础上加入 KL 散度约束，限制策略更新幅度：

$$\max_{\theta} \mathbb{E} \left[\frac{\pi_\theta}{\pi_{\theta_{\text{old}}}} \hat{A} \right] \quad \text{s.t.} \quad D_{KL}(\pi_{\theta_{\text{old}}} \| \pi_\theta) \leq \delta$$

3.3 PPO: Clip 替代 KL 约束

PPO 用 clip 机制替代 TRPO 的 KL 约束，实现更简单高效：重要性比率 r_t 被限制在 $[1-\epsilon, 1+\epsilon]$ 范围内。

3.4 本章小结

PG $\rightarrow$ TRPO $\rightarrow$ PPO 是从朴素到约束到高效的演进。PPO 在保持训练稳定性的同时大幅简化了实现。

4 总结与延伸

1. PG 是最基础的策略梯度方法
2. TRPO 通过 KL 约束保证单步更新不过大
3. PPO 用 clip 替代 KL，简单高效，是当前标准
4. 核心概念：Reward、Advantage、On/Off-policy、重要性采样