

课程笔记

从 PG 到 TRPO 到 PPO

基于公开课程资料整理

2025

RL4LLM 基石

Policy Gradient

TRPO

PPO-Clip

视频作者/频道：五道口纳什

发布日期：2025

视频时长：约 15 分钟

项目主页：<https://github.com/hqh1025/ai-course-notes>

目录

1	引言	2
2	PPO Clip 目标函数	2
3	从 PG 到 TRPO 到 PPO	2
3.1	Vanilla PG	2
3.2	TRPO: 信任域约束	2
3.3	PPO: Clip 替代 KL 约束	2
3.4	本章小结	2
4	工程视角：为什么 PPO 成为默认选项	3
4.1	复杂度、稳定性与可实现性的折中	3
4.2	本章小结	3
5	总结与延伸	4

1 引言

本期主线：从 Policy Gradient (PG) 到 TRPO 到 PPO，串联核心公式之间的过渡关系。

核心概念链

Reward $\rightarrow$ 期望 $\rightarrow$ 状态价值函数 $V(s) \rightarrow$ 状态动作价值函数 $Q(s, a) \rightarrow$ Advantage $A(s, a) \rightarrow$ On-policy / Off-policy $\rightarrow$ 重要性采样

2 PPO Clip 目标函数

PPO Clip 是策略优化 (Policy Optimization) 方法。优化对象是**策略** (Policy Network)：输入状态，输出动作的概率分布。

$$L^{\text{CLIP}} = \mathbb{E} \left[\min \left(r_t \hat{A}_t, \text{clip}(r_t, 1-\epsilon, 1+\epsilon) \hat{A}_t \right) \right]$$

策略 vs. 价值

- **策略网络** $\pi_\theta(a|s)$ ：输入状态，输出动作概率分布
- **DQN**：输入状态 + 动作，输出 $Q(s, a)$
- PPO 属于策略优化方法，DQN 属于价值方法

3 从 PG 到 TRPO 到 PPO

3.1 Vanilla PG

$$\nabla_\theta J(\theta) = \mathbb{E}_{\pi_\theta} \left[\nabla_\theta \log \pi_\theta(a|s) \cdot \hat{A}(s, a) \right]$$

3.2 TRPO: 信任域约束

TRPO 在 PG 基础上加入 KL 散度约束，限制策略更新幅度：

$$\max_{\theta} \mathbb{E} \left[\frac{\pi_\theta}{\pi_{\theta_{\text{old}}}} \hat{A} \right] \quad \text{s.t.} \quad D_{KL}(\pi_{\theta_{\text{old}}} \parallel \pi_\theta) \leq \delta$$

3.3 PPO: Clip 替代 KL 约束

PPO 用 clip 机制替代 TRPO 的 KL 约束，实现更简单高效：重要性比率 r_t 被限制在 $[1-\epsilon, 1+\epsilon]$ 范围内。

3.4 本章小结

PG $\rightarrow$ TRPO $\rightarrow$ PPO 是从朴素到约束到高效的演进。PPO 在保持训练稳定性的同时大幅简化了实现。

4 工程视角：为什么 PPO 成为默认选项

4.1 复杂度、稳定性与可实现性的折中

课程虽然只用 15 分钟讲解 PG、TRPO、PPO 的演化，但背后的工程结论非常明确：PPO 之所以流行，不是因为它在所有 benchmark 上都绝对最优，而是因为它在**稳定性、实现门槛和训练效率**之间取得了最平衡的折中。

方法	优点	主要代价	适用判断
PG	概念最直接	方差高、更新不稳	用于理解基本原理
TRPO	理论约束更强	二阶近似和实现复杂	更适合研究型推导
PPO	稳定且实现简单	仍需精调 clip/advantage	工程实践的默认起点

表 1: PG、TRPO、PPO 在工程中的典型取舍

不要把 PPO 当作“免调参算法”

PPO 只是把 TRPO 的复杂约束换成了更易用的剪裁目标，并不意味着训练就会自动稳定。batch 大小、优势归一化、reward 尺度和 rollout 质量依旧会直接影响结果。

4.2 本章小结

从工程落地角度看，PPO 是一个高性价比基线：先用它搭通训练闭环，再决定是否有必要引入更复杂的约束或更新规则，通常比一开始就追求“最强算法”更现实。

5 总结与延伸

1. PG 是最基础的策略梯度方法
2. TRPO 通过 KL 约束保证单步更新不过大
3. PPO 用 clip 替代 KL，简单高效，是当前标准
4. 核心概念：Reward、Advantage、On/Off-policy、重要性采样