

课程笔记

GRPO 下的 PG Loss 分析

五道口纳什 & AI

2026 年 3 月 29 日

Policy Gradient 优势标准化 Loss curve 分析 on-policy code

🔍 🔍 🔍 🔍 🔍 🔍 🔍 🔍 🔍 🔍

视频作者/频道: 五道口纳什

发布日期: 2025

视频时长: 约 20 分钟

视频链接: 未填写

目录

1	引言	2
2	GRPO 中的 PG Loss	2
2.1	Group Relative Policy Optimization	2
2.2	Loss 围绕 0 震荡的原因	2
2.3	本章小结	2
3	REINFORCE 在 CartPole 上的验证	2
4	总结与延伸	2

1 引言

本期分析 Policy Gradient Loss 在 GRPO setting 下的特性，解释为什么 PG Loss 围绕 0 震荡。

PG Loss 的震荡特性

PG Loss 围绕 0 上下震荡是正常现象。RL 的真正 objective 是最大化期望奖励，PG Loss 只是代理损失。Rewards Curve 持续上升并最终收敛才是训练成功的标志。

2 GRPO 中的 PG Loss

2.1 Group Relative Policy Optimization

GRPO 对同一 prompt 采样一组 response，计算组内的相对优势。这消除了对 value model 的依赖。

2.2 Loss 围绕 0 震荡的原因

$PG\ Loss = \mathbb{E}[r_t \cdot A_t]$ 。因为 Advantage A_t 有正有负（好的动作 $A > 0$ ，差的 $A < 0$ ），期望值在 0 附近。随着策略改进，正负 advantage 的分布动态变化，导致 loss 持续震荡。

2.3 本章小结

PG Loss 的震荡是其数学本质决定的，不代表训练失败。关键指标是 Rewards Curve。

3 REINFORCE 在 CartPole 上的验证

本期最后用 REINFORCE 算法在 CartPole 环境上验证了上述分析：PG Loss 围绕 0 震荡，而 rewards 稳步提升。

4 总结与延伸

1. PG Loss 围绕 0 震荡是正常现象
2. GRPO 通过组内相对优势消除 value model 依赖
3. 训练监控应以 Rewards Curve 为主