

课程笔记

GRPO 下的 PG Loss 分析

基于公开课程资料整理

2025

Policy Gradient 优势标准化 Loss curve 分析 on-policy code



视频作者/频道: 五道口纳什

发布日期: 2025

视频时长: 约 20 分钟

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1 引言	2
2 GRPO 中的 PG Loss	2
2.1 Group Relative Policy Optimization	2
2.2 Loss 围绕 0 震荡的原因	2
2.3 本章小结	2
3 REINFORCE 在 CartPole 上的验证	2
4 训练判断：先看 reward，再看代理损失	2
4.1 本章小结	2
5 总结与延伸	3

1 引言

本期分析 Policy Gradient Loss 在 GRPO setting 下的特性，解释为什么 PG Loss 围绕 0 震荡。

PG Loss 的震荡特性

PG Loss 围绕 0 上下震荡是正常现象。RL 的真正 objective 是最大化期望奖励，PG Loss 只是代理损失。Rewards Curve 持续上升并最终收敛才是训练成功的标志。

2 GRPO 中的 PG Loss

2.1 Group Relative Policy Optimization

GRPO 对同一 prompt 采样一组 response，计算组内的相对优势。这消除了对 value model 的依赖。

2.2 Loss 围绕 0 震荡的原因

$PG\ Loss = \mathbb{E}[r_t \cdot A_t]$ 。因为 Advantage A_t 有正有负（好的动作 $A > 0$ ，差的 $A < 0$ ），期望值在 0 附近。随着策略改进，正负 advantage 的分布动态变化，导致 loss 持续震荡。

2.3 本章小结

PG Loss 的震荡是其数学本质决定的，不代表训练失败。关键指标是 Rewards Curve。

3 REINFORCE 在 CartPole 上的验证

本期最后用 REINFORCE 算法在 CartPole 环境上验证了上述分析：PG Loss 围绕 0 震荡，而 rewards 稳步提升。

4 训练判断：先看 reward，再看代理损失

短讲里最容易被误解的一点，是把 PG loss 的波动当成训练失败。更合理的做法是把 reward、成功率和采样质量放在一起看：如果 reward 在升、采样轨迹越来越稳定，那么 loss 在 0 附近震荡并不是坏事，反而说明优势估计仍在持续推动策略分化。

最小监控面板

- Reward curve：判断策略是否真的变强
- Episode 长度/成功率：判断环境里是否学到了可复用行为
- PG loss：只作为辅助信号，不单独解释

4.1 本章小结

GRPO 或 REINFORCE 这类方法都提醒我们：代理损失的数值形态不等于训练成败。真正应该被优先解释的是 reward 和 rollout 质量是否持续改善。

5 总结与延伸

1. PG Loss 围绕 0 震荡是正常现象
2. GRPO 通过组内相对优势消除 value model 依赖
3. 训练监控应以 Rewards Curve 为主