

课程笔记

vLLM 推理与部署：参数调优与显存分析

基于公开课程资料整理

2025

vLLM 参数配置 显存分析 性能调优

视频作者/频道：五道口纳什

发布日期：2025

视频时长：约 20 分钟

项目主页：<https://github.com/hqh1025/ai-course-notes>

目录

1	引言	2
2	Online vs. Offline 推理	2
2.1	Offline Batch Generation	2
2.2	Online Serving	2
3	显存分析	2
3.1	本章小结	2
4	总结与延伸	2

1 引言

本期展开 vLLM 推理和部署的更多参数和细节，包括显存分析和调优方法。vLLM 有两大应用场景：推理部署和 RL Training 中的在线 rollout。

vLLM 的两大场景

- **推理部署**：Offline Batch Generation + Online Serving (OpenAI API 兼容)
- **RL Training**：在 RL for Language Model 中做模型的 online rollout (如 OpenRLHF 首次引入现代推理引擎到 RL pipeline)

2 Online vs. Offline 推理

2.1 Offline Batch Generation

适用于批量处理场景，一次性处理大量请求，最大化吞吐量。

2.2 Online Serving

部署为 OpenAI API 兼容的服务，支持实时请求。关键指标：TTFT (首 token 延迟) 和 TPS (每秒 token 数)。

3 显存分析

模型权重 + KV Cache + 中间激活值。KV Cache 随序列长度线性增长，是长上下文推理的主要瓶颈。

3.1 本章小结

vLLM 的显存消耗主要由模型权重和 KV Cache 决定。合理的参数配置是高效推理的关键。

4 系统视角：吞吐受限时先查哪里

对于 Agentic RL 训练，推理模式与显存占用并不是两个独立话题。真正的系统瓶颈往往体现在：一边想提高 rollout 吞吐，一边又被 context、batch 和 cache 挤爆显存。理解 online/offline 的差异，本质上是在理解训练系统如何在延迟和吞吐之间做取舍。

排查顺序建议

- 先看每轮 rollout 的 token 数和并发数
- 再看 KV cache、batch size 是否占满显存
- 最后再决定采用 online 还是 offline 推理编排

4.1 本章小结

显存分析不是附属话题，而是 RL 系统设计的一部分。只有吞吐、延迟和显存三者同时平衡，训练管线才能稳定跑起来。

5 总结与延伸

1. vLLM 同时服务于推理部署和 RL Training
2. Offline 和 Online 两种模式各有优化方向
3. 显存分析：模型权重 + KV Cache + 激活值