

课程笔记

# vLLM 推理与部署：参数调优与显存分析

五道口纳什 & AI

2026 年 3 月 29 日

## vLLM 参数配置 显存分析 性能调优

视频作者/频道：五道口纳什

发布日期：2025

视频时长：约 20 分钟

视频链接：未填写

# 目录

|          |                                    |          |
|----------|------------------------------------|----------|
| <b>1</b> | <b>引言</b>                          | <b>2</b> |
| <b>2</b> | <b>Online vs. Offline 推理</b>       | <b>2</b> |
| 2.1      | Offline Batch Generation . . . . . | 2        |
| 2.2      | Online Serving . . . . .           | 2        |
| <b>3</b> | <b>显存分析</b>                        | <b>2</b> |
| 3.1      | 本章小结 . . . . .                     | 2        |
| <b>4</b> | <b>总结与延伸</b>                       | <b>2</b> |

# 1 引言

本期展开 vLLM 推理和部署的更多参数和细节，包括显存分析和调优方法。vLLM 有两大应用场景：推理部署和 RL Training 中的在线 rollout。

## vLLM 的两大场景

- **推理部署**：Offline Batch Generation + Online Serving (OpenAI API 兼容)
- **RL Training**：在 RL for Language Model 中做模型的 online rollout (如 OpenRLHF 首次引入现代推理引擎到 RL pipeline)

## 2 Online vs. Offline 推理

### 2.1 Offline Batch Generation

适用于批量处理场景，一次性处理大量请求，最大化吞吐量。

### 2.2 Online Serving

部署为 OpenAI API 兼容的服务，支持实时请求。关键指标：TTFT (首 token 延迟) 和 TPS (每秒 token 数)。

## 3 显存分析

模型权重 + KV Cache + 中间激活值。KV Cache 随序列长度线性增长，是长上下文推理的主要瓶颈。

### 3.1 本章小结

vLLM 的显存消耗主要由模型权重和 KV Cache 决定。合理的参数配置是高效推理的关键。

## 4 总结与延伸

1. vLLM 同时服务于推理部署和 RL Training
2. Offline 和 Online 两种模式各有优化方向
3. 显存分析：模型权重 + KV Cache + 激活值