

课程笔记

veRL 实战：Multi-turn SFT 训练

基于公开课程资料整理

2025

Coding Agent MultiTurn SFT loss mask 分布式训练配置

视频作者/频道：五道口纳什

发布日期：2025

视频时长：约 20 分钟

项目主页：<https://github.com/hqh1025/ai-course-notes>

目录

1 引言	2
2 三大切入点	2
3 Multi-turn SFT 的特点	2
3.1 本章小结	2
4 工程提示：SFT 先把行为轨迹教稳	2
4.1 本章小结	2
5 总结与延伸	3

1 引言

从本期开始，花几期内容介绍 veRL 的实际训练过程。本期介绍字节 ReTool 项目的 Multi-turn SFT 训练。

ReTool 项目

字节 2025 年 4 月发布的 Coding Agent 工作：用户提出复杂计算问题，模型通过写代码、调用环境、执行代码、获取反馈的循环来解决问题。提供了完整的数据集、训练脚本和模型权重。

2 三大切入点

分析任何模型训练工作，从三个方面切入：

1. **Data**: Multi-turn tool-use 数据
2. **Algorithm**: SFT（监督微调）
3. **Training**: veRL 的训练配置

3 Multi-turn SFT 的特点

SFT 数据包含多轮 tool call，每轮有 user/assistant/tool 消息。训练时只对 assistant 的输出计算 loss。

3.1 本章小结

Multi-turn SFT 是 Agentic RL Training 的前置步骤，为后续 RL 训练提供良好的初始策略。

4 工程提示：SFT 先把行为轨迹教稳

在 Agentic RL 场景里，Multi-turn SFT 的价值不只是“先训一个能说话的模型”，而是先把 tool-use 的基本行为轨迹教稳。只有模型已经学会在多轮对话里正确地调用工具、读取反馈、继续生成，后续 RL 才不会把大量采样预算浪费在最基础的格式错误上。

为什么先做 SFT 再做 RL

- SFT 先学会行为模板，降低 RL 的探索难度
- Multi-turn 数据能教会模型处理 tool 消息的时序结构
- 好的初始策略能显著提高后续 rollout 的有效比例

4.1 本章小结

对 Agentic 系统来说，SFT 是行为对齐的起点。它先把基本交互模式固定下来，再让 RL 去优化更细粒度的策略质量。

5 总结与延伸

1. ReTool 提供了完整的 Agentic SFT $\rightarrow$ RL 训练案例
2. Multi-turn 数据的处理是关键技术点
3. Data + Algorithm + Training 是分析训练工作的三大框架