

课程笔记

从概率分布视角重新审视 SFT 与 RL

基于公开课程资料整理

2025

LLM 训练 概率分布视角 SFT vs. RL FKL vs. RKL 分布与奖励

视频作者/频道：五道口纳什

发布日期：2025

视频时长：约 20 分钟

项目主页：<https://github.com/hqh1025/ai-course-notes>

目录

1 引言	2
2 SFT 的分布含义	2
3 RL 的分布含义	2
3.1 本章小结	2
4 实践含义：分布差异会怎样影响训练	2
4.1 本章小结	2
5 总结与延伸	3

1 引言

本期从概率分布的视角重新审视语言模型的 SFT 和 RL 训练过程。

分布视角

无论是 SFT 还是 RL，都是将 Base Model 的分布 π_{ref} 训练到一个新的目标分布：

- **SFT**：模仿人类数据分布的“平均形态（监督学习）
- **RL**：搜索奖励最高的分布（强化学习）

两者意味着不同的优化过程和不同的目标分布。

2 SFT 的分布含义

SFT 通过 Prompt-Response 数据对模型做监督学习。目标是让模型输出分布尽可能接近训练数据的分布。

3 RL 的分布含义

RL 中 Response 是模型 online rollout 出来的（不是固定数据）。目标是最大化期望奖励，最终分布不一定等于人类分布。

3.1 本章小结

SFT 追求“像人类”，RL 追求“奖励最高”。两者的目标分布本质不同。

4 实践含义：分布差异会怎样影响训练

一旦从分布角度理解 SFT 和 RL，就更容易看清两者为什么会训练出不同风格的模型。SFT 更像是在逼近已有数据的经验分布，而 RL 会主动把概率质量推向高奖励区域，因此两者在多样性、稳定性与可控性上的取舍也不相同。

做实验时该先问什么

- 当前任务更需要贴近人类分布，还是更需要极致奖励
- rollout 是否足够在线，能否支撑 RL 的分布移动
- 是否需要先用 SFT 打底，再用 RL 做局部强化

4.1 本章小结

分布视角的最大价值，在于它能帮助研究者判断何时该模仿、何时该搜索奖励，以及两者应该怎样组合。

5 总结与延伸

1. 分布视角是理解 SFT vs. RL 的统一框架
2. SFT = 监督模仿；RL = 奖励最大化
3. 为理解 DPO 做铺垫