

课程笔记

DPO: 从 Reward Model 到直接偏好优化

基于公开课程资料整理

2025

重新推导/理解 DPO 评估/生成一体



视频作者/频道: 五道口纳什

发布日期: 2025

视频时长: 约 20 分钟

项目主页: <https://github.com/hqhq1025/ai-course-notes>

目录

1	引言	2
2	从 RLHF 到 DPO	2
2.1	RLHF 的两阶段	2
2.2	DPO 的推导	2
2.3	本章小结	2
3	方法比较：简化流程不等于没有假设	2
3.1	本章小结	2
4	总结与延伸	3

1 引言

有了前两期关于 Reward Model 和分布视角的铺垫，本期介绍 DPO (Direct Preference Optimization)。

DPO 的核心思想

DPO 将 RLHF 的两阶段（先训 RM，再用 RM 做 RL）合并为一步直接优化，绕过了显式的 Reward Model。

2 从 RLHF 到 DPO

2.1 RLHF 的两阶段

1. 搜集偏好数据 → 训练 Reward Model
2. 用 RM 构造代理损失 → PPO 优化策略

2.2 DPO 的推导

DPO 的关键洞察：最优策略 π^* 与 reward function 之间存在闭式关系。利用这个关系，可以直接从偏好数据优化策略，无需显式 RM。

$$\mathcal{L}_{\text{DPO}} = -\mathbb{E} \left[\log \sigma \left(\beta \log \frac{\pi_{\theta}(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \beta \log \frac{\pi_{\theta}(y_l|x)}{\pi_{\text{ref}}(y_l|x)} \right) \right]$$

2.3 本章小结

DPO 通过数学推导将两阶段 RLHF 压缩为一步，是一个优雅的简化。

3 方法比较：简化流程不等于没有假设

DPO 的吸引力在于它用一个更短的优化链条替代了 RLHF 的两阶段流程，但这并不意味着它没有前提。它之所以成立，是因为我们接受了最优策略和 reward 之间的特定关系，并且愿意用 reference policy 与 KL 约束来保持训练稳定。

理解 DPO 时要保留的三点

- 它省掉的是显式 RM，不是偏好建模本身
- reference policy 仍然在目标里扮演稳定器角色
- 偏好数据质量依旧直接决定训练上限

3.1 本章小结

DPO 的“优雅”来自推导简洁，但实验时仍然要关注数据质量、reference 选择和偏好噪声，不能把它理解成零成本替代品。

4 总结与延伸

1. DPO 绕过显式 RM，直接从偏好数据优化策略
2. 数学上等价于带 KL 约束的 RLHF
3. 实现简单，效果与 RLHF 相当或更好