

课程笔记

Advantage Estimator: GRPO、RLOO、 REINFORCE++

基于公开课程资料整理

2025

RL4LLM 核心算法 GAE GRPO/RLOO REINFORCE++ baseline



视频作者/频道：五道口纳什

发布日期：2025

视频时长：约 25 分钟

项目主页：<https://github.com/hqh1025/ai-course-notes>

目录

1	引言	2
2	关键概念	2
2.1	Token Level vs. Sequence Level	2
2.2	Batch vs. Group	2
3	各算法详解	2
3.1	GAE (Generalized Advantage Estimation)	2
3.2	GRPO Advantage	2
3.3	REINFORCE / REINFORCE++ / RLOO	2
3.4	本章小结	2
4	总结与延伸	2

1 引言

本期介绍 veRL 中各种强化学习算法的 Advantage Estimator 实现。核心代码: `trainer/ppo/core_algorithms.`

2 关键概念

2.1 Token Level vs. Sequence Level

两种粒度

- **Token Level:** 每个 token 有独立的 advantage 值 (如 GAE)
- **Sequence Level:** 整个序列共享一个 advantage 值 (如 GRPO)

2.2 Batch vs. Group

Batch 是训练的 mini-batch, Group 是 GRPO 中对同一 prompt 的多个 response 分组。

3 各算法详解

3.1 GAE (Generalized Advantage Estimation)

Token-level 的 advantage 估计, 需要 value model。

3.2 GRPO Advantage

Sequence-level, 组内标准化, 不需要 value model。

3.3 REINFORCE / REINFORCE++ / RLOO

不同的 baseline 减法策略, 减小方差。

3.4 本章小结

不同 Advantage Estimator 在粒度、是否需要 value model、方差控制上各有取舍。

4 方法选择：优势估计没有银弹

GAE、GRPO、RLOO 看起来只是公式不同，但它们真正的差别在于训练信号的粒度、方差控制方式以及对额外模块的依赖。理解这些差别，比背诵缩写本身更重要。

选择 Advantage Estimator 时看三件事

- 需要 token-level 还是 sequence-level 信号
- 是否愿意引入 value model 提高复杂度
- 当前任务更怕方差大，还是更怕估计偏差

4.1 本章小结

优势估计方法的选择，本质上是在粒度、复杂度和方差之间做权衡。理解这个权衡，比盲目追新算法更有用。

5 总结与延伸

1. GAE 需要 value model, GRPO 不需要
2. GRPO 通过组内标准化实现 advantage 估计
3. RLOO 使用 leave-one-out 作为 baseline