


课程笔记

[CS25 V1] GPT Models (GPT-3, Codex) — Mark Chen, OpenAI

五道口纳什 & Codex

2026 年 3 月 28 日



视频作者/频道: Stanford Online

发布日期: 2021

视频时长: 约 60 分钟

视 频 链 接: https://www.youtube.com/playlist?list=PLoROMvodv4rNiJRchCzutFw5ItR_Z27CM

目录

1 语言建模的演进	2
1.1 从 n-gram 到 RNN	2
1.2 LSTM 与长距离依赖	2
1.3 Transformer 语言模型	2
1.4 本章小结	2
2 从语言建模到无监督学习	2
2.1 为什么关心语言建模?	2
2.2 生成模型与 Analysis by Synthesis	3
2.3 自回归建模的合理性	3
2.4 本章小结	3
3 GPT 系列的演进	3
3.1 GPT-1: 预训练 + 微调	3
3.2 GPT-2: Zero-shot 能力的涌现	3
3.3 GPT-3: 元学习视角	3
3.4 本章小结	4
4 将 GPT 应用于图像	4
4.1 Image GPT	4
4.2 DALL·E: 跨模态生成	4
4.3 本章小结	4
5 Codex: 代码生成模型	4
5.1 动机	4
5.2 HumanEval 数据集	5
5.3 Pass@k 指标	5
5.4 采样的”不合理有效性”	5
5.5 Codex-S: 监督微调	5
5.6 局限性	5
5.7 本章小结	5
6 总结与延伸	5
6.1 拓展阅读	6

1 语言建模的演进

Mark Chen (OpenAI) 以语言建模能力的进化为线索，展示了从 n-gram 到 GPT-3 的发展轨迹。

1.1 从 n-gram 到 RNN

2011 年以前的语言模型依赖巨大的 n-gram 查找表，生成文本几乎不可读。神经网络语言模型（尤其是 RNN）的引入使生成文本开始具有句子的“流畅感”，尽管语义仍不连贯。

1.2 LSTM 与长距离依赖

LSTM 通过门控机制改善了梯度流，能更好地建模长程依赖。生成文本开始在短段落内保持一定的连贯性，但仍有明显的重复和逻辑断裂。

1.3 Transformer 语言模型

自回归 Transformer 在建模长距离依赖方面更为出色。GPT-2 的生成已可保持多句连贯性，GPT-3 则能在多段落间维持角色一致性（如虚构的 Perez 博士）。

GPT-3 的标志性能力

GPT-3 的“最佳采样”质量大致相当于 GPT-2 的 top-1/top-5 采样。其 175B 参数模型能在多段落间保持风格一致性（如模仿《三体》的叙事风格），并产生诗意的隐喻。

人类能否分辨 GPT-3 生成的文本？

在新闻文章场景下，随着模型参数增加，人类分辨真假文章的准确率趋近于随机猜测（约 50%），说明大模型的生成质量已接近真实文本。

1.4 本章小结

语言建模的进步经历了 n-gram → RNN → LSTM → Transformer 的路径，每一步都显著提升了生成文本的连贯性和多样性。

2 从语言建模到无监督学习

2.1 为什么关心语言建模？

Mark Chen 坦言，语言建模本身是一个相对狭窄的能力。OpenAI 真正关心的是无监督学习——如何从海量无标注数据中学习可迁移的表示。

监督学习的瓶颈

监督学习需要大量标注数据，而标注成本高昂且难以规模化。互联网提供了近乎无限的无标注文本数据，关键问题是：能否利用这些数据来解决下游任务？

2.2 生成模型与 Analysis by Synthesis

Richard Feynman 的名言“What I cannot create, I do not understand”及其逆命题“What I can create, I can also understand”为生成式预训练提供了理论直觉：如果模型能生成多样且连贯的文本，那它必然建立了有助于语言理解的内部表示。

2.3 自回归建模的合理性

自回归目标看似“局部”——仅预测下一个 token。但考虑推理小说的场景：要准确预测揭晓凶手的那个 token，模型需要理解整个故事的逻辑链条。因此下一 token 预测实际上隐含了全局理解的需求。

Sentiment Neuron 的发现

2017 年，OpenAI 训练了一个预测 Amazon 评论下一字符的 LSTM 模型，惊讶地发现其中一个神经元自发学会了情感分类——正激活对应正面评论，负激活对应负面评论，且未见过任何标签。

2.4 本章小结

GPT 系列的核心动机并非语言建模本身，而是将其作为无监督学习的手段。自回归预训练 + 微调（或 zero-shot）的范式已成为 NLP 的主导框架。

3 GPT 系列的演进

3.1 GPT-1：预训练 + 微调

GPT-1 在互联网文本上预训练后，通过简单的分类头微调即可在多个下游任务上取得优异表现，证明了“预训练 + 微调”路线的可行性。

3.2 GPT-2：Zero-shot 能力的涌现

GPT-2 的关键洞察：许多下游任务可以自然地表达为语言模型的补全问题：

- **阅读理解**：将段落和问题拼接，在“Answer:”后补全
- **摘要**：在文本后加“TL;DR”
- **翻译**：格式化为“Sentence ... translated from French to English means”

规模的作用

Zero-shot 能力随参数规模平滑提升。此外，zero-shot 与 few-shot 之间的性能差距也随规模增大而扩大，说明大模型更擅长“学习如何学习”。

3.3 GPT-3：元学习视角

GPT-3 的核心洞察：训练过程可以被解读为元学习——外层循环是 SGD 训练步，内层循环是模型根据 prompt 识别并适应当前任务。

In-Context Learning 的涌现

Few-shot 算术实验显示，能力随参数量增加出现“阶跃函数”式的跃升——在接近 175B 参数时，加法、减法甚至部分乘法的准确率急剧上升。

3.4 本章小结

GPT-1/2/3 展示了从微调到 zero-shot/few-shot 的范式演进，核心驱动力是规模——更大的模型在预训练中发展出更强的 in-context learning 能力。

4 将 GPT 应用于图像

4.1 Image GPT

将图像视为“像素语言”，用自回归方式预测下一个像素。模型在 ImageNet 无标签数据上预训练后：

- 能生成多样化的图像补全（同一上半部分产生不同下半部分）
- 线性探测的特征质量优于同规模的有监督 ResNet
- 在 CIFAR-10 上达到 99% 准确率

4.2 DALL·E：跨模态生成

DALL·E 在文本-图像拼接序列上训练 Transformer，实现了文本到图像的生成。令人印象深刻的 zero-shot 能力包括：

- 风格转换（照片 → 素描）
- 图像着色
- 语义变换（给猫加墨镜）
- 逆 OCR（渲染指定文本）

4.3 本章小结

自回归建模具有通用性——相同的架构和训练范式可以直接应用于图像，且在缺少领域归纳偏置的情况下仍能获得有竞争力的表示。

5 Codex：代码生成模型

5.1 动机

- GPT-3 在几乎未训练过代码数据的情况下就展现了初步的代码生成能力
- 代码具有独特优势：可以通过单元测试客观评估功能正确性

5.2 HumanEval 数据集

164 道手写编程题，每题平均 8 个单元测试。手写的原因是避免 GitHub 上已有解答的”数据泄露”。

5.3 Pass@k 指标

$$\text{pass}@k = \mathbb{E} \left[1 - \frac{\binom{n-c}{k}}{\binom{n}{k}} \right]$$

其中 n 是生成的样本数， c 是通过单元测试的样本数。这是一个无偏估计量，避免了直接采样 k 个样本带来的高方差。

BLEU 不适用于代码评估

对于同一问题的正确和错误解答，BLEU 分数的分布存在大量重叠，无法有效区分功能正确性。因此必须使用基于执行的评估指标。

5.4 采样的”不合理有效性”

核心发现

从 12B 参数模型中采样 100 次， $\text{pass}@100$ 从 $\text{pass}@1$ 的不到 30% 跃升至超过 70%。这不是简单的重复采样——模型在不同样本中会组合出功能不同的解法。

温度参数影响采样多样性： $\text{pass}@1$ 适合低温（高置信度）， $\text{pass}@100$ 适合高温（高多样性）。

5.5 Codex-S：监督微调

在竞赛编程题和含 CI 测试的开源项目上微调，进一步提升性能。能力提升路径：GPT-3 → Codex → Codex-S → + 重排序 → + Oracle。

5.6 局限性

- **变量绑定**：多变量复杂操作时容易混淆
- **组合泛化**：能完成单个简单操作，但难以组合 n 个操作

5.7 本章小结

Codex 展示了将语言建模应用于代码领域的巨大潜力，而基于执行的评估和大量采样是释放其能力的关键。

6 总结与延伸

本讲的四个核心要点：

1. 神经语言建模进步迅速，GPT 系列是无监督学习推动的产物

2. 自回归建模具有通用性，即使在有强归纳偏置的领域（图像、代码）也能取得出色结果
3. 规模是涌现能力的关键驱动力
4. 采样是提升模型性能的”不合理有效”的方法

6.1 拓展阅读

- Brown et al., *Language Models are Few-Shot Learners*, NeurIPS 2020
- Chen et al., *Evaluating Large Language Models Trained on Code*, 2021
- Ramesh et al., *Zero-Shot Text-to-Image Generation* (DALL · E), 2021