


课程笔记

[CS25] Transformers in Vision —Lucas Beyer, Google Brain

基于 Stanford CS25 公开课程资料整理

2022 年 3 月 1 日



视频作者/频道: Stanford CS25 Vision Series

发布日期：2022 年 2 月 28 日

视频时长：约 60 分钟

视频链接: <https://cs.stanford.edu/people/academic-programs/cs25>

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1	Vision Transformer 的目标与测量标准	2
1.1	引入通用视觉表征的价值命题	2
1.2	Transition to Next Sections	2
1.3	本章小结	2
2	规模化预训练：数据、模型与耐心	3
2.1	BiT 的实证教训	3
2.2	挑战：数据泄露与近重复	3
2.3	本章小结	3
3	Vision Transformer 的建模与细节	4
3.1	Patch-based 序列建模	4
3.2	数据规模对比	4
3.3	本章小结	4
4	迁移策略与效率	5
4.1	Fine-tune vs. Linear Probe	5
4.2	案例：卫星图像任务	5
4.3	本章小结	5
5	系统工程与风险管理	6
5.1	工程约束	6
5.2	运维：监控 VTAB drift	6
5.3	本章小结	6
6	开放问题与未来方向	7
6.1	数据高光与预训练上限	7
6.2	多模态与视频拓展	7
6.3	本章小结	7
7	总结与延伸	8
7.1	核心总结表	8
7.2	进一步阅读	8
7.3	本章小结	8

1 Vision Transformer 的目标与测量标准

1.1 引入通用视觉表征的价值命题

Lucas Beyer 设问：为什么视觉研究者仍然在用 ImageNet 训练模型却直接拿去做卫星图像、医学切片或计数任务？答案在于**表征泛化**的缺失——传统模型在尘埃未落定的新领域里仍需要从零训练。讲座用 VTAB (Visual Task Adaptation Benchmark) 作为统一尺子，强调**少量样本可适应能力**才是真正的实用标准。




图 1：课程封面回顾。

VTAB 的三个核心维度

1. **多样任务集**：包含自然图像、专业图像与非分类任务；
2. **限样适应**：每个任务只提供极少 labeled samples；
3. **平均分数**：用平均性能而非单一任务决定模型好坏。

教学逻辑

讲座结构自上而下：先明确“什么是好表征”，再讨论“如何通过规模化与架构设计获得”，接下来讲“如何评估/部署”并在结尾提出风险与开放问题。

1.2 Transition to Next Sections

由此可见，本节关注的问题是“目标与度量”。接下来会依次谈论 **预训练规模化** → **架构创新** → **迁移策略** → **效率与风险** → **工程监控**四个关键环节。

1.3 本章小结

本章锁定通用视觉表征的问题域，提出 VTAB 等多维度指标，明确后续讨论的教学逻辑：度量、预训练、架构、迁移、部署。

2 规模化预训练：数据、模型与耐心

2.1 BiT 的实证教训

Google Brain 的 Big Transfer (BiT) 项目以 ImageNet-21k、JFT-300M 等海量数据配合 ResNet-152/ResNet-50 的方法，得出“数据 + 模型 + 训练周期”缺一不可的经验。Lucas 强调：训练早期 loss 不下降也要耐心，只有在足够 epochs 后，deep model 才能显现优势。

BiT 的三条定律

- 增加数据必须伴随更大模型容量；
- 无需人工微调的 checkpoint 可以覆盖更多下游任务；
- 训练曲线应提前观察 robustness；在 ObjectNet 上 BiT 模型展现出强鲁棒性。

2.2 挑战：数据泄露与近重复

Lucas 提醒，在大规模预训练中，必须排查下游测试集是否出现在 pre-train set 里。利用 near-duplicate detection kernel 能有效过滤，避免在 VTAB 里因泄露获得虚假的“百宝箱”优势。

数据泄露风险

使用 JFT、ImageNet1k/21k 等数据集时应持续检查：

- 图像哈希重复：去除与下游测试集重复的样本；
- 标签一致性：避免错误标签在多个数据集中反复传播；
- 法律合规：确认数据采集与使用的授权范围。

2.3 本章小结

规模化预训练尽管带来 VTAB 上的 progress，但必须与数据审查、训练耐心与鲁棒性监控并驾齐驱。

3 Vision Transformer 的建模与细节

3.1 Patch-based 序列建模

ViT 的核心创新是将图像切成 patch，并平铺喂入 Transformer。每个 patch 被视为 token，通过线性投影后加入 position embedding，再与 [CLS] token 共同输入 Transformer。




图 2: ViT 架构示意 (缩略图)。

ViT 与 CNN 的差异

1. **感受野**: ViT token 全局交互，不依赖局部卷积;
2. **位置编码**: 需要显式 position embedding 以保留空间;
3. **数据需求**: ViT 只在 10M+ 图像时才超过 CNN。

3.2 数据规模对比

ViT 在 ImageNet-1k 上表现不如 ResNet，但在 ImageNet-21k、JFT-300M 上开始领先。手头表格总结了不同数据-模型组合的 performance tipping point:

组合	数据规模	观察
ViT-B/16 + IN-1k	1.3M	分数略低于 ResNet-50
ViT-B/16 + IN-21k	14M	与 ResNet-152 持平
ViT-L/16 + JFT-300M	300M	超越所有 ResNet，鲁棒性更强

3.3 本章小结

ViT 强调序列化视觉，只有在巨量数据与模型容量配合下才显优势，本章概括了 patch token 化、位置编码与规模敏感性。

4 迁移策略与效率

4.1 Fine-tune vs. Linear Probe

讲座评估了两种迁移方式在 VTAB 上的差距：full fine-tuning 虽然性能最好，但时间代价高；linear probe 结合 projector 既保持部分性能又节省 compute。

迁移效率三法

- Linear probe：冻结主干，仅训练一个线性分类头；
- Adapter tuning：插入小模块，仅更新少数参数；
- Prompt tuning (Vision prompt)：引入 learnable tokens，保持 backbone freeze。

4.2 案例：卫星图像任务

在 VTAB 的 satellite task 下，ViT 的 backbone 使用 linear probe 后相比 ResNet 仍有 3% 提升。Lucas 解释为 Transformer 更强的 global attention 能识别长距离光谱模式。

4.3 本章小结

迁移时务必权衡 compute 与 accuracy，ViT 在 linear probe 甚至 adapter 设置下仍有优势，适合工程级 deployment。

5 系统工程与风险管理

5.1 工程约束

Autonomy 的部署还需面对工程约束，包括训练预算、推理 latency 与模型可解释性。讲者建议：

- 使用 model distillation 缩小 ViT 以适配边缘设备；
- 采用 mixed precision + gradient checkpoint 降低 GPU 内存；
- 为 downstream 任务保留 viewpoint-specific metrics（如 clarity, blur）。

不可忽视的风险

- Large model 对 rare artifact 的依赖：需要增强数据多样性；
- 解释能力差：Transformer 内部 attention 仍难解释，可以加 attention rollout；
- Energy cost：部署 JFT-scale 模型需评估电力与碳足迹。

5.2 运维：监控 VTAB drift

建议 setup drift detection：在每次模型 update 之后，重跑 VTAB sample tasks，观察 Δ performance。若 drift 超过阈值，先 rollback 再分析训练 log。

Drift awareness checklist

- 记录 pre-training dataset 版本与 sampling policy；
- 对 drift task 设立 guardrail（如 success drop > 2 ）
- 保留 auto-rollback script，便于回到最后 stable checkpoint。

5.3 本章小结

工程部署需要兼顾 latency、energy 与 interpretability，与此同时用 drift monitoring 保证长期性能，避免 “scale drift”。

6 开放问题与未来方向

6.1 数据高光与预训练上限

ViT 展现出在亿级数据上的潜力，但也引发问题：人力是否还能持续获取这些数据？是否能够通过 synthetic data + self-training 替代？Beyer 提出未来需要进一步发展**数据高光 detection** 与 **low-resource augmentation** 方法。

6.2 多模态与视频拓展

讲者还讨论了将 ViT 扩展到视频、多模态任务的可能性，关键在于如何处理 temporal coherence 与 cross-modal alignment。比如，使用 cross attention 连接 video frame 与 audio/ language cost。

6.3 本章小结

虽然 ViT 取得显著成绩，但数据获取、能源消耗与多模态拓展仍是短期内需解决的开放问题。

7 总结与延伸

7.1 核心总结表

维度	核心洞察	实践建议
目标与度量	VTAB 提供多样任务与少样测评	结合 few-shot metric 评估 backbone;
规模化预训练	BiT 说明数据、模型、训练要一起 enlarge	增量训练前先做泄露检测与 robustness probe;
架构创新	ViT 扁平化视觉 token 化需要大量数据	在 resource-bounded settings 使用 adapter/linear probe;
迁移与效率	Transformer 在 linear probe 下仍优于 CNN	采用 adapter/prompt 避免 full fine-tune;
工程与风险	需控制 energy/-dataset drift 与 explainability	建立 drift dashboard + rollback pipeline;

7.2 进一步阅读

- Beyer et al., “Are we done with ImageNet?” NeurIPS Workshop 2021 (解释 VTAB)
- Kolesnikov et al., “Big Transfer (BiT): General Visual Representation Learning,” ECCV 2020
- Dosovitskiy et al., “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale,” ICLR 2021
- Zhai et al., “Scaling Vision Transformers,” CVPR 2022
- Touvron et al., “Training data-efficient image transformers & distillation through attention,” ICML 2021

7.3 本章小结

通过目标、规模、架构、迁移、工程与未来展望六个维度，课程勾勒出通用视觉表征的研究与部署路线图，同时提醒我们要持续监控 drift 与投入成本。