



课程笔记

[CS25] Decision Transformer / RL — Aditya Grover

基于 Aditya Grover 在 Stanford CS25 公开讲座整理

2021 年 06 月 03 日

Sequential Data → Sequential Decisions.



4

视频作者/频道: Stanford CS25

发布日期: 2021 年 06 月 03 日

视频时长: 约 60 分钟

视频链接: <https://web.stanford.edu/class/cs25/recordings/>

项目主页: <https://github.com/hqhq1025/ai-course-notes>

目录

1 引言：Transformer 统一决策制定	2
2 传统强化学习回顾	2
2.1 RL 的基本框架	2
2.2 离线 RL 的挑战	2
2.3 本章小结	2
3 Decision Transformer: 将 RL 重构为序列建模	3
3.1 核心框架	3
3.2 架构细节	3
3.3 本章小结	3
4 实验结果与分析	3
4.1 离线 RL 基准测试	3
4.2 关键优势：长期信用分配	4
4.3 条件化生成的灵活性	4
4.4 本章小结	4
5 讨论与局限	4
5.1 与传统 RL 的比较	4
5.2 未来方向	4
5.3 本章小结	4
6 总结与延伸	5
6.1 拓展阅读	5

1 引言：Transformer 统一决策制定

Aditya Grover 来自 UCLA (与 UC Berkeley 合作), 介绍了将 Transformer 应用于强化学习的开创性工作——**Decision Transformer**。

Transformer 自 2017 年提出以来, 已在多个领域取得突破: 自然语言处理 (GPT、BERT)、计算机视觉 (ViT)、蛋白质折叠 (AlphaFold)、代码生成 (Codex)。一个自然的问题是: **能否用 Transformer 统一决策制定 (decision making) ?**

核心洞察

Decision Transformer 将强化学习重新定义为**序列建模问题**: 给定过去的状态、动作和奖励序列, 预测下一步应该采取的动作。这完全绕开了传统 RL 中的价值函数估计和策略梯度。

2 传统强化学习回顾

2.1 RL 的基本框架

强化学习的标准设置:

- 智能体在环境中按策略 π 选择动作
- 每步获得奖励 r_t , 目标是最大化累积回报 $R = \sum_t \gamma^t r_t$
- 核心方法: Q-learning (价值函数)、Policy Gradient (策略梯度)

2.2 离线 RL 的挑战

在线 RL vs. 离线 RL

- **在线 RL**: 智能体边探索边学习, 可以与环境交互
- **离线 RL**: 仅从预先收集的固定数据集学习, 不再与环境交互
- 离线 RL 更实用 (避免昂贵的环境交互), 但面临**分布偏移**问题

2.3 本章小结

传统 RL 方法依赖价值函数估计或策略梯度, 在离线设置下面临诸多挑战。Decision Transformer 提出了一种全新的范式。

3 Decision Transformer: 将 RL 重构为序列建模

3.1 核心框架

Decision Transformer 的序列表示

将一条轨迹表示为 token 序列:

$$\tau = (\hat{R}_1, s_1, a_1, \hat{R}_2, s_2, a_2, \dots, \hat{R}_T, s_T, a_T)$$

其中 $\hat{R}_t = \sum_{t'=t}^T r_{t'}$ 是从时刻 t 开始的**累积回报** (return-to-go)。

在推理时, 通过设定期望的 $\hat{R}_1$ 来**条件化**生成——告诉模型”我希望获得多高的总回报”, 模型便会生成相应质量的动作序列。

3.2 架构细节

- 使用 GPT 架构 (因果 Transformer, 仅向左注意力)
- 每个时间步有三个 token: return-to-go $\hat{R}_t$ 、状态 s_t 、动作 a_t
- 使用时间步嵌入 (而非标准位置嵌入)
- 训练目标: 给定历史序列, 预测下一个动作

为什么用 return-to-go 而不是即时奖励?

即时奖励 r_t 告诉模型”刚才发生了什么”, 而 return-to-go $\hat{R}_t$ 告诉模型”未来还能获得多少回报”。后者提供了**目标信号**, 使模型在推理时可以通过设定高 return-to-go 来引导行为。

3.3 本章小结

Decision Transformer 的核心创新是将 RL 问题转化为条件序列生成问题, 用 GPT 架构直接学习”高回报 $\rightarrow$ 好动作”的映射。

4 实验结果与分析

4.1 离线 RL 基准测试

在 Atari 和 OpenAI Gym 环境上, Decision Transformer 与最先进的无模型离线 RL 方法 (如 CQL) 表现相当甚至更优:

- **Atari**: 在多个游戏中达到或超过专家水平
- **OpenAI Gym**: 在 HalfCheetah、Hopper、Walker2d 等任务上有竞争力
- **Key-to-Door**: 在需要长期信用分配的稀疏奖励任务上表现出色

4.2 关键优势：长期信用分配

稀疏奖励下的优势

在 Key-to-Door 环境中，智能体必须先拿到钥匙，再开门，中间有一段空白阶段。传统 RL 在这种稀疏奖励设置下难以进行信用分配，而 Decision Transformer 通过 return-to-go 条件化天然地处理了这个问题——高 return-to-go 直接指向”拿钥匙 → 开门”的成功轨迹。

4.3 条件化生成的灵活性

通过改变推理时的目标 return-to-go，可以控制行为的质量：

- 高 return-to-go → 最优行为
- 中等 return-to-go → 次优但可行的行为
- 这提供了一种直观的”旋钮”来控制智能体的表现

4.4 本章小结

Decision Transformer 在离线 RL 基准上表现出色，特别是在稀疏奖励和长期规划方面具有天然优势。

5 讨论与局限

5.1 与传统 RL 的比较

Decision Transformer 不是万能的

- 目前主要在**离线**设置下验证，在线 RL（需要探索）的效果尚待研究
- 性能受限于训练数据的质量——如果数据中没有好的轨迹，模型也无法生成好的行为
- 对于需要精确价值估计的任务，传统方法可能更合适

5.2 未来方向

- 将 Decision Transformer 扩展到**在线 RL** 场景
- 与其他序列模型（如 RNN、State Space Models）的比较
- 多模态决策：结合视觉、语言和动作
- 更大规模的预训练和迁移学习

5.3 本章小结

Decision Transformer 提出了 RL 的全新范式，但仍有诸多开放问题，特别是在在线学习和探索方面。

6 总结与延伸

Decision Transformer 的贡献在于揭示了一个深刻的联系：**序列建模和决策制定可以统一在同一个框架下**。通过将 RL 轨迹视为 token 序列，利用 Transformer 的强大序列建模能力，我们可以绕开传统 RL 中的许多难题（如价值函数逼近、时序差分学习等）。

6.1 拓展阅读

- Chen et al., “Decision Transformer: Reinforcement Learning via Sequence Modeling,” NeurIPS 2021
- Janner et al., “Offline Reinforcement Learning as One Big Sequence Modeling Problem,” NeurIPS 2021
- Kumar et al., “Conservative Q-Learning for Offline RL,” NeurIPS 2020