

课程笔记

[CS25] Mixture of Experts / Switch Transformer —Barret Zoph, Google

五道口纳什 & Codex

2026 年 3 月 29 日

Preventing Dropping with No-Token-Left-Behind

An attempt to avoid dropped tokens by sending to the *next-best* expert (if the preferred expert is at capacity).

Empirically this approach doesn't work that well.

Token wants to get routed to its highest probability expert.

Router Probabilities
0.1 0.7 0.5 0.9 0.3 0.7
0.7 0.2 0.3 0.1 0.1 0.1
0.2 0.1 0.2 0.1 0.8 0.2

Google

Stanford

Barret Zoph

视频作者/频道: Stanford CS25

发布日期: 2021

视频时长: 约 60 分钟

视频链接: 未填写

目录

1 引言：通过稀疏性扩展 Transformer	2
2 Mixture of Experts (MoE) 基础	2
2.1 MoE 架构	2
2.2 本章小结	2
3 Switch Transformer: 简化 MoE	2
3.1 核心创新: Top-1 路由	2
3.2 容量因子 (Capacity Factor)	3
3.3 负载均衡损失	3
3.4 本章小结	3
4 实验结果	3
4.1 预训练加速	3
4.2 Top-1 vs. Top-2 路由对比	3
4.3 知识蒸馏	4
4.4 本章小结	4
5 展望与讨论	4
5.1 稀疏性的未来	4
6 总结与延伸	4
6.1 拓展阅读	4

1 引言：通过稀疏性扩展 Transformer

Barret Zoph（与 Erwin 联合演讲）介绍了通过**稀疏性（Sparsity）**来扩展 Transformer 的研究。核心动机来自缩放定律（Scaling Laws）——模型性能随规模（计算、数据、参数）的增长而可预测地提升。

稀疏模型的核心思想

传统密集模型对每个输入使用所有参数。稀疏模型（Mixture of Experts, MoE）让**不同的输入激活不同的参数子集**，从而在不成比例增加计算量的情况下大幅增加模型参数量。

2 Mixture of Experts (MoE) 基础

2.1 MoE 架构

MoE 层替换 Transformer 中的标准 FFN 层：

- 包含 N 个独立的“专家”（每个是一个 FFN）
- 一个**路由网络（Router/Gate）** 决定每个 token 发送给哪些专家
- 标准方案：Top- k 路由——每个 token 选择得分最高的 k 个专家

$$y = \sum_{i=1}^N g_i(x) \cdot E_i(x), \quad g(x) = \text{TopK}(\text{softmax}(W_g \cdot x))$$

MoE 的历史

MoE 的思想可以追溯到 1991 年 Jacobs 等人的工作。在深度学习时代，Shazeer et al. (2017) 首次将 MoE 成功应用于大规模 LSTM 语言模型。Switch Transformer 进一步简化了 MoE 并将其应用于 Transformer。

2.2 本章小结

MoE 通过条件计算实现了参数量和计算量的解耦——模型可以拥有万亿参数，但每个 token 只使用其中一小部分。

3 Switch Transformer：简化 MoE

3.1 核心创新：Top-1 路由

Switch Transformer 的简化

Switch Transformer 将路由简化为 **Top-1**——每个 token 只路由到一个专家。这带来了：

- 更低的计算开销（每个 token 只经过一个专家 FFN）
- 更简单的实现和通信模式
- 在保持质量的同时获得更高的训练吞吐量

3.2 容量因子 (Capacity Factor)

每个专家有一个固定大小的缓冲区来接收 token:

$$\text{专家缓冲区大小} = \text{Capacity Factor} \times \frac{\text{总 token 数}}{\text{专家数}}$$

- Capacity Factor = 1.0: 理想均匀分配
- Capacity Factor > 1.0: 允许负载不均衡, 减少 token 溢出
- 溢出的 token 跳过 MoE 层, 仅通过残差连接

3.3 负载均衡损失

专家坍缩问题

如果没有额外约束, 路由器可能将所有 token 都发送给少数几个专家, 导致其余专家未被训练——这就是**专家坍缩**。Switch Transformer 使用辅助负载均衡损失来鼓励均匀分配:

$$L_{\text{balance}} = \alpha \cdot N \cdot \sum_{i=1}^N f_i \cdot P_i$$

其中 f_i 是分配给专家 i 的 token 比例, P_i 是路由器对专家 i 的平均概率。

3.4 本章小结

Switch Transformer 通过 Top-1 路由大幅简化了 MoE 的训练和推理, 同时保持了稀疏模型的扩展优势。

4 实验结果

4.1 预训练加速

Switch Transformer 在相同计算预算下的训练速度提升显著:

- 与同等计算量的密集 T5 模型相比, Switch-Base 达到相同质量的**速度快 7 倍**
- 在 101 种语言上的多语言实验中, 91% 的语言获得超过 4 倍加速

4.2 Top-1 vs. Top-2 路由对比

- 在相同 FLOPS 下, Top-1 (Switch) 与 Top-2 (传统 MoE) 质量相当
- Top-1 的训练速度更快 (通信和计算更简单)
- 综合考虑速度和质量, Top-1 是更好的选择

4.3 知识蒸馏

稀疏模型的一个挑战是参数量巨大，部署困难。通过将稀疏模型蒸馏回密集模型，可以在保留大部分性能的同时缩小模型：

- Switch-Base 蒸馏到 T5-Base：保留约 30% 的质量提升
- 这证明稀疏预训练可以作为更好的“教师”来提升密集模型

4.4 本章小结

Switch Transformer 在预训练速度和多语言任务上表现出色，知识蒸馏为实际部署提供了可行路径。

5 展望与讨论

5.1 稀疏性的未来

讲者认为稀疏性将在以下方面发挥作用：

- 自适应计算：不同难度的输入使用不同的计算量
- 与线性注意力等效率方法结合
- 新的预训练目标

6 总结与延伸

MoE 和 Switch Transformer 代表了一种重要的模型扩展范式：通过稀疏激活，在计算预算有限的情况下大幅增加模型容量。这一思想在后续的 GShard、GLaM、Mixtral 等工作中得到广泛应用和发展。

6.1 拓展阅读

- Fedus et al., “Switch Transformers: Scaling to Trillion Parameter Models with Simple and Efficient Sparsity,” JMLR 2022
- Shazeer et al., “Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer,” ICLR 2017
- Lepikhin et al., “GShard: Scaling Giant Models with Conditional Computation,” ICLR 2021