

课程笔记

[CS25] Perceiver and Perceiver IO — Andrew Jaegle, DeepMind

五道口纳什 & Codex

2026 年 3 月 29 日

Why? We want to understand all data modalities



→ Inductive bias engineering has worked for some of our data (notably images).
→ But we can't afford to hand-design inductive biases for every type of data!

Stanford

Drew Jaegle

视频作者/频道: Stanford CS25

发布日期: 2021

视频时长: 约 60 分钟

视频链接: 未填写

目录

1 引言：通用架构的动机	2
2 标准 Transformer 的瓶颈	2
2.1 自注意力的二次复杂度	2
2.2 本章小结	2
3 Perceiver：交叉注意力瓶颈	2
3.1 核心架构	2
3.2 位置编码的角色	3
3.3 本章小结	3
4 Perceiver IO：通用输出	3
4.1 从感知到输出	3
4.2 多模态多任务应用	3
4.3 本章小结	4
5 总结与延伸	4
5.1 拓展阅读	4

1 引言：通用架构的动机

Andrew Jaegle 来自 DeepMind，介绍了 **Perceiver** 系列架构的研究动机和设计。核心目标是开发**通用感知架构**——一个能处理任意模态输入（图像、音频、视频、点云、文本等）的单一模型。

为什么需要通用架构？

- 现实世界的的数据模态极其多样（视觉、听觉、触觉、本体感觉、语言等）
- 为每种模态设计专用架构效率低下且不可持续
- 人类大脑能用统一的神经计算处理多种感知输入

2 标准 Transformer 的瓶颈

2.1 自注意力的二次复杂度

标准 Transformer 的自注意力复杂度为 $O(N^2)$ ，其中 N 是序列长度。对于高维感知数据：

- 图像 $224 \times 224 = 50176$ 像素
- 音频 $48\text{kHz} \times \text{数秒} = \text{数十万采样点}$
- 视频 = 帧数 $\times$ 像素数，轻松达到百万级

直接在序列上做自注意力在计算上不可行。

2.2 本章小结

标准 Transformer 的二次复杂度是构建通用感知架构的主要障碍。Perceiver 通过引入潜在瓶颈来解决这个问题。

3 Perceiver：交叉注意力瓶颈

3.1 核心架构

Perceiver 的关键设计

引入一组可学习的潜在变量（latent array），维度远小于输入。处理流程：

1. **交叉注意力**：潜在变量（query）从输入数据（key, value）中提取信息。复杂度 $O(M \times N)$ ，其中 $M \ll N$
2. **自注意力**：潜在变量之间进行自注意力计算。复杂度 $O(M^2)$
3. 重复上述步骤（迭代细化）

这样，计算复杂度主要由 M （潜在变量数量）决定，与输入大小 N 解耦。

与 Slot Attention 的关系

Perceiver 的潜在变量类似于 Slot Attention 中的“slots”——两者都使用可学习的向量从输入数据中提取信息。但 Perceiver 更通用，不局限于对象分割。

3.2 位置编码的角色

由于 Perceiver 的输入是“扁平化”的字节数组，位置编码至关重要：

- 使用傅里叶特征（Fourier features）编码位置
- 可以灵活适应不同模态的空间/时间结构
- 不假设任何特定的空间拓扑

3.3 本章小结

Perceiver 通过交叉注意力将高维输入压缩到低维潜在空间，使计算复杂度不再受限于输入大小。

4 Perceiver IO：通用输出

4.1 从感知到输出

原始 Perceiver 主要处理分类等简单输出。**Perceiver IO** 将通用性扩展到输出端。

Perceiver IO 的输出机制

使用**输出查询**（output query）通过交叉注意力从潜在变量中读取信息：

1. 定义与目标输出对应的查询向量
2. 这些查询向潜在变量做交叉注意力
3. 得到任意大小和结构的输出

输出大小独立于潜在变量数量，实现了 $O(\text{output size})$ 的线性缩放。

4.2 多模态多任务应用

Perceiver IO 可以用**同一个架构**处理：

- 图像分类和目标检测
- 光流估计（dense prediction）
- 自然语言理解
- 多模态输入（如视频 + 音频 + 文本）
- 星际争霸 II 游戏

将任何数据视为表格数据

Perceiver 将所有输入数据视为“表格数据”——一个 $N \times C$ 的数组，其中 N 是元素数量， C 是每个元素的特征维度。位置编码提供结构信息。这种统一视角是通用性的关键。

4.3 本章小结

Perceiver IO 将通用性从输入端扩展到输出端，真正实现了“一个架构处理所有模态”的愿景。

5 总结与延伸

Perceiver 系列展示了一种优雅的方式来构建通用感知架构：通过潜在瓶颈解耦输入/输出大小与计算复杂度。这一思想对后续的通用模型设计产生了深远影响。

5.1 拓展阅读

- Jaegle et al., “Perceiver: General Perception with Iterative Attention,” ICML 2021
- Jaegle et al., “Perceiver IO: A General Architecture for Structured Inputs & Outputs,” ICLR 2022
- Locatello et al., “Object-Centric Learning with Slot Attention,” NeurIPS 2020