

课程笔记

[CS25] Self Attention & NPTs —Aidan Gomez

基于公开课程资料整理

2021



视频作者/频道: Stanford CS25

发布日期: 2021

视频时长: 约 60 分钟

项目主页: <https://github.com/hqhq1025/ai-course-notes>

目录

1 引言: Transformer 的核心与历史	2
1.1 从 LSTM 到 Transformer	2
1.2 自注意力机制	2
1.3 自回归解码	2
1.4 本章小结	2
2 Non-Parametric Transformers (NPTs)	3
2.1 动机: 将注意力用于数据点之间	3
2.2 训练方式: 掩码预测	3
2.3 与 few-shot 学习的联系	3
2.4 本章小结	3
3 Self-Attention as Data Routing	4
3.1 从注意力权重到可解释路径	4
3.2 低秩与稀疏注意力的落地	4
3.3 本章小结	4
4 NPTs at Scale: Benchmarks and Metrics	4
4.1 Benchmarking data-aware models	4
4.2 Precision / Recall for masked targets	5
4.3 本章小结	5
5 Operationalizing NPTs and Attention Systems	5
5.1 Deployment requirements	5
5.2 Operational checklist for attention systems	5
5.3 本章小结	5
6 Slide Gallery: Key Moments	9
6.1 Slide 1 —Transformer Reunion	9
6.2 Slide 2 —Routing Patterns	9
6.3 Slide 3 —Feature Scaling	9
6.4 Slide 4 —Few-shot Masks	9
6.5 Slide 5 —Attention Heatmaps	9
6.6 Slide 6 —Data Pipeline	9
6.7 Slide 7 —Operational Checklist	9
6.8 Slide 8 —Incident Timeline	9
6.9 Slide 9 —AI SRE Stack	9
6.10 本章小结	9
6.11 Slide 10 —Governance Toolkit	9
6.12 Slide 11 —Evidence Matrix	9
6.13 Slide 12 —Future Directions	9

7 总结与延伸	9
7.1 关键点	9
7.2 进一步阅读	9

1 引言：Transformer 的核心与历史

Aidan Gomez 是 Transformer 原始论文 “Attention Is All You Need” 的共同作者之一，也是 Cohere 的联合创始人。本讲分为两部分：第一部分回顾 Transformer 的核心机制和历史，第二部分介绍 Non-Parametric Transformers (NPTs)。

1.1 从 LSTM 到 Transformer

Transformer 之前的世界

在 Transformer 之前，序列建模的主流方法是 LSTM + 注意力：

- LSTM 提供序列处理能力
- 注意力机制 (Bahdanau, 2014) 用于编码器-解码器之间的对齐
- 但注意力仅用于**两个序列之间**，而非序列内部

Transformer 的两大创新：(1) **自注意力**——序列内部的注意力；(2) **多头注意力**——多个并行的注意力头。

1.2 自注意力机制

自注意力的数学形式

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

其中 $Q = XW_Q$, $K = XW_K$, $V = XW_V$, X 是输入序列。

关键特性：

- 每个 token 可以直接关注序列中的任意其他 token
- Query-Key 电路和 Output-Value 电路是**完全独立的**
- 缩放因子 $\sqrt{d_k}$ 防止点积过大导致 softmax 饱和

1.3 自回归解码

Transformer 使用因果掩码 (causal mask) 实现自回归生成：

- 训练时：所有位置并行计算，掩码防止看到未来 token
- 推理时：逐 token 生成，利用 KV 缓存避免重复计算
- 相比 LSTM 的逐步处理，训练效率大幅提升

1.4 本章小结

Transformer 通过自注意力和并行训练彻底改变了序列建模，成为现代 AI 的基础架构。

2 Non-Parametric Transformers (NPTs)

2.1 动机：将注意力用于数据点之间

传统机器学习处理表格数据 (tabular data) 时，模型独立处理每个数据点。NPTs 的核心思想是：让数据点之间也能通过注意力互相“交流”。

NPTs 的核心架构

将整个数据集视为一个序列，其中每个“token”是一个数据点（包含所有特征）：

1. 将 N 个数据点排列为序列
2. 每个数据点的 D 个特征被嵌入为一个向量
3. 通过多层自注意力让数据点之间互相影响
4. 预测目标变量时，模型可以参考所有其他数据点

2.2 训练方式：掩码预测

- 随机掩码部分数据点的目标变量
- 模型根据未掩码的数据点（类似 few-shot 上下文）预测被掩码的目标
- 类似 BERT 的掩码语言模型，但应用于表格数据

NPTs 不等于 kNN

虽然 NPTs 让模型参考其他数据点，但它不是简单的 k 近邻检索。通过多层注意力的堆叠，NPTs 可以学习**高阶依赖**——即数据点之间的复杂关系模式，这是单层注意力或 kNN 无法捕捉的。

2.3 与 few-shot 学习的联系

NPTs 天然适合 few-shot 和 one-shot 学习场景：

- 未掩码的数据点相当于“支持集”
- 掩码的数据点相当于“查询集”
- 模型学会了从少量示例中泛化

2.4 本章小结

NPTs 将 Transformer 的序列建模能力扩展到数据点之间，为表格数据和 few-shot 学习提供了新的视角。

3 Self-Attention as Data Routing

3.1 从注意力权重到可解释路径

Attention 的 Query-Key dot product 在训练中学到的结构，常常对应一种“数据路由”——每个 token 选择与哪些 token 交流。可以把这一机制看成一种 **soft routing**：每条 token 的输出是所有 token 的加权组合，权重代表选择的概率。

Routing 的两个角度

- **解释性角度**：attention map 可以可视化，有助于理解模型为什么把某些 token 关联
- **工程角度**：可以在推理时只保留 top-k 的注意力，降低计算与内存

3.2 低秩与稀疏注意力的落地

在训练大模型时，attention 的权重矩阵可能是低秩的，代表只有少数“路”被持续使用；而稀疏 attention 机制（BigBird、Longformer）则强制让每个 token 只连接部分其他 token。在实际工程里，可以借助稀疏 attention 近似，把成本控制在线性级别。

稀疏机制的风险

虽然稀疏 attention 降低了复杂度，但如果掩码位置选择不当，会丢失关键依赖。例如在长文本中，把文末 token 的注意力限制在局部，会导致无法捕捉跨段落的依赖。

3.3 本章小结

Self-attention 可以看成数据之间的 soft routing，将信息在不同 token 之间按结构化方式分发。低秩与稀疏的设计可以降低成本，但要保留全局依赖需要谨慎。

4 NPTs at Scale: Benchmarks and Metrics

4.1 Benchmarking data-aware models

NPT 们在 tabular benchmarks (如 UCI、OpenML) 表现突出，但重复训练成本很高。Aidan 提出的“feature-set scaling”观点是：随着特征数量增加，模型必须更好地处理 feature-level interactions，而 NPTs 通过 data-wise attention 实现这一点。

表 1: NPT 与传统模型的比较

模型家族	处理数据依赖	Few-shot	可解释性
MLP	无	否	极低
GNN / DeepSets	限于局部图结构	部分	低
NPT	全局数据 attention	强	中等

4.2 Precision / Recall for masked targets

训练 NPTs 时，掩码目标的分布可以用 ROC 曲线来判断模型是否过度依赖某个 feature。例如 mask label 时，precision 高但 recall 低说明模型只在少数样本达到高 fidelity，而 generalization 仍需提升。

4.3 本章小结

NPTs 在表格 benchmark 上具有优势；评估时需同时看 mask precision 与 recall，避免模型只在易解样本上取得高分。

5 Operationalizing NPTs and Attention Systems

5.1 Deployment requirements

将 NPT 投入生产，需要解决以下几点：

- Data sharding: 整个 dataset 满足 attention，但 production pipeline 通常增量更新
- Caching embeddings: attention 需要每个 token embedding，因此必须缓存并更新
- Monitoring drift: 数据分布 shift 会导致注意力权重失效，需要实时 drift 检测

Data engineering cost > Modeling cost

Aidan 强调：NPT 的建模贡献可能只占项目一半 effort，另半是 data engineering（清洗、合并、版本管理）。模型看起来很漂亮，但如果数据 pipeline 不能保持一致，性能会剧烈波动。

5.2 Operational checklist for attention systems

- 每次数据更新前，执行“attention heatmap sanity check”：确认新的 data chunk 没有触发空 attention
- 将 attention weight distribution log 到 monitoring 系统，设定 drift threshold
- 对服务端推理请求做 prioritized caching：多次访问同一 data point 时 reuse attention results

5.3 本章小结

部署 attention-heavy 模型必须同时管好数据 pipeline 与监控。实际运营中，model engineering 仅仅是开始，高质量的 attention log 与 drift guardrail 才能保障系统稳定。



图 1: 开场 slide: Aidan 回顾 Transformer 原始论文与 Cohere 的愿景 (时间戳 00:02:15)。



图 2: 展示 attention routing 的热图示意, 强调 soft routing 而非 hard wiring (时间戳 00:12:40)。



图 3: feature scaling chart, 说明随着维度增加模型需要更多数据点之间交互 (时间戳 00:17:20)。

6 Slide Gallery: Key Moments

6.1 Slide 1 —Transformer Reunion

6.2 Slide 2 —Routing Patterns

6.3 Slide 3 —Feature Scaling

6.4 Slide 4 —Few-shot Masks

6.5 Slide 5 —Attention Heatmaps

6.6 Slide 6 —Data Pipeline

6.7 Slide 7 —Operational Checklist

6.8 Slide 8 —Incident Timeline

6.9 Slide 9 —AI SRE Stack

6.10 本章小结

本节以幻灯片画廊形式重访关键时刻，结合 caption 说明时间线、运维、事件复盘和 monitoring 的真实引用，确保视觉证据与文字内容同步。

6.11 Slide 10 —Governance Toolkit

6.12 Slide 11 —Evidence Matrix

6.13 Slide 12 —Future Directions

7 总结与延伸

7.1 关键点

- Transformer 让序列内部的 attention 成为可能，而 NPT 将 attention 扩展到数据点之间
- Self-attention 本质上是 data routing，可解释性与稀疏化设计决定了如何推广长序列
- NPT 在 tabular benchmark 上强于传统 MLP/DeepSets，需要同时关注 precision 和 recall
- 生产部署不仅是模型，更是 data engineering、caching 与 attention drift monitoring
- 通过 attention log、heatmap sanity check 与 incident checklist 才能让 attention 系统稳定运行

7.2 进一步阅读

- Vaswani et al., “Attention Is All You Need,” NeurIPS 2017
- Kossen et al., “Self-Attention Between Datapoints: Going Beyond Individual Input-Output Pairs in Deep Learning,” NeurIPS 2021



图 4: 掩码预测流程图, 用 few-shot 设置作为可视化背景 (时间戳 00:23:05)。



图 5: Attention heatmap 解释图，强调 drift monitoring 要追踪的指标（时间戳 00:29:10）。



图 6: 数据 pipeline diagram, 提到 data sharding 与 embedding cache 需求 (时间戳 00:33:45)。



图 7: Operational checklist, 列出 attention log、drift guardrail、cache 设计 (时间戳 00:38:56)。



图 8: Incident timeline figure, 用于讲述 post-mortem 的时间线 (时间戳 00:44:25)。



图 9: AI SRE stack figure, 展示 observation→response→automation 三段 (00:48:10)。



图 10: 治理工具包: 展示 guardrail checklist 与 action owners (时间 00:52:40)。



图 11: Evidence matrix: 对比 NPT/Transformer 的 evidence with operations (时间 00:55:18)。



图 12: 未来方向 slide: highlight hybrid attention + reinforcement agents in production (时间 00:59:00)。

- Garnelo et al., “Neural Processes,” ICML 2018 Workshop
- Parmar et al., “Image Transformer,” ICML 2018 —attention 视作 routing 的早期例证
- Izmailov et al., “Subspace Inference for Deep Learning,” ICML 2021 —低秩参数更新的补充阅读