

课程笔记

[CS25] Self Attention & NPTs —Aidan Gomez

五道口纳什 & Codex

2026 年 3 月 29 日



视频作者/频道: Stanford CS25

发布日期: 2021

视频时长: 约 60 分钟

视频链接: 未填写

目录

1 引言：Transformer 的核心与历史	2
1.1 从 LSTM 到 Transformer	2
1.2 自注意力机制	2
1.3 自回归解码	2
1.4 本章小结	2
2 Non-Parametric Transformers (NPTs)	3
2.1 动机：将注意力用于数据点之间	3
2.2 训练方式：掩码预测	3
2.3 与 few-shot 学习的联系	3
2.4 本章小结	3
3 总结与延伸	4
3.1 拓展阅读	4

1 引言：Transformer 的核心与历史

Aidan Gomez 是 Transformer 原始论文 “Attention Is All You Need” 的共同作者之一，也是 Cohere 的联合创始人。本讲分为两部分：第一部分回顾 Transformer 的核心机制和历史，第二部分介绍 Non-Parametric Transformers (NPTs)。

1.1 从 LSTM 到 Transformer

Transformer 之前的世界

在 Transformer 之前，序列建模的主流方法是 LSTM + 注意力：

- LSTM 提供序列处理能力
- 注意力机制 (Bahdanau, 2014) 用于编码器-解码器之间的对齐
- 但注意力仅用于**两个序列之间**，而非序列内部

Transformer 的两大创新：(1) **自注意力**——序列内部的注意力；(2) **多头注意力**——多个并行的注意力头。

1.2 自注意力机制

自注意力的数学形式

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

其中 $Q = XW_Q$, $K = XW_K$, $V = XW_V$, X 是输入序列。

关键特性：

- 每个 token 可以直接关注序列中的任意其他 token
- Query-Key 电路和 Output-Value 电路是**完全独立的**
- 缩放因子 $\sqrt{d_k}$ 防止点积过大导致 softmax 饱和

1.3 自回归解码

Transformer 使用因果掩码 (causal mask) 实现自回归生成：

- 训练时：所有位置并行计算，掩码防止看到未来 token
- 推理时：逐 token 生成，利用 KV 缓存避免重复计算
- 相比 LSTM 的逐步处理，训练效率大幅提升

1.4 本章小结

Transformer 通过自注意力和并行训练彻底改变了序列建模，成为现代 AI 的基础架构。

2 Non-Parametric Transformers (NPTs)

2.1 动机：将注意力用于数据点之间

传统机器学习处理表格数据 (tabular data) 时，模型独立处理每个数据点。NPTs 的核心思想是：让数据点之间也能通过注意力互相“交流”。

NPTs 的核心架构

将整个数据集视为一个序列，其中每个“token”是一个数据点（包含所有特征）：

1. 将 N 个数据点排列为序列
2. 每个数据点的 D 个特征被嵌入为一个向量
3. 通过多层自注意力让数据点之间互相影响
4. 预测目标变量时，模型可以参考所有其他数据点

2.2 训练方式：掩码预测

- 随机掩码部分数据点的目标变量
- 模型根据未掩码的数据点（类似 few-shot 上下文）预测被掩码的目标
- 类似 BERT 的掩码语言模型，但应用于表格数据

NPTs 不等于 kNN

虽然 NPTs 让模型参考其他数据点，但它不是简单的 k 近邻检索。通过多层注意力的堆叠，NPTs 可以学习**高阶依赖**——即数据点之间的复杂关系模式，这是单层注意力或 kNN 无法捕捉的。

2.3 与 few-shot 学习的联系

NPTs 天然适合 few-shot 和 one-shot 学习场景：

- 未掩码的数据点相当于“支持集”
- 掩码的数据点相当于“查询集”
- 模型学会了从少量示例中泛化

2.4 本章小结

NPTs 将 Transformer 的序列建模能力扩展到数据点之间，为表格数据和 few-shot 学习提供了新的视角。

3 总结与延伸

本讲从 Transformer 的历史出发,展示了自注意力机制如何从序列内部扩展到数据点之间。NPTs 代表了将 Transformer 应用于更广泛机器学习问题的一种有趣尝试,暗示着“一切皆序列”的统一建模范式。

3.1 拓展阅读

- Vaswani et al., “Attention Is All You Need,” NeurIPS 2017
- Kossen et al., “Self-Attention Between Datapoints: Going Beyond Individual Input-Output Pairs in Deep Learning,” NeurIPS 2021
- Garnelo et al., “Neural Processes,” ICML 2018 Workshop