


## 课程笔记

# [CS25] Transformer Circuits / In-Context Learning —Chris Olah, Anthropic

基于公开课程资料整理

2021



视频作者/频道: Stanford CS25

发布日期: 2021

视频时长: 约 60 分钟

项目主页: <https://github.com/hqhq1025/ai-course-notes>

# 目录

|                                        |          |
|----------------------------------------|----------|
| <b>1 引言：机制可解释性</b>                     | <b>2</b> |
| <b>2 注意力头的两个独立电路</b>                   | <b>2</b> |
| 2.1 QK 电路与 OV 电路 . . . . .             | 2        |
| 2.2 本章小结 . . . . .                     | 2        |
| <b>3 归纳头 (Induction Heads)</b>         | <b>3</b> |
| 3.1 什么是归纳头? . . . . .                  | 3        |
| 3.2 归纳头与 In-Context Learning . . . . . | 3        |
| 3.3 本章小结 . . . . .                     | 3        |
| <b>4 信息流与残差流</b>                       | <b>3</b> |
| 4.1 残差流视角 . . . . .                    | 3        |
| 4.2 组合性 . . . . .                      | 4        |
| 4.3 本章小结 . . . . .                     | 4        |
| <b>5 总结与延伸</b>                         | <b>4</b> |
| 5.1 拓展阅读 . . . . .                     | 4        |

# 1 引言：机制可解释性

Chris Olah 来自 Anthropic，是机制可解释性（Mechanistic Interpretability）领域的先驱。他的研究目标是理解神经网络内部的算法——不只是观察输入输出行为，而是弄清楚参数如何映射到具体的计算过程。

## 什么是机制可解释性？

机制可解释性试图逆向工程神经网络：

- 不是“模型为什么做出这个预测”（归因/解释）
- 而是“模型内部实际执行了什么算法”（机制理解）
- 类似于逆向工程一个编译后的程序——从二进制代码恢复源代码逻辑

## 2 注意力头的两个独立电路

### 2.1 QK 电路与 OV 电路

#### 注意力头的数学分解

一个注意力头可以分解为两个完全独立的电路：

- **QK 电路** (Query-Key)：决定“哪些 token 应该关注哪些 token”

$$A = \text{softmax} \left( \frac{(XW_Q)(XW_K)^T}{\sqrt{d_k}} \right)$$

- **OV 电路** (Output-Value)：决定“当一个 token 被关注时，什么信息被传递”

$$\text{Output} = A \cdot (XW_VW_O)$$

这两个电路是独立的参数矩阵，尽管公式看起来它们是纠缠的。

#### 直觉理解

想象一个图书馆系统：

- QK 电路 = 目录/索引系统——决定去哪本书找信息
- OV 电路 = 书的内容——决定找到后获取什么信息

你可以改变索引系统而不改变书的内容，反之亦然。

### 2.2 本章小结

注意力头的 QK 和 OV 电路的独立性是理解 Transformer 内部计算的基础。

## 3 归纳头 (Induction Heads)

### 3.1 什么是归纳头？

#### 归纳头——In-Context Learning 的机制

归纳头是一种在 Transformer 中自发涌现的**两层注意力模式**，执行以下算法：

**规则：**如果序列中出现过“A B ... A”模式，则预测下一个 token 为“B”。

**机制：**

1. **第一层：**一个“前一个 token”注意力头将 B 的信息复制到 B 之后的位置
2. **第二层：**归纳头从当前 A 回头寻找之前 A 的下一个位置（现在包含 B 的信息），并将 B 复制到输出

这本质上是**上下文最近邻**——在序列上下文中查找匹配模式并复制答案。

### 3.2 归纳头与 In-Context Learning

Chris Olah 提出了一个重要假说：**归纳头可能是 in-context learning 的核心机制**。

- 归纳头在训练过程中突然出现（相变），伴随着 loss 的急剧下降
- 出现时机与模型获得 in-context learning 能力的时机一致
- 在不同规模的模型中都观察到这一现象

#### 归纳头不是全部

虽然归纳头是最显著的 in-context learning 机制，但可能还有其他贡献因素。Chris 强调这是当前的“工作假说”，而非最终结论。

### 3.3 本章小结

归纳头是一种优雅的两层注意力模式，可能是 Transformer in-context learning 能力的核心机制。

## 4 信息流与残差流

### 4.1 残差流视角

#### 残差流 (Residual Stream)

将 Transformer 视为一条“残差流”——信息沿着残差连接流动，每个注意力头和 MLP 层向流中读写信息：

- 残差流是模型各层之间的“通信总线”
- 早期层可以将信息写入残差流，供后续层读取
- 这解释了为什么跨层的注意力模式组合能产生复杂行为

## 4.2 组合性

Transformer 的强大来自**组合性**——多个注意力头的效果可以组合，产生比单个头复杂得多的行为。通过残差流视角，我们可以分析信息如何在层间流动和组合。

## 4.3 本章小结

残差流提供了分析 Transformer 信息流动的统一框架，使得跨层行为的理解成为可能。

# 5 总结与延伸

Chris Olah 的工作展示了机制可解释性的巨大潜力——我们可以打开 Transformer 的“黑箱”，发现其中的具体算法。归纳头的发现是这一研究方向的标志性成果，它不仅提供了对 in-context learning 的机制理解，也暗示了更多复杂电路等待发现。

## 5.1 拓展阅读

- Elhage et al., “A Mathematical Framework for Transformer Circuits,” Anthropic, 2021
- Olsson et al., “In-context Learning and Induction Heads,” Anthropic, 2022
- Olah et al., “Zoom In: An Introduction to Circuits,” Distill, 2020