


课程笔记

[CS25] Transformer Circuits / In-Context Learning —Chris Olah, Anthropic

五道口纳什 & Codex

2026 年 3 月 29 日



视频作者/频道: Stanford CS25

发布日期: 2021

视频时长: 约 60 分钟

视频链接: 未填写

目录

1 引言：机制可解释性	2
2 注意力头的两个独立电路	2
2.1 QK 电路与 OV 电路	2
2.2 本章小结	2
3 归纳头 (Induction Heads)	3
3.1 什么是归纳头?	3
3.2 归纳头与 In-Context Learning	3
3.3 本章小结	3
4 信息流与残差流	3
4.1 残差流视角	3
4.2 组合性	4
4.3 本章小结	4
5 总结与延伸	4
5.1 拓展阅读	4

1 引言：机制可解释性

Chris Olah 来自 Anthropic，是机制可解释性（Mechanistic Interpretability）领域的先驱。他的研究目标是理解神经网络内部的算法——不只是观察输入输出行为，而是弄清楚参数如何映射到具体的计算过程。

什么是机制可解释性？

机制可解释性试图逆向工程神经网络：

- 不是“模型为什么做出这个预测”（归因/解释）
- 而是“模型内部实际执行了什么算法”（机制理解）
- 类似于逆向工程一个编译后的程序——从二进制代码恢复源代码逻辑

2 注意力头的两个独立电路

2.1 QK 电路与 OV 电路

注意力头的数学分解

一个注意力头可以分解为两个完全独立的电路：

- **QK 电路** (Query-Key)：决定“哪些 token 应该关注哪些 token”

$$A = \text{softmax} \left(\frac{(XW_Q)(XW_K)^T}{\sqrt{d_k}} \right)$$

- **OV 电路** (Output-Value)：决定“当一个 token 被关注时，什么信息被传递”

$$\text{Output} = A \cdot (XW_VW_O)$$

这两个电路是独立的参数矩阵，尽管公式看起来它们是纠缠的。

直觉理解

想象一个图书馆系统：

- QK 电路 = 目录/索引系统——决定去哪本书找信息
- OV 电路 = 书的内容——决定找到后获取什么信息

你可以改变索引系统而不改变书的内容，反之亦然。

2.2 本章小结

注意力头的 QK 和 OV 电路的独立性是理解 Transformer 内部计算的基础。

3 归纳头 (Induction Heads)

3.1 什么是归纳头？

归纳头——In-Context Learning 的机制

归纳头是一种在 Transformer 中自发涌现的**两层注意力模式**，执行以下算法：

规则：如果序列中出现过“A B ... A”模式，则预测下一个 token 为“B”。

机制：

1. **第一层：**一个“前一个 token”注意力头将 B 的信息复制到 B 之后的位置
2. **第二层：**归纳头从当前 A 回头寻找之前 A 的下一个位置（现在包含 B 的信息），并将 B 复制到输出

这本质上是**上下文最近邻**——在序列上下文中查找匹配模式并复制答案。

3.2 归纳头与 In-Context Learning

Chris Olah 提出了一个重要假说：**归纳头可能是 in-context learning 的核心机制**。

- 归纳头在训练过程中突然出现（相变），伴随着 loss 的急剧下降
- 出现时机与模型获得 in-context learning 能力的时机一致
- 在不同规模的模型中都观察到这一现象

归纳头不是全部

虽然归纳头是最显著的 in-context learning 机制，但可能还有其他贡献因素。Chris 强调这是当前的“工作假说”，而非最终结论。

3.3 本章小结

归纳头是一种优雅的两层注意力模式，可能是 Transformer in-context learning 能力的核心机制。

4 信息流与残差流

4.1 残差流视角

残差流 (Residual Stream)

将 Transformer 视为一条“残差流”——信息沿着残差连接流动，每个注意力头和 MLP 层向流中读写信息：

- 残差流是模型各层之间的“通信总线”
- 早期层可以将信息写入残差流，供后续层读取
- 这解释了为什么跨层的注意力模式组合能产生复杂行为

4.2 组合性

Transformer 的强大来自**组合性**——多个注意力头的效果可以组合，产生比单个头复杂得多的行为。通过残差流视角，我们可以分析信息如何在层间流动和组合。

4.3 本章小结

残差流提供了分析 Transformer 信息流动的统一框架，使得跨层行为的理解成为可能。

5 总结与延伸

Chris Olah 的工作展示了机制可解释性的巨大潜力——我们可以打开 Transformer 的“黑箱”，发现其中的具体算法。归纳头的发现是这一研究方向的标志性成果，它不仅提供了对 in-context learning 的机制理解，也暗示了更多复杂电路等待发现。

5.1 拓展阅读

- Elhage et al., “A Mathematical Framework for Transformer Circuits,” Anthropic, 2021
- Olsson et al., “In-context Learning and Induction Heads,” Anthropic, 2022
- Olah et al., “Zoom In: An Introduction to Circuits,” Distill, 2020