


课程笔记

[CS25] Transformers in Audio/Speech/Music —Prateek Verma

五道口纳什 & Codex

2026 年 3 月 29 日



视频作者/频道: Stanford CS25

发布日期: 2021

视频时长: 约 50 分钟

视频链接: 未填写

目录

1 引言：音频领域的 Transformer	2
2 从不同视角理解 Transformer	2
2.1 本章小结	2
3 采样级别的音频语言建模	2
3.1 SampleRNN 到 Transformer	2
3.2 上下文长度的挑战	3
3.3 本章小结	3
4 语音和音乐的 Transformer 应用	3
4.1 语音识别与合成	3
4.2 音乐生成与理解	3
4.3 本章小结	3
5 总结与延伸	4
5.1 拓展阅读	4

1 引言：音频领域的 Transformer

Prateek Verma 来自 Stanford，介绍了 Transformer 在音频、语音和音乐领域的应用。音频处理与文本/图像有本质差异：音频信号是**高采样率的时间序列**（如 16kHz 语音、48kHz 音乐），这对 Transformer 的序列长度提出了极大挑战。

音频表示的特殊性

- **原始波形**：每秒数万个采样点，序列极长
- **频谱图/梅尔频谱**：时频表示，类似于图像，但时间轴有因果性
- **离散音频 token**：通过 VQ-VAE 等方法将音频离散化为 token 序列

2 从不同视角理解 Transformer

Prateek 提供了 Transformer 自注意力的一个有趣视角：

自注意力 vs. 小波变换

传统信号处理使用**固定**的基函数（如小波、傅里叶基）来分析信号。Transformer 的自注意力可以看作一种**自适应**的基函数——它根据输入数据动态决定哪些时间点/频率点需要更多关注。这使得 Transformer 在处理非平稳信号时天然优于固定基方法。

2.1 本章小结

Transformer 通过自适应注意力机制，在音频领域提供了超越传统信号处理方法的灵活性。

3 采样级别的音频语言建模

3.1 SampleRNN 到 Transformer

早期的音频生成模型（如 WaveNet、SampleRNN）逐采样点自回归生成，速度极慢。Transformer 可以在以下层面进行“语言建模”：

- **采样级别**：直接预测下一个音频采样值（精度最高但最慢）
- **帧级别**：预测频谱帧（平衡精度与效率）
- **Token 级别**：先将音频编码为离散 token，再做语言建模（最高效）

3.2 上下文长度的挑战

音频的上下文长度瓶颈

以 16kHz 采样率的 100ms 音频为例,就有 1600 个采样点。标准注意力需要 $1600^2 \approx 2.56 \times 10^6$ 的内存。对于几秒的音频片段,这个问题更加严峻。解决方案包括:

- 稀疏注意力模式
- 线性注意力近似
- 分层处理 (先局部再全局)
- 音频 tokenization 降低序列长度

3.3 本章小结

音频的高采样率对 Transformer 的上下文长度提出了独特挑战,催生了多种高效注意力方案。

4 语音和音乐的 Transformer 应用

4.1 语音识别与合成

- ASR (自动语音识别): Transformer 已成为主流架构 (如 Whisper)
- TTS (文本到语音): Tacotron 2 + Transformer、VITS 等
- 语音翻译: 端到端的跨语言语音转换

4.2 音乐生成与理解

- Music Transformer (Huang et al.): 基于相对注意力的音乐生成
- Jukebox (OpenAI): 使用 VQ-VAE + Transformer 的原始音频音乐生成
- 音乐信息检索: 节拍检测、乐器识别、情感分析

研究中的诚实性

Prateek 引用 DeepMind 研究者的观点,强调在发表论文时应诚实报告训练技巧的贡献——很多时候性能提升来自于工程技巧而非模型创新。区分“模型实际贡献”和“训练技巧贡献”对于领域的健康发展至关重要。

4.3 本章小结

Transformer 在语音和音乐领域的应用正在快速发展,从识别到生成全面覆盖。

5 总结与延伸

音频领域的 Transformer 应用展示了这一架构的通用性，同时也揭示了其在处理长序列信号时的独特挑战。随着高效注意力机制和音频 tokenization 方法的发展，Transformer 在音频领域的能力将持续提升。

5.1 拓展阅读

- Huang et al., “Music Transformer: Generating Music with Long-Term Structure,” ICLR 2019
- Dhariwal et al., “Jukebox: A Generative Model for Music,” arXiv 2020
- Radford et al., “Robust Speech Recognition via Large-Scale Weak Supervision (Whisper),” 2022