


课程笔记

[CS25] GLOM: Part-Whole Hierarchies —Geoffrey Hinton

基于公开课程资料整理

2021

The embedding vectors for nearby columns
at a single time-step as GLOM settles



At each level there are islands of agreement. These islands represent the parse tree for the scene.

It is a multi-level, real-valued Ising model with coordinate transforms between levels.



视频作者/频道: Stanford CS25

发布日期: 2021

视频时长: 约 55 分钟

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1 引言：部分-整体层次结构问题	2
2 GLOM 的核心思想	2
2.1 岛屿与列	2
2.2 对比学习的角色	2
2.3 本章小结	2
3 心理意象与变换随机场	3
3.1 心理意象 (Mental Imagery)	3
3.2 变换随机场	3
3.3 神经场 (Neural Fields)	3
3.4 本章小结	3
4 为什么 GLOM 难以直接落地	3
4.1 训练信号与结构假设的张力	3
4.2 工程上最棘手的三个问题	4
4.3 本章小结	4
5 对今天视觉基础模型的启发	4
5.1 对象中心表征仍然是未完成任务	4
5.2 如果今天重新做这件事	4
5.3 本章小结	4
6 总结与延伸	5
6.1 拓展阅读	5

1 引言：部分-整体层次结构问题

Geoffrey Hinton 介绍了 **GLOM**——一个关于神经网络如何表示部分-整体层次结构的思想实验。这是一篇“设计文档”而非已实现的系统，但其中的思想深刻影响了后续研究。

核心问题

人类视觉天然地将场景解析为层次结构：像素 → 边缘 → 部件（鼻子、眼睛）→ 物体（脸）→ 场景。如何让神经网络也表示这种**动态的、依赖于输入**的部分-整体关系？

为什么这个问题难？

传统 CNN 通过固定的层级结构处理视觉信息，但：

- 同一个部件（如圆形）在不同上下文中可以是不同物体的一部分
- 层次结构应该是**动态的**——依赖于具体输入而非预先固定
- 经典的“胶囊网络”试图解决这个问题，但在实现上遇到困难

2 GLOM 的核心思想

2.1 岛屿与列

GLOM 的架构可以想象为一个二维网格上的“列”，每个列对应输入的一个空间位置（类似 ViT 的 patch）。每个列有多个层级，每个层级用一个向量表示。

GLOM 的关键机制

- 每个空间位置有一个“列”，包含从低级到高级的多个表示层
- 同一层级上，相邻位置如果属于同一物体，其表示向量应该**趋于一致**——形成“岛屿”
- **同层注意力**：同一层级的相邻位置通过注意力机制互相靠拢
- **跨层预测**：高层预测低层（自上而下），低层预测高层（自下而上）

2.2 对比学习的角色

Hinton 简要介绍了对比自监督学习的思想：

- 同一图像的不同裁剪应有相似的表示
- 这种方法可以学习到有意义的特征，无需标签
- GLOM 中的“岛屿形成”类似于对比学习中的聚类过程

2.3 本章小结

GLOM 通过“岛屿”机制动态地形成部分-整体层次结构，而非依赖固定的网络拓扑。

3 心理意象与变换随机场

3.1 心理意象 (Mental Imagery)

Hinton 讨论了神经网络如何表示空间关系：

- 人类使用“心理意象”来推理空间关系（如家具的排列）
- 涉及关系推理的任务受益于某种内部的“画布”或“地图”
- GLOM 中的空间网格可以作为这种内部表示的载体

3.2 变换随机场

消歧义的挑战

一个圆形可能是轮子的一部分、也可能是眼睛。Hinton 提出使用**变换随机场**来消歧义：节点之间的消息传递需要考虑空间变换。例如，“鼻子”向周围发送的“嘴巴应该在下方”的消息，需要根据空间位置关系进行变换。

3.3 神经场 (Neural Fields)

Hinton 将 GLOM 与神经场 (NeRF 等) 联系起来：

- 高层表示可以通过给定空间位置来预测低层表示
- 这类似于 NeRF 中给定 3D 坐标预测颜色和密度
- 同一个高层向量可以在不同位置生成不同的低层预测

3.4 本章小结

GLOM 综合了对比学习、变换随机场和神经场等多个概念，构建了一个关于视觉层次表示的统一框架。

4 为什么 GLOM 难以直接落地

4.1 训练信号与结构假设的张力

GLOM 最吸引人的地方，是它试图让网络显式表示“部分属于哪个整体”。但也正因为目标太雄心勃勃，训练信号变得不那么直接。分类任务的监督只能告诉模型“图里有什么”，却很难精确约束每一个 patch 应该聚成哪个对象岛屿；纯自监督训练又容易学到纹理相似性，而不是真正的对象一致性。

GLOM、Capsule 与 ViT 的关键差别

Capsule Networks 试图通过显式路由来表达部分-整体关系，GLOM 则改为用同层一致性和跨层预测来形成“岛屿”；ViT 的成功路径更朴素，它不强行要求对象结构显式出现，而是依赖大数据和大计算隐式学到有用表示。GLOM 的问题不是想法不对，而是它比 ViT 需要更强的结构性训练信号。

4.2 工程上最棘手的三个问题

- **边界不稳定**: 相邻 patch 在早期训练阶段很容易因为纹理相似而错误聚合。
- **层级耦合过强**: 高层和低层互相预测会让优化过程彼此牵制, 难以单独调试。
- **评测不清晰**: 如果没有对象级标注, 研究者很难知道模型是否真的学到了 part-whole hierarchy。

漂亮的概念图不等于可训练系统

GLOM 非常像一份优秀的研究设计备忘录: 它准确指出了视觉系统缺少什么, 但从“应该表示什么”走到“如何稳定训练出来”之间还有很长的工程距离。这也是很多对象中心表示方法共同面对的问题。

4.3 本章小结

GLOM 的瓶颈不在概念表达, 而在于缺少足够强且足够稳定的训练与评测闭环。

5 对今天视觉基础模型的启发

5.1 对象中心表征仍然是未完成任务

尽管 GLOM 没有像 Transformer 一样成为主流架构, 但它提出的问题并没有消失。视觉系统仍然需要回答: 如何把像素组织成对象、如何表达对象间的空间关系、如何让模型具备稳定的组合泛化能力。今天的 world model、视频理解模型、机器人感知系统, 仍在以不同方式重提这些问题。

GLOM 留下来的三条长期启发

1. 视觉表征不应只追求分类可分性, 还要追求对象结构可读性。
2. 层次表示最好是动态形成的, 而不是由固定网络拓扑硬编码。
3. 自监督学习真正有价值的方向, 是让表示能支持后续推理, 而不只是压缩输入。

5.2 如果今天重新做这件事

如果以 2026 年的工具重做 GLOM, 较合理的路线可能是: 先用强大的视觉基础模型和视频数据提供对象级先验, 再把对象槽位、时序一致性和动作条件建模结合起来。换句话说, GLOM 的思想更可能以模块化形式融入现代系统, 而不是单独作为一整个端到端架构出现。

“The right question is not whether hierarchy exists, but how much of it the network should discover by itself.”

5.3 本章小结

GLOM 作为单一架构未必成功, 但它对对象中心视觉和层次化 world model 的启发仍然非常直接。

6 总结与延伸

GLOM 虽然是“纯粹的设计文档”，但提出了关于神经网络如何表示部分-整体关系的深刻思想。这些思想影响了后续关于视觉表示学习、对象中心学习和层次化表示的研究方向。

6.1 拓展阅读

- Hinton, “How to represent part-whole hierarchies in a neural network,” Neural Computation, 2023
- Sabour et al., “Dynamic Routing Between Capsules,” NeurIPS 2017
- Mildenhall et al., “NeRF: Representing Scenes as Neural Radiance Fields,” ECCV 2020