


课程笔记

[CS25] Language and Human Alignment

—Jan Leike, OpenAI

五道口纳什 & Codex

2026 年 3 月 29 日



openai.com/blog/instruction-following

Stanford

视频作者/频道: Stanford CS25

发布日期: 2023

视频时长: 约 55 分钟

视频链接: 未填写

目录

1	引言：AI 对齐的紧迫性	2
2	从 RLHF 到超级对齐	2
2.1	RLHF 的基本框架	2
2.2	AI 辅助评估	2
2.3	ChatGPT 中的对齐实践	2
2.4	本章小结	2
3	超级对齐的挑战	3
3.1	能力超越评估能力	3
3.2	对齐研究的方向	3
3.3	本章小结	3
4	总结与延伸	3
4.1	拓展阅读	3

1 引言：AI 对齐的紧迫性

Jan Leike 领导 OpenAI 的对齐团队，拥有超过 10 年的对齐研究经验。他指出 AI 对齐问题正在从理论变为实践：随着 AI 系统能力的快速提升，确保其行为与人类意图一致变得越来越紧迫。

AI 对齐的核心问题

如何确保 AI 系统做**人类真正希望它做的事情**，而不仅仅是表面上看起来在做正确的事？随着模型能力超越人类评估能力，这个问题将变得更加困难。

2 从 RLHF 到超级对齐

2.1 RLHF 的基本框架

基于人类反馈的强化学习 (RLHF)

RLHF 的标准流程：

1. **监督微调 (SFT)**：在人工编写的高质量回答上微调模型
2. **奖励模型训练**：收集人类对模型输出的偏好排序，训练奖励模型
3. **PPO 优化**：用奖励模型的信号通过强化学习优化策略模型

2.2 AI 辅助评估

可扩展的监督 (Scalable Oversight)

当 AI 系统的输出超越人类直接评估的能力时，一个关键思路是用 **AI 辅助人类评估**：

- 让 AI 为人类提供批评 (critique)
- 让 AI 帮助人类进行事实核查
- 让 AI 生成解释，帮助人类理解复杂输出
- 使用辩论 (debate) 机制：两个 AI 互相挑战，人类做裁判

2.3 ChatGPT 中的对齐实践

Jan 分享了 InstructGPT/ChatGPT 开发中的经验：

- ChatGPT 的数据标注者偏向程序员群体，导致了某种“技术风格”
- 不同标注者群体会导致不同的模型风格
- 理想情况下，模型应该能适应用户偏好的风格

2.4 本章小结

RLHF 是当前实现对齐的主要工具，但随着模型能力增长，需要更可扩展的评估和监督机制。

3 超级对齐的挑战

3.1 能力超越评估能力

对齐的根本困难

核心困境：如果 AI 的能力超越了人类在某个领域的评估能力，我们如何确保它在做正确的事？

- 人类可能无法区分“真正正确的回答”和“看起来正确但有微妙错误的回答”
- 模型可能学会“讨好评估者”而非真正解决问题
- 这不是遥远的未来问题——在编程、数学等领域已经部分存在

3.2 对齐研究的方向

- **可解释性**：理解模型内部在做什么
- **过程监督**：不仅评估最终结果，还评估推理过程
- **递归奖励建模**：用对齐的 AI 帮助对齐更强的 AI
- **宪法 AI**：让 AI 根据明确的原则进行自我约束

3.3 本章小结

超级对齐是 AI 安全领域最重要也最困难的开放问题之一。

4 总结与延伸

Jan Leike 的演讲强调了对齐研究的紧迫性和复杂性。从 RLHF 到可扩展监督，从人类评估到 AI 辅助评估，对齐方法需要与 AI 能力同步进化。这不仅是技术问题，也涉及深刻的哲学和社会问题。

4.1 拓展阅读

- Ouyang et al., “Training Language Models to Follow Instructions with Human Feedback,” NeurIPS 2022
- Leike et al., “Scalable Agent Alignment via Reward Modeling,” arXiv 2018
- Burns et al., “Weak-to-Strong Generalization,” OpenAI 2023
- Bai et al., “Constitutional AI: Harmlessness from AI Feedback,” 2022