


课程笔记

[CS25] Emergent Abilities and Scaling — Jason Wei, Google

基于公开课程资料整理

2023



视频作者/频道: Stanford CS25

发布日期: 2023

视频时长: 约 55 分钟

项目主页: <https://github.com/hqhq1025/ai-course-notes>

目录

1 引言：缩放定律与涌现能力	2
2 涌现能力的定义与观察	2
2.1 什么是涌现能力?	2
2.2 典型的涌现能力	2
2.3 本章小结	2
3 Chain-of-Thought Prompting	3
3.1 思维链的核心思想	3
3.2 CoT 的变体	3
3.3 本章小结	3
4 指令微调 (Instruction Tuning)	3
4.1 FLAN 与指令微调	3
4.2 与 fine-tuning 的区别	3
4.3 本章小结	3
5 如何判断涌现是真现象还是度量伪影	4
5.1 阈值效应与离散指标	4
5.2 为什么研究者仍然重视它	4
5.3 本章小结	4
6 从研究结论到产品策略	4
6.1 CoT 与 Instruction Tuning 的组合价值	4
6.2 不应忽视的数据问题	4
6.3 本章小结	5
7 总结与延伸	5
7.1 开放问题	5
7.2 拓展阅读	5

1 引言：缩放定律与涌现能力

Jason Wei 来自 Google, 介绍了大语言模型中的**涌现能力** (Emergent Abilities) 和缩放 (Scaling) 研究。这项工作联合了 Google、DeepMind 和 Stanford 的研究者。

缩放定律回顾

Kaplan et al. (2020) 发现, 语言模型的测试损失随计算量、数据量和参数量的增加而**可预测**地下降, 呈现幂律关系。但下游任务的性能并不总是平滑提升。

2 涌现能力的定义与观察

2.1 什么是涌现能力？

涌现能力的定义

一种能力被称为“涌现的” (emergent), 当且仅当:

- 在**小模型**中完全不存在 (接近随机水平)
- 在模型规模达到某个**临界点**后突然出现
- 无法通过观察小模型的趋势来预测其出现

这与缩放定律中的平滑改进形成鲜明对比——涌现是**非线性的、阶跃式的**。

2.2 典型的涌现能力

Jason 展示了多个涌现能力的例子:

- **多步算术**: 小模型完全无法做, 大模型突然可以
- **逻辑推理**: 类似的阶跃跳变
- **代码执行追踪**
- **多语言翻译**中的某些语言对

涌现的不可预测性

涌现能力的关键特征是**不可预测性**——你无法通过训练小模型来判断某个能力需要多大的模型才能涌现。这意味着:

- 当前模型可能“差一点”就能解决某些任务
- 也可能还需要几个数量级的规模增长
- 这对资源规划和安全评估都构成挑战

2.3 本章小结

涌现能力是大语言模型最令人惊讶的特性之一, 挑战了“平滑缩放”的直觉。

3 Chain-of-Thought Prompting

3.1 思维链的核心思想

Chain-of-Thought (CoT) Prompting

在提示中展示**逐步推理过程**，而不仅是最终答案。例如：

标准提示：“Roger 有 5 个网球，他又买了 2 筒，每筒 3 个。他现在有多少？ 答：11”

CoT 提示：“Roger 有 5 个网球，他又买了 2 筒，每筒 3 个。所以他买了 $2 \times 3 = 6$ 个。 $5 + 6 = 11$ 。答：11”

关键发现：CoT 只在**大模型**中有效——这本身就是一种涌现能力。

3.2 CoT 的变体

- **Zero-shot CoT**：只需在提示末尾加 “Let’s think step by step”
- **Self-consistency**：多次采样 CoT 推理，取多数投票
- **Least-to-most prompting**：将复杂问题分解为子问题

3.3 本章小结

CoT 是释放大模型推理能力的关键技术，但它本身也是涌现的——小模型无法从中受益。

4 指令微调 (Instruction Tuning)

4.1 FLAN 与指令微调

指令微调的效果

在大量不同任务的指令-输出对上微调模型：

- 显著提升模型在**未见过的**任务上的 zero-shot 表现
- 本质上是教会模型“遵循指令”这个**元能力**
- 与 CoT 结合 (Flan-PaLM) 效果更佳

4.2 与 fine-tuning 的区别

指令微调 vs. 任务微调

- **任务微调**：在特定任务上训练，提升该任务的性能
- **指令微调**：在多样化的指令上训练，提升所有任务的 zero-shot 性能
- 关键区别：指令微调的目标是**泛化到新指令**，而非记住特定任务

4.3 本章小结

指令微调使模型从“能做任务”变为“听得懂指令”，是 ChatGPT 等产品背后的关键技术。

5 如何判断涌现是真现象还是度量伪影

5.1 阈值效应与离散指标

涌现能力之所以引发争议，一个重要原因是很多基准使用**离散阈值式指标**。例如，模型从 49% 提升到 51% 时，可能在图上看起来像“突然学会了”；但如果改用连续指标或更细粒度评测，这种跃迁可能只是平滑曲线的一段。

看到“拐点”时先问评测怎么定义

判断能力是否真的涌现，第一步不是讨论哲学，而是检查指标设计：是否存在 hard threshold、是否存在 few-shot prompt 对小模型极不友好、是否存在数据污染或 benchmark 饱和。如果这些问题没排除，所谓“相变”很可能只是度量方式放大了曲线变化。

5.2 为什么研究者仍然重视它

即便存在度量争议，涌现讨论依然有价值，因为它提醒研究者：能力增长并不总是线性可预测。对于产品团队而言，这意味着模型一旦跨过某个能力门槛，prompt、工具、检索和微调策略都可能突然变得更有效。

5.3 本章小结

讨论涌现时，既不能把所有拐点都神秘化，也不能忽视规模增长带来的真实能力重组。

6 从研究结论到产品策略

6.1 CoT 与 Instruction Tuning 的组合价值

Jason Wei 的工作可以被压缩成一个非常实用的产品结论：**基础模型规模决定能力上限，CoT 决定是否能调用推理，Instruction Tuning 决定用户是否能稳定触发这些能力**。三者缺一不可。

一个实用的系统设计顺序

1. 先确认基础模型是否已经跨过目标任务的能力门槛。
2. 再用 prompt / CoT / self-consistency 挖掘推理性能。
3. 最后用 instruction tuning 或 preference tuning 固化交互体验。

6.2 不应忽视的数据问题

很多团队在看到 CoT 和 instruction tuning 的成功后，会立即增加更多人工模板或更长的推理示例。但真正决定长期收益的，往往是训练数据是否覆盖了**任务多样性、错误示例和边界案例**。如果数据过于单一，模型只是学会了某种回答腔调，而非真正提升泛化。

“Scale gives you the possibility of reasoning; the rest of the pipeline decides whether users can actually reach it.”

6.3 本章小结

从工程视角看，涌现、CoT 和指令微调并不是三个独立话题，而是一条完整的能力释放链条。

7 总结与延伸

Jason Wei 的演讲串联了大语言模型研究中的三个核心主题：缩放带来涌现能力、CoT 释放推理能力、指令微调实现通用遵从。这三者共同构成了现代 LLM 的能力基础。

7.1 开放问题

- 涌现能力是真实的相变还是度量的伪影？
- 如何降低获得涌现能力所需的计算成本？
- 需要更多更好的基准来评估新涌现的能力

7.2 拓展阅读

- Wei et al., “Emergent Abilities of Large Language Models,” TMLR 2022
- Wei et al., “Chain-of-Thought Prompting Elicits Reasoning in Large Language Models,” NeurIPS 2022
- Chung et al., “Scaling Instruction-Finetuned Language Models (Flan-PaLM),” 2022
- Schaeffer et al., “Are Emergent Abilities of LLMs a Mirage?” NeurIPS 2023