


课程笔记

[CS25] Emergent Abilities and Scaling — Jason Wei, Google

基于公开课程资料整理

2023



视频作者/频道: Stanford CS25

发布日期: 2023

视频时长: 约 55 分钟

项目主页: <https://github.com/hqhq1025/ai-course-notes>

目录

1 引言：缩放定律与涌现能力	2
2 涌现能力的定义与观察	2
2.1 什么是涌现能力?	2
2.2 典型的涌现能力	2
2.3 本章小结	2
3 Chain-of-Thought Prompting	3
3.1 思维链的核心思想	3
3.2 CoT 的变体	3
3.3 本章小结	3
4 指令微调 (Instruction Tuning)	3
4.1 FLAN 与指令微调	3
4.2 与 fine-tuning 的区别	3
4.3 本章小结	3
5 总结与延伸	4
5.1 开放问题	4
5.2 拓展阅读	4

1 引言：缩放定律与涌现能力

Jason Wei 来自 Google, 介绍了大语言模型中的**涌现能力** (Emergent Abilities) 和缩放 (Scaling) 研究。这项工作联合了 Google、DeepMind 和 Stanford 的研究者。

缩放定律回顾

Kaplan et al. (2020) 发现, 语言模型的测试损失随计算量、数据量和参数量的增加而**可预测**地下降, 呈现幂律关系。但下游任务的性能并不总是平滑提升。

2 涌现能力的定义与观察

2.1 什么是涌现能力？

涌现能力的定义

一种能力被称为“涌现的” (emergent), 当且仅当:

- 在**小模型**中完全不存在 (接近随机水平)
- 在模型规模达到某个**临界点**后突然出现
- 无法通过观察小模型的趋势来预测其出现

这与缩放定律中的平滑改进形成鲜明对比——涌现是**非线性的、阶跃式的**。

2.2 典型的涌现能力

Jason 展示了多个涌现能力的例子:

- **多步算术**: 小模型完全无法做, 大模型突然可以
- **逻辑推理**: 类似的阶跃跳变
- **代码执行追踪**
- **多语言翻译**中的某些语言对

涌现的不可预测性

涌现能力的关键特征是**不可预测性**——你无法通过训练小模型来判断某个能力需要多大的模型才能涌现。这意味着:

- 当前模型可能“差一点”就能解决某些任务
- 也可能还需要几个数量级的规模增长
- 这对资源规划和安全评估都构成挑战

2.3 本章小结

涌现能力是大语言模型最令人惊讶的特性之一, 挑战了“平滑缩放”的直觉。

3 Chain-of-Thought Prompting

3.1 思维链的核心思想

Chain-of-Thought (CoT) Prompting

在提示中展示**逐步推理过程**，而不仅是最终答案。例如：

标准提示：“Roger 有 5 个网球，他又买了 2 筒，每筒 3 个。他现在有多少？ 答：11”

CoT 提示：“Roger 有 5 个网球，他又买了 2 筒，每筒 3 个。所以他买了 $2 \times 3 = 6$ 个。 $5 + 6 = 11$ 。答：11”

关键发现：CoT 只在**大模型**中有效——这本身就是一种涌现能力。

3.2 CoT 的变体

- **Zero-shot CoT**：只需在提示末尾加 “Let’s think step by step”
- **Self-consistency**：多次采样 CoT 推理，取多数投票
- **Least-to-most prompting**：将复杂问题分解为子问题

3.3 本章小结

CoT 是释放大模型推理能力的关键技术，但它本身也是涌现的——小模型无法从中受益。

4 指令微调 (Instruction Tuning)

4.1 FLAN 与指令微调

指令微调的效果

在大量不同任务的指令-输出对上微调模型：

- 显著提升模型在**未见过的**任务上的 zero-shot 表现
- 本质上是教会模型“遵循指令”这个**元能力**
- 与 CoT 结合 (Flan-PaLM) 效果更佳

4.2 与 fine-tuning 的区别

指令微调 vs. 任务微调

- **任务微调**：在特定任务上训练，提升该任务的性能
- **指令微调**：在多样化的指令上训练，提升所有任务的 zero-shot 性能
- 关键区别：指令微调的目标是**泛化到新指令**，而非记住特定任务

4.3 本章小结

指令微调使模型从“能做任务”变为“听得懂指令”，是 ChatGPT 等产品背后的关键技术。

5 总结与延伸

Jason Wei 的演讲串联了大语言模型研究中的三个核心主题：缩放带来涌现能力、CoT 释放推理能力、指令微调实现通用遵从。这三者共同构成了现代 LLM 的能力基础。

5.1 开放问题

- 涌现能力是真实的相变还是度量的伪影？
- 如何降低获得涌现能力所需的计算成本？
- 需要更多更好的基准来评估新涌现的能力

5.2 拓展阅读

- Wei et al., “Emergent Abilities of Large Language Models,” TMLR 2022
- Wei et al., “Chain-of-Thought Prompting Elicits Reasoning in Large Language Models,” NeurIPS 2022
- Chung et al., “Scaling Instruction-Finetuned Language Models (Flan-PaLM),” 2022
- Schaeffer et al., “Are Emergent Abilities of LLMs a Mirage?” NeurIPS 2023