

课程笔记

[CS25] Strategic Games (Diplomacy) — Noam Brown, Meta

五道口纳什 & Codex

2026 年 3 月 29 日



视频作者/频道: Stanford CS25

发布日期: 2023

视频时长: 约 55 分钟

视频链接: 未填写

目录

1 引言：从扑克到外交——不完美信息博弈	2
2 搜索时计算 (Test-Time Compute)	2
2.1 从快思考到慢思考	2
2.2 本章小结	2
3 Cicero：外交游戏 AI	2
3.1 系统架构	2
3.2 对话生成的挑战	3
3.3 实验结果	3
3.4 本章小结	3
4 更广泛的意义	3
4.1 从游戏到现实	3
5 总结与延伸	3
5.1 拓展阅读	3

1 引言：从扑克到外交——不完美信息博弈

Noam Brown 来自 Meta AI (FAIR)，是 Libratus/Pluribus (扑克 AI) 和 Cicero (外交游戏 AI) 的核心研究者。本讲聚焦于**外交游戏 (Diplomacy)** 中 AI 面临的独特挑战。

外交游戏简介

外交是一款 7 人策略棋盘游戏，设定在一战前的欧洲。每个玩家控制一个国家，核心特点：

- **同时行动**：所有玩家同时提交行动，而非轮流
- **自然语言沟通**：玩家在每轮行动前可以自由交流、结盟、谈判
- **背叛是允许的**：承诺不具约束力，“破坏友谊的游戏”
- **核心技能**：在鼓励不信任的环境中建立信任

2 搜索时计算 (Test-Time Compute)

2.1 从快思考到慢思考

搜索的价值

Noam 首先回顾了扑克 AI 中的关键发现：

- 训练后的 bot 在困难局面下**瞬间**做出决策（查表）
- 人类在困难局面下会**花时间思考**（有时数分钟）
- 给 bot 加入**推理时搜索**（test-time compute）——在当前局面重新计算更好的策略——可以用极少的参数达到大参数模型的效果

这一发现预示了后来的“思考 token”和 o1 等方向。

2.2 本章小结

搜索时计算是 AI 博弈中的关键技术，其思想已扩展到语言模型推理中。

3 Cicero：外交游戏 AI

3.1 系统架构

Cicero 的核心组件

Cicero 由两个主要模块组成：

1. **战略推理引擎**：预测所有玩家的行动，搜索最优策略（类似于扑克 AI 的均衡求解）
2. **对话模型**：基于大语言模型的自然语言生成，用于与其他玩家沟通

两个模块的协调是系统的关键——战略意图必须通过语言准确传达。

3.2 对话生成的挑战

对话模型的“愚蠢”泄露

一个有趣的技术难题：战略引擎会将**完整的己方计划**（包括对当前对话伙伴的敌对行动）输入对话模型。由于对话模型并不“理解”策略，它可能会**直接告诉对手你要攻击他**——这种“诚实得过分”的行为需要额外的过滤机制来防止。

3.3 实验结果

Cicero 在 webDiplomacy.net 上与人类玩家匿名对战：

- 在多局游戏中达到**前 10%** 的表现水平
- 大部分人类玩家**未能识别出** Cicero 是 AI
- Cicero 表现出了合作、谈判和适度欺骗的能力

3.4 本章小结

Cicero 是首个在需要自然语言沟通的多人策略游戏中达到人类水平的 AI 系统。

4 更广泛的意义

4.1 从游戏到现实

- 外交游戏中的技能（谈判、信任建立、策略沟通）直接适用于商业、外交等现实场景
- **语言和推理的结合**是 AI 的下一个前沿——不仅要“说得好”，还要“想得深”
- 搜索时计算的思想正在从博弈领域扩展到通用语言模型推理

5 总结与延伸

Noam Brown 的工作展示了 AI 在**需要沟通的策略环境**中的能力。Cicero 结合了博弈论推理和语言模型生成，代表了从“纯棋盘 AI”（AlphaGo、Libratus）到“社交 AI”的重要一步。推理时搜索的思想更是对整个 AI 领域产生了深远影响。

5.1 拓展阅读

- FAIR et al., “Human-level play in the game of Diplomacy by combining language models with strategic reasoning,” Science, 2022
- Brown & Sandholm, “Superhuman AI for heads-up no-limit poker: Libratus beats top professionals,” Science, 2018
- Snell et al., “Scaling LLM Test-Time Compute,” 2024