


课程笔记

[CS25] Robotics and Imitation Learning

—Ted Xiao, Google

基于公开课程资料整理

2023



视频作者/频道: Stanford CS25

发布日期: 2023

视频时长: 约 65 分钟

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1 引言：机器人的 Transformer 时代	2
2 RT-1: Robotics Transformer	2
2.1 架构与训练	2
2.2 缩放效应	2
2.3 本章小结	2
3 SayCan: 语言模型作为机器人规划器	3
3.1 核心思想	3
3.2 本章小结	3
4 Inner Monologue: 闭环语言反馈	3
4.1 机器人的内心独白	3
4.2 本章小结	3
5 RT-2: 视觉-语言-动作模型	4
5.1 从 VLM 到 VLA	4
5.2 本章小结	4
6 总结与延伸	4
6.1 拓展阅读	4

1 引言：机器人的 Transformer 时代

Ted Xiao 来自 Google Brain 机器人团队，介绍了 Transformer 和大型基础模型在机器人领域的应用。核心主题是：如何让机器人像语言模型一样，通过大规模数据和模型获得通用能力。

机器人学的独特挑战

与纯数字领域（文本、图像）不同，机器人需要在**物理世界**中行动：

- **实时性**：约 100ms 的推理延迟约束
- **安全性**：错误动作可能导致硬件损坏
- **数据稀缺**：无法像互联网文本一样大规模获取机器人操作数据
- **多模态**：需要融合视觉、语言、本体感觉、力反馈等

2 RT-1: Robotics Transformer

2.1 架构与训练

RT-1 的设计

RT-1 (Robotics Transformer 1) 是 Google 的大规模机器人操作模型：

- 输入：RGB 图像 + 自然语言指令
- 输出：离散化的机器人动作（末端执行器位移、夹爪开合等）
- 训练数据：13 个机器人、17 个月的数据收集、超过 130K 演示
- 模型大小需控制在 100ms 推理时间内

2.2 缩放效应

RT-1 展示了机器人领域的缩放效应：

- 更多数据和更多样化的任务 → 更好的泛化
- 多任务训练优于单任务训练
- 但受限于实体数据收集的高成本

2.3 本章小结

RT-1 证明了 Transformer 可以用于真实世界的机器人控制，但数据获取仍是瓶颈。

3 SayCan: 语言模型作为机器人规划器

3.1 核心思想

SayCan: 接地的语言规划

SayCan 将大语言模型用于机器人**任务规划**:

- **Say**: LLM 评估每个可能动作的“有用性”(与任务目标的相关性)
- **Can**: 价值函数评估每个动作的“可行性”(当前状态下能否成功执行)
- 最终选择 = $\arg \max(\text{有用性} \times \text{可行性})$

这将 LLM 的世界知识与机器人的物理能力“接地”(grounding)在一起。

3.2 本章小结

SayCan 展示了 LLM 作为机器人高级规划器的潜力,通过“可行性过滤”解决了 LLM 不了解机器人能力的问题。

4 Inner Monologue: 闭环语言反馈

4.1 机器人的内心独白

Inner Monologue 的创新

在 SayCan 的基础上加入**闭环反馈**:

- 机器人执行动作后,视觉检测器判断是否成功
- 成功/失败信息**反馈给 LLM**
- LLM 根据反馈重新规划后续动作
- 支持人类在执行中途改变指令

这使得机器人不再是“盲目执行预定计划”,而是能够**适应性地重规划**。

4.2 本章小结

Inner Monologue 通过闭环反馈使机器人系统更加鲁棒和灵活。

5 RT-2: 视觉-语言-动作模型

5.1 从 VLM 到 VLA

RT-2 的突破

RT-2 将视觉-语言模型 (VLM) 直接微调为**视觉-语言-动作** (VLA) 模型:

- 基于 PaLI 或 PaLM-E 等 VLM
- 将机器人动作表示为文本 token (如 “1 128 91 241 1 0 1”)
- 模型在预训练的互联网知识基础上, 学习输出动作
- 展现出 zero-shot 泛化能力 (如理解 “移到 Taylor Swift 旁边”)

上下文长度的限制

当前 VLA 模型的一个瓶颈是**上下文长度**——仅 6 张图像就接近上下文容量上限, 无法输入完整的操作轨迹。这限制了 few-shot 行为学习和长期规划。

5.2 本章小结

RT-2 证明了互联网规模的视觉-语言预训练可以直接迁移到机器人控制, 实现语义级别的泛化。

6 总结与延伸

Ted Xiao 的演讲展示了基础模型如何从三个层面改变机器人学: (1) RT-1 用 Transformer 做底层控制, (2) SayCan/Inner Monologue 用 LLM 做高层规划, (3) RT-2 将两者统一为端到端的 VLA 模型。机器人学正在经历从 “为每个任务编程” 到 “通过数据和基础模型泛化” 的范式转变。

6.1 拓展阅读

- Brohan et al., “RT-1: Robotics Transformer for Real-World Control at Scale,” RSS 2023
- Ahn et al., “Do As I Can, Not As I Say: Grounding Language in Robotic Affordances (SayCan),” 2022
- Huang et al., “Inner Monologue: Embodied Reasoning through Planning with Language Models,” CoRL 2022
- Brohan et al., “RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control,” 2023