

课程笔记

[CS25] Common Sense Reasoning — Yejin Choi

五道口纳什 & Codex

2026 年 3 月 29 日



视频作者/频道: Stanford CS25

发布日期: 2023

视频时长: 约 55 分钟

视频链接: 未填写

目录

1 引言：常识推理与 ChatGPT 时代	2
2 David vs. Goliath：小模型的逆袭	2
2.1 规模不是万能的	2
2.2 本章小结	2
3 常识知识图谱与神经符号方法	2
3.1 ATOMIC 与 COMET	2
3.2 道德推理	3
3.3 本章小结	3
4 价值多元主义与 AI 安全	3
4.1 谁的价值观?	3
4.2 AI 安全过滤器	3
4.3 本章小结	3
5 总结与延伸	3
5.1 拓展阅读	4

1 引言：常识推理与 ChatGPT 时代

Yejin Choi 教授介绍了**神经符号常识推理** (Neurosymbolic Common Sense Reasoning) 的研究。她首先回应了“ChatGPT 是否已解决 NLP”的疑问，通过一个经典的 Winograd Schema 例子展示：

ChatGPT 的常识脆弱性

“The trophy doesn't fit in the brown suitcase because it's too big.” (it = trophy)

ChatGPT 在标准表述下回答正确，但稍微改变问法就会出错——说明它**没有真正理解物理常识**，而是在做模式匹配。这种“看似聪明实则脆弱”的行为是当前 LLM 的核心局限。

2 David vs. Goliath：小模型的逆袭

2.1 规模不是万能的

规模 vs. 质量

Yejin 认为“更大 = 更好”的叙事过于简单化：

- 大模型在很多任务上表现优异，但在常识推理的**可靠性**上仍有严重问题
- 小模型通过更好的训练策略和数据质量，可以在特定任务上超越大模型
- 关键不在于参数数量，而在于模型**学到了什么样的知识**

2.2 本章小结

在常识推理领域，模型规模不是唯一的解决方案——知识质量和推理机制同样重要。

3 常识知识图谱与神经符号方法

3.1 ATOMIC 与 COMET

构建常识知识

- **ATOMIC**：大规模常识知识图谱，包含日常事件的因果关系、意图、反应等
- **COMET**：在 ATOMIC 上训练的生成式常识模型——给定一个事件，可以推断相关的常识
- 核心思想：将**人类标注的常识**与**神经网络的泛化能力**结合

3.2 道德推理

AI 的道德判断

Yejin 介绍了将常识推理应用于**道德判断**的研究：

- Delphi 系统：基于众包数据训练的道德判断模型
- 能处理自由形式的道德问题（如“杀熊是否道德？”vs.“为救孩子杀熊？”）
- 但仍然是**描述性的**（描述人们认为什么是对的）而非**规范性的**（什么真的是对的）

3.3 本章小结

常识知识图谱和神经符号方法为补充 LLM 的常识短板提供了重要思路。

4 价值多元主义与 AI 安全

4.1 谁的价值观？

AI 伦理的复杂性

在为 AI 注入道德判断时面临的根本问题：

- 不同文化、宗教、个人有**不同的道德标准**
- 不应该将某一种道德框架强加为“正确的”
- 应采取**价值多元主义**——尊重多样化的文化和个人偏好
- 需要 AI、哲学、心理学、政策制定者的**跨学科合作**

4.2 AI 安全过滤器

关于 AI 内容过滤：

- 可以让 AI 过滤器**高度公平和包容**（避免微攻击等）
- 这**不违反**言论自由——只是让 AI 本身不说有害的话
- 但需要更多研究来确定“什么应该被过滤”

4.3 本章小结

AI 的道德推理需要在技术能力和价值多元性之间找到平衡。

5 总结与延伸

Yejin Choi 的演讲揭示了当前 LLM 在常识推理方面的深层局限，并展示了神经符号方法如何补充纯规模化方法的不足。常识推理、道德判断和价值对齐是 AI 发展中不可避免的核心挑战。

5.1 拓展阅读

- Hwang et al., “COMET-ATOMIC 2020: On Symbolic and Neural Commonsense Knowledge Graphs,” AAAI 2021
- Jiang et al., “Delphi: Towards Machine Ethics and Norms,” 2021
- Sap et al., “ATOMIC: An Atlas of Machine Commonsense,” AAAI 2019
- Choi, “The Curious Case of Commonsense Intelligence,” Daedalus, 2022