

课程笔记

[CS25] Common Sense Reasoning — Yejin Choi

基于公开课程资料整理

2023



视频作者/频道: Stanford CS25

发布日期: 2023

视频时长: 约 55 分钟

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1 引言：常识推理与 ChatGPT 时代	2
2 David vs. Goliath：小模型的逆袭	2
2.1 规模不是万能的	2
2.2 本章小结	2
3 常识知识图谱与神经符号方法	2
3.1 ATOMIC 与 COMET	2
3.2 道德推理	3
3.3 本章小结	3
4 价值多元主义与 AI 安全	3
4.1 谁的价值观？	3
4.2 AI 安全过滤器	3
4.3 本章小结	3
5 数据、评测与偏见控制	3
5.1 为什么常识数据总是显得不够	3
5.2 构建更可靠的评测闭环	4
5.3 本章小结	4
6 常识系统的产品落地策略	4
6.1 LLM、知识图谱与工具调用的分工	4
6.2 面向 AI 安全的直接启示	4
6.3 本章小结	4
7 总结与延伸	5
7.1 拓展阅读	5

1 引言：常识推理与 ChatGPT 时代

Yejin Choi 教授介绍了**神经符号常识推理** (Neurosymbolic Common Sense Reasoning) 的研究。她首先回应了“ChatGPT 是否已解决 NLP”的疑问，通过一个经典的 Winograd Schema 例子展示：

ChatGPT 的常识脆弱性

“The trophy doesn't fit in the brown suitcase because it's too big.” (it = trophy)

ChatGPT 在标准表述下回答正确，但稍微改变问法就会出错——说明它**没有真正理解物理常识**，而是在做模式匹配。这种“看似聪明实则脆弱”的行为是当前 LLM 的核心局限。

2 David vs. Goliath：小模型的逆袭

2.1 规模不是万能的

规模 vs. 质量

Yejin 认为“更大 = 更好”的叙事过于简单化：

- 大模型在很多任务上表现优异，但在常识推理的**可靠性**上仍有严重问题
- 小模型通过更好的训练策略和数据质量，可以在特定任务上超越大模型
- 关键不在于参数数量，而在于模型**学到了什么样的知识**

2.2 本章小结

在常识推理领域，模型规模不是唯一的解决方案——知识质量和推理机制同样重要。

3 常识知识图谱与神经符号方法

3.1 ATOMIC 与 COMET

构建常识知识

- **ATOMIC**：大规模常识知识图谱，包含日常事件的因果关系、意图、反应等
- **COMET**：在 ATOMIC 上训练的生成式常识模型——给定一个事件，可以推断相关的常识
- 核心思想：将**人类标注的常识**与**神经网络的泛化能力**结合

3.2 道德推理

AI 的道德判断

Yejin 介绍了将常识推理应用于**道德判断**的研究：

- Delphi 系统：基于众包数据训练的道德判断模型
- 能处理自由形式的道德问题（如“杀熊是否道德？”vs.“为救孩子杀熊？”）
- 但仍然是**描述性的**（描述人们认为什么是对的）而非**规范性的**（什么真的是对的）

3.3 本章小结

常识知识图谱和神经符号方法为补充 LLM 的常识短板提供了重要思路。

4 价值多元主义与 AI 安全

4.1 谁的价值观？

AI 伦理的复杂性

在为 AI 注入道德判断时面临的根本问题：

- 不同文化、宗教、个人有不同的**道德标准**
- 不应该将某一种道德框架强加为“正确的”
- 应采取**价值多元主义**——尊重多样化的文化和个人偏好
- 需要 AI、哲学、心理学、政策制定者的**跨学科合作**

4.2 AI 安全过滤器

关于 AI 内容过滤：

- 可以让 AI 过滤器**高度公平和包容**（避免微攻击等）
- 这**不违反**言论自由——只是让 AI 本身不说有害的话
- 但需要更多研究来确定“什么应该被过滤”

4.3 本章小结

AI 的道德推理需要在技术能力和价值多元性之间找到平衡。

5 数据、评测与偏见控制

5.1 为什么常识数据总是显得不够

常识推理看起来像“每个人都懂一点”，但真正把它写成可训练数据却非常困难。原因在于，常识不是事实库那样的静态知识，而是带有情境依赖、文化背景和默认前提的弱结构信息。同一句话

换一个上下文，合理推断就可能完全不同。

常识评测的三类典型失真

- **语料偏见**：数据集中更常见的群体经验被模型误当作普遍规律。
- **任务过窄**：多项选择题会把开放式常识问题压缩成套路化模式。
- **上下文缺失**：很多推理错误并不是模型“不懂常识”，而是题目没有给出关键前提。

5.2 构建更可靠的评测闭环

如果团队真的要做常识系统，至少要同时准备反事实案例、跨文化标注和开放生成评测。仅靠单一 benchmark 排行榜，很容易得到“会做题但不会判断”的模型。

高分 benchmark 可能掩盖低质量判断

常识和道德任务尤其容易被模板化。模型也许学会了哪类答案在数据集里更常见，却没有形成稳健的因果理解。这种情况下，离线分数和真实世界可用性之间会出现很大断层。

5.3 本章小结

常识研究的核心不是找到一个更大的数据集，而是建立能暴露偏见、情境依赖和推理脆弱性的评测方法。

6 常识系统的产品落地策略

6.1 LLM、知识图谱与工具调用的分工

从工程角度看，最可行的路线往往不是让一个模型独自承担全部常识能力，而是让不同组件分工协作：LLM 负责语言理解与生成，知识图谱负责提供结构化先验，检索或工具负责补充最新事实，人类策略层负责定义边界条件。

一个务实的部署原则

把常识当作系统能力，而不是单模型属性。换句话说，可靠常识来自“模型 + 结构化知识 + 评测治理”的组合，而不是期待某个更大的基础模型自动解决一切。

6.2 面向 AI 安全的直接启示

一旦系统会参与教育、医疗、陪伴或高风险建议，常识缺陷就不再是“偶尔答错一道题”，而会变成真实伤害。因此，常识系统上线前必须明确哪些问题允许开放回答，哪些问题必须触发保守策略或人工升级。

6.3 本章小结

把常识能力产品化的关键，不是追求单点完美，而是通过组件分工与治理设计降低系统性失误。

7 总结与延伸

Yejin Choi 的演讲揭示了当前 LLM 在常识推理方面的深层局限，并展示了神经符号方法如何补充纯规模化方法的不足。常识推理、道德判断和价值对齐是 AI 发展中不可避免的核心挑战。

7.1 拓展阅读

- Hwang et al., “COMET-ATOMIC 2020: On Symbolic and Neural Commonsense Knowledge Graphs,” AAAI 2021
- Jiang et al., “Delphi: Towards Machine Ethics and Norms,” 2021
- Sap et al., “ATOMIC: An Atlas of Machine Commonsense,” AAAI 2019
- Choi, “The Curious Case of Commonsense Intelligence,” Daedalus, 2022