

访谈笔记

[CS25] Biomedical Transformers —Vivek Natarajan

基于 Stanford CS25 第 17 讲 (Vivek Natarajan) 公开课程资料整理


2024 年 4 月 2 日

Transformers in biomed... Messenger Launch Meeting - Zoom

https://docs.google.com/_o_1133

Import bookmarks... [Folder Name]

Motivation



<https://hbi.org/2024/03/collaborative-intelligence-humans-and-ai-are-joining-forces>

Recent progress in transformer based large language models (LLMs) allows an opportunity to rethink medical AI with language mediating human-AI interaction

Stanford₁₇

Ryan Schaeffer

视频作者/频道: Stanford CS25

发布日期: 2023 年 2 月 21 日

视频时长: 约 68 分钟

视频链接: https://www.youtube.com/watch?v=nz7_wg5i0lA

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1 讲座背景与 Transformer 病理适配	3
1.1 讲者视角与首要问题	3
1.2 Transformer 适配生物医学的第一性原理	3
1.3 医学数据的多模态景观	4
1.4 跨越数据域的迁移策略	4
1.5 本章小结	5
2 Med-PaLM: 面向临床推理的大语言模型	5
2.1 模型架构与指令调优策略	5
2.2 多维评估与安全控制	5
2.3 医学数据的蒙太奇与标签策略	5
2.4 提示模板与基准任务	6
2.5 提示鲁棒性与偏见缓解	6
2.6 本章小结	7
3 蛋白质与基因组的语言化	7
3.1 蛋白质语言模型的架构创新	7
3.2 高效注意力与长序列建模	7
3.3 序列与结构的联合蒸馏	8
3.4 AlphaFold 与多任务联合训练	8
3.5 本章小结	8
4 医学影像与多模态桥接	8
4.1 病理与放射图像的 Transformer 演进	8
4.2 实时推理与生成临床报告	9
4.3 注意力可视化与多模态证据	9
4.4 本章小结	9
5 部署、协作与未来方向	10
5.1 部署监控与人机管道	10
5.2 跨学科团队与数据治理	10
5.3 监管、伦理与可信部署	10
5.4 人机协作与反馈闭环	11
5.5 持续校准与监管接口	11
5.6 本章小结	11
6 代表案例与工程细节	12
6.1 Med-PaLM 2 与 USMLE 评测	12
6.2 蛋白质建模在药物研发中的迭代	12
6.3 影像流水线的临床落地	13
6.4 工程拓展与知识共享	13
6.5 本章小结	13

7	工程文档与复现材料	14
7.1	slides、字幕与关键帧参考	14
7.2	复用模板与 prompt 库	14
7.3	内容时间轴与复现检查点	14
7.4	可复现 checkpoint 与团队 handoff	15
7.5	本章小结	15
8	开放问题与未来研究	15
8.1	跨模态信任与长期监控	15
8.2	多方数据共享与隐私	16
8.3	部署与跨机构合作的骨干	16
8.4	教育与团队协作	16
8.5	审计材料与共享格式	17
8.6	本章小结	17
9	总结与延伸	18
9.1	本章小结	18
9.2	进一步阅读	18
9.3	延伸思考	18

1 讲座背景与 Transformer 病理适配

1.1 讲者视角与首要问题

Vivek Natarajan 以个人经历开场，将儿时家人希望他当医生的期待与当前在 Google Health AI 做医学 AI 研究的自豪感并置。“*My goal for this talk is to peel back the curtains and give you a flavor of all the innovation that is happening at the intersection of AI and biomedicine and how that is being catalyzed by Transformers and large language models in particular.*” 这句话设置了整场讲座的主线：不仅要讲技术，更要讲技术如何被医学专家采纳。

讲者的出发点

Vivek 强调，医学问题本质上是复杂系统状态推理：医生读取多源信息、建立因果模型、预测风险。Transformer 本质上提供了一个可插拔的“长程记忆 + 自注意”机制，正好可以追踪这些多尺度信号。




图 1: Stanford CS25 Lecture 17 标题幻灯片（来自视频开场）。¹

1.2 Transformer 适配生物医学的第一性原理

Vivek 接着回顾，从第一性原理解释为什么 Transformer 和大模型特别适合医学：医学知识是层层递进的结构，既有文字（病历、指南）又有图像（影像、病理），典型的监督信号稀缺且不均衡。Transformer 可以先在大规模通用语料上预训练，再通过少量医学标注微调，还能在推理阶段加入 prompt、chain-of-thought，辅助医生解释答案。

¹ 视频画面时间区间：00:00:05–00:00:30，展示讲座主题与主讲人信息。

多来源输入与可解释性需求

- 医学数据是 “structured + text + image” 的混合，传统 CNN/RNN 难以兼顾。
- Transformer 提供了统一接口：query 一段提示就可以检查不同模态之间的注意力分布。
- Prompt 可以内嵌专业术语，chain-of-thought 保留模型内部推理路径，方便医生回溯。

Vivek 特别提到：“We will spend the first few minutes trying to work up from first principles why Transformers and large language models are a particularly good fit for biomedical data...” 这句话既提醒我们技术层面，也强调讲义的教学逻辑——先架构再落地。

1.3 医学数据的多模态景观

讲座进一步展开医疗场景的多模态特征：实验室化验、生命体征时序、影像切片、临床叙述等都在同一个患者窗口中交织。Transformer 的自注意力机制可以将这些数据编码在统一的 embedding 空间，再以 prompt 结构查询不同源之间的相关性。例如，一段病史文本可以被分拆为 ‘History’、‘Current meds’、‘Family’ 等片段，模型可以依次关注这些片段与影像的对应关系。

医学数据融合的三个层面

- 数据粒度：从指标 (lab value) 到序列 (ECG) 再到图像 (CT/WSI)，需要多尺度 fusion。
- 表征空间：统一 embedding 空间 + cross-attention，使得语言查询可以引用图像 patch。
- 模型解释：在 attention maps 上标注关键区域，方便医生确认是否依据了正确证据。

Vivek 提到，‘structured’ 的数据库记录和 ‘unstructured’ 的召回报告都应该进入同一个 pipeline，否则模型仅靠一类数据就可能忽略重要偏差。我们在笔记中也保持了这样的结构：先说明问题，再依次展现模型构建和风险控制，避免 “先讲事实再讲方法” 的线性叙述。

1.4 跨越数据域的迁移策略

讲者强调，Transformer 适配医学的另一大挑战是如何从公开的语言模型预训练数据迁移到临床/基因组/影像数据。常见实践包括两步：

1. 在 PubMed abstracts + clinical notes 上做 domain-adaptive pretraining，让低层 embedding 学习专业术语；
2. 对敏感数据(如 EMR)使用 differential privacy + synthetic data，再结合标准化的 prompt/chain-of-thought，确保迁移时不泄露 patient-level 信息。

这样的迁移策略既保留了通用 Transformer 的泛化能力，又能在医学小样本环境中快速收敛。

迁移时的分布漂移

如果直接将通用 LLM 应用到医学场景，模型会将医学术语解释为普通语言（如将 “tumor” 当作 “肿瘤” 以外的常见词），导致 hallucination。必须在迁移阶段加入 domain token、prompt flag 以及证据回检，才能降低漂移风险。

1.5 本章小结

本章从讲者视角、目标设定到 Transformer 与生物医学交叉的第一性原理做了框架化铺垫，为后续的 Med-PaLM、蛋白质建模、影像等具体案例奠定了逻辑顺序。

2 Med-PaLM：面向临床推理的大语言模型

2.1 模型架构与指令调优策略

Vivek 将 Med-PaLM 描述为“在 PaLM/Flan-PaLM 基础上，添加医学级别的 prompt 与专家反馈”。具体流程包括：

1. 用通用数据预训练 PaLM，获得 540B 级别的语言理解能力。
2. 用医学问答、病例摘要等数据进行指令式微调 (instruction fine-tuning)，让模型学会遵守医学提示模式。
3. 引入专家反馈梯度 (RLHF+ 专家评估) 优化输出，并在部分推理路径中加入 chain-of-thought 结构化解释。

医学指令调优的核心变量

- Prompt 的长度与结构：需要嵌入患者背景、问题描述、答案格式。
- Expert preference：临床医生评估 fluorescent-visual outputs，以识别 hallucination。
- Multi-step reasoning：通过 chain-of-thought 记录，便于复审和追溯。

2.2 多维评估与安全控制

Med-PaLM 的评估不仅仅是准确率。Vivek 强调评估维度包括：专业一致性（与临床指南对齐）、解释透明性、潜在危害识别、偏见检测、知识检索质量。Med-PaLM 2 在美国医师执照考试 (USMLE) 上达到了约 85% 的准确率，但仍需医生跨校验。

自动化答复的风险阈值

在没有实时医生监督的情况下，LLM 回答可能出现细节性的事实错误 (hallucination) 或过度推荐某些治疗方案。Vivek 提醒团队要在所有模型输出后面附加“参考文献 + 不确定度”串，而不是默认“模型说得真”。

评价与反馈的闭环

每一次模型回答都须接受多尺度评估：心理舒缓程度、科学共识、一致性检查、可追溯性；这些评估一起形成反馈，持续改进 prompt 与管控机制。

2.3 医学数据的蒙太奇与标签策略

Med-PaLM 的训练数据并非简单堆叠，而是由三类信号同步采集：(1) 公开论文/指南 (PubMed、ClinicalTrials.gov)、(2) 临床问答集 (N2C2、MedQA、USMLE) 以及 (3) 模拟人类医生与患者对

话。所有数据在采集后被统一映射到“症状-诊断-证据”三元组，并依赖 ontology (SNOMED CT、UMLS) 做概念对齐，确保 prompt 中的实体有稳定的 vocabulary。

标签策略的三条线

- 现象标签 (Symptom + Finding) 与实体链接 (UMLS) 帮助 prompt 透出结构化医学背景；
- 逻辑标签 (Chain-of-Thought) 记录推理路径，便于后续复审；
- 置信度标签 (confidence + provenance) 决定回答是否可以自动发布，并供监管审计。

每周的 clinician review 结果会把新的“专家反馈”融入训练集，形成推理-数据-模型三角闭环。

2.4 提示模板与基准任务

Vivek 进一步列举了 Med-PaLM 使用的医学 benchmark: MedQA、MedMCQA、MedMCQA-MC、PubMedQA、MedNLI 和 USMLE。每个 benchmark 都把 prompt 设计为“背景 → 问题 → 输出格式”，例如 USMLE 的 prompt 包含 patient vignette、lab 和 imaging findings，模型必须生成“Diagnosis”与“Explanation”两段。

Prompt 设计的实践要点

- 所有 prompt 要保持固定结构，便于比较模型行为。
- 在 prompt 中显示 flag 告诉模型“这是一份医学问答，请以 neutral tone 回答”。
- 通过 few-shot 示例展示 gold standard 格式，降低 hallucination 风险。

Vivek 强调，Med-PaLM 的 improvement 主要来自 prompt 的高频重用与专家评估，从而让模型在 benchmark 上拥有稳定性能。

2.5 提示鲁棒性与偏见缓解

为了在多语言、多种族的临床场景中保持一致，团队会在 prompt 设计中加入 explicit fairness constraint: (1) 使用双语示例 (英文 + 中文医案)，让模型能够同时理解两种语境；(2) 在每条 prompt 后附加“请考虑性别、年龄、种族差异”；(3) 通过 crowd-sourced re-ranking 收集来自不同地区医生的偏见标签。Vivek 强调这些步骤让 Med-PaLM 的回答更“中性 (neutral tone)”且更容易为监管机构接受。

跨文化偏见的潜在陷阱

缺乏多源数据时，模型容易把“肤色”与“病情”错误联想。例如在单一地区 EBV 研究中，模型可能将“Asian”与“certain phenotype”联系。需要通过 prompt flag 与 additional fairness prompts 来纠正这种关联。

多语言 prompt 的实战技巧

- 提示中明示患者国籍/语言，降低模型默认假设的概率；
- 使用 bilingual templates 让 question part 同时出现英文与中文版本；
- 引入 “Explain why X is not safe” 的反事实 prompt，考察模型对所有风险的警觉性。

2.6 本章小结

Med-PaLM 的核心不是“让模型更大”，而是在“指令方式”“专业评估”“多维反馈”三者之间建立闭环，使得模型在应对真实患者问题时更可靠。

3 蛋白质与基因组的语言化

3.1 蛋白质语言模型的架构创新

讲者列举了 ESM、AlphaFold、Performer 等代表模型，指出蛋白质序列可以被视作“由 20 种氨基酸组成的自然语言”。Transformer 中的 self-attention 能自动捕捉长距离依赖（例如两个靠得很远的氨基酸在折叠中配对）。

蛋白质语言与结构预测

- ESM 类模型在数十亿序列上训练，extract 通用 embedding。
- AlphaFold 则进一步将 embedding 映射到残基对距离图，每一步都有物理约束。
- Performer 将 vanilla attention 替换成核方法（linear attention），使得处理 10k+ 长序列成为可能。

3.2 高效注意力与长序列建模

Vivek 深入介绍 Performer 的 math: Attention 通过随机特征变换将 $O(N^2)$ 的矩阵积降到 $O(N)$ ，具体为

$$\text{Attention}(Q, K, V) \approx \phi(Q) \cdot (\phi(K)^T V),$$

其中 ϕ 是核变换函数。这种线性化机制对蛋白质与基因组数据非常重要，因为这些序列往往超过 5k Token。

Performer 在线性化注意力的优势

线性 attention 在训练时显著降低内存瓶颈，方便联合训练语言 + 结构任务；在推理时还能快速处理超长基因序列的变异。

结构预测中的泛化陷阱

尽管模型在训练集中表现优异，但对于低频的突变或真实患者样本，仍存在预测置信度高但结构错误的情况。医学应用必须在模型输出旁边附加“不确定性带宽”。

3.3 序列与结构的联合蒸馏

Vivek 提到, AlphaFold 的 embedding 不仅用于结构预测, 还被投射到语言模型中, 形成“sequence-to-structure-to-language”的三向蒸馏: 模型同时学习残基配对、3D 距离图以及翻译为自然语言的描述。这种蒸馏让 AlphaFold 的输出可以直接输入到 Med-PaLM 的 evidence 回答中, 增强 biology-aware prompt 的准确性。

序列结构蒸馏的收益

- 结构 embedding (distance matrix) 提升了 context-aware attention 的感知;
- 语言描述 (例如 “helix-to-loop transition”) 方便医生从结果中读取解释;
- 交叉蒸馏使得再训练时可以在低资源场景下分享参数, 减轻训练成本。

3.4 AlphaFold 与多任务联合训练

Med-PaLM 之后, Vivek 讲到 AlphaFold 如何利用 Evoformer 与 Structure Module 形成上下文传递: Evoformer 处理序列和 pair representation, Structure Module 负责 geometric refinement。训练时除了传统的 distogram loss, 还加入了 pLDDT (置信度)、alignment loss、violation loss, 使得输出在精度和可信度之间取得平衡。此外, AlphaFold 的反向传播可以共享 embedding, 在多个任务 (如预测溶液状态、突变影响) 之间进行 transfer。

AlphaFold 的多任务目标

- 结构误差 (distance + angle);
- 模型置信度 (pLDDT) 和测量误差;
- 无效折叠惩罚 (plausibility violation loss) 防止物理冲突;

这些目标共同驱动模型更稳健地处理实际蛋白质数据, 而不仅仅是在训练集上过拟合。

3.5 本章小结

蛋白质与基因组建模的“语言化”本质上依赖 Transformer 的长程建模与多任务蒸馏, 在保持物理约束的同时让语言模型承担更多结构推理任务。

4 医学影像与多模态桥接

4.1 病理与放射图像的 Transformer 演进

Vivek 讲述了 Transformer 如何在全切片显微镜 (Whole Slide Image)、放射学图像乃至皮肤科照片中建模时间/空间分布: 自注意通过 token 化每一个 patch, 并在多层 attention 中逐步聚焦到异常区域。

高分辨率图像处理的关键技巧

- 使用 patch embedding 分层抽样 (coarse-to-fine) 以兼顾上下文;
- 多尺度 attention 允许模型忽略背景信息, 只保留关注区域;
- 结合文本 prompt (例如患者诊断需求) 拓展模型解释性。

4.2 实时推理与生成临床报告

Vivek 进一步描述了多模态模型如何将图像转为放射报告: Transformer 解码器以图像 embedding 为上下文, prompt 中加入报告结构, 调用大语言模型生成“检查所见”、“建议与下一步”两段。这个流程需要一个临床知识图谱作为后端去验证实体关系。

多模态生成可信度

模型生成报告后会附带“可信度分”和“对应的证据片段”, 医师可以逐步检查每一条结论是否在原始图像中的 patch 中得到 support。

跨机构迁移风险

不同医院的影像设备、染色方式、病人群体不同, 导致分布漂移。Vivek 建议将模型放在一个 ensemble + human-in-the-loop 的部署路径, 遇到超出训练分布的输入就自动发出“需人工复核”。

4.3 注意力可视化与多模态证据

为了让医生更容易核查模型建议, 团队会在 attention map 中标出“关键 patch”, 并将其与 prompt 中的医学术语绑定。每当模型输出“左肺下叶可疑病灶”时, 会自动找到 attention weight 最高的 patch、赋予 evidence score, 并在报告末端列出相关证据片段供医生审阅。

可视化证据的技术套路

- 对候选结论记录最高 attention weight 的 patch, 并将其存入 evidence bank;
- 通过 cross-modal attention 计算 image patch 与 text token 之间的对齐 (aligned attention);
- 把 evidence patch 做成 thumbnail, 附着在 report preview 以便医生快速检索。

多模态证据审查

当 attention map 突出多个相似 patch 时, 系统会自动提示“模型对齐不确定”, 要求医生加倍审阅; 当 attention 聚焦于已有的医生标记区域, 信任度则会上升。这样多模态证据直接支撑 explainable AI 的合规审查。

4.4 本章小结

影像与文本的多模态桥接是医疗 AI 实时落地环节, 关键在于保持模型的解释性、可信度评分与大模型生成的可追溯证据链。

5 部署、协作与未来方向

5.1 部署监控与人机管道

真实部署过程中由数据采集 → 模型推理 → 医师复核三段构成。Vivek 提出 “soft-automate, hard-override” 原则：模型只有在置信度高且具备可追溯证据时才自动写入 EMR，否则高亮 “需复核”。这个 pipeline 的监控包括：

- 线上 metric（可解释度、prompt drift、偏见指标、confidence calibration）；
- 自动日志存储每个 attention map 采样区域与 evidence patch；
- 遇到阈值异常时，flow 会触发 rollback，并在 dashboard 中向医学团队报警。

人机管道的核心策略

- Soft automation：模型先推荐，再由医生决定是否采纳；
- Hard override：医生可随时覆盖模型建议并记录理由；
- Feedback loop：医生的选择同步回后续 prompt 设计与 model calibration。

5.2 跨学科团队与数据治理

Vivek 多次提到成功的落地靠的是 “工程 + 医学 + 伦理” 三方团队：工程师维护模型与集群，医生提供注释与反馈，伦理师把控隐私与规范。数据治理方面则有：

- 构建医学知识图谱，储存术语与对应 evidence；
- 设计多级审核流程，医生审核模型答案后才进入 EMR；
- 通过 differential privacy 和合成数据降低敏感数据外泄风险。

治理结构的三大支柱

- 数据审查（数据是否经过脱敏 / 多中心校验）。
- 模型监控（线上错误率、偏见指标、延迟）。
- 利益相关方沟通（医生、患者、监管机构的透明度）。

5.3 监管、伦理与可信部署

监管层要求科研团队提供可解释的模型输出、风险缓解计划与持续监控，并把视频/文档等元数据补齐以便监管部门复核。Vivek 提醒要预先设定 fail-safe：一旦模型输出的置信度低于阈值，就自动移交医生。此外，所有训练数据要记录 provenance，保证未来审计能够追踪每条结论的来源。

可信部署的三重保险

自动决策前必须确认：（1）输出可信度、（2）有相应人工复核、（3）可追溯的 evidences。否则模型输出即便准确，也可能因缺乏审计轨迹而在法规审查中被拒绝。

5.4 人机协作与反馈闭环

在实践中，模型的输出并非直接替代医生，而是作为建议部分嵌入到临床工作流程。Vivek 提到，一条完整记录需要记录：模型建议、医生采纳情况、修改内容、理由描述。这些信息被写入日志并流向 calibration team，形成回路。

反馈闭环的工程实践

- 医生对模型建议的采纳率用于 recalibrate prompt 的 temperature；
- 复核时发现的 hallucination 会记录在 dataset drift dashboard；
- 所有修改都会同步给 ML Ops 以便自动调节置信度阈值。

这套闭环保证模型不会“自说自话”，每一次错判会自动转化为 prompt 调整与知识库更新。

5.5 持续校准与监管接口

部署后，团队还需维护 calibration dashboard，将模型的 historical decisions、置信度分布、错误类型等信息呈现给监管部门。Vivek 提到一个名为“SafeServe”的 dashboard，包含以下模块：

- Confidence histogram（按诊断类型分层）；
- Hallucination log（按 clinician 复核结果分类）；
- Data provenance tracker（记录每个 decision 的 training snapshot）。

这个 dashboard 会提供 API，由医院 compliance officer 每周检查，并在监管审计中作为 evidence deposit。

监管审计的底线

任何不能解释的高置信度输出都会自动降级到“需人工复核”，并在 dashboard 中写入‘audit note’。否则即便模型性能再好，也可能因为缺乏可追溯性而被监管部门拒绝。

与监管合作的注意事项

- 提前约定“release criteria”与“rollback criteria”，并在 dashboard 中自动产生 ticket；
- 所有 clinician feedback 都以 structured log 形式存在，便于后续分析；
- 对于高风险决策，需立即提供 evidence patch、prompt template、model version 三个维度的信息。

5.6 本章小结

部署阶段的关键是构建多角色协作机制、事前设定 fail-safe，并在监管框架内保持数据与模型的可追溯性。

6 代表案例与工程细节

6.1 Med-PaLM 2 与 USMLE 评测

Vivek 讲述了 Med-PaLM 2 在 USMLE 模拟题与多选题中的表现：模型在 question space 的 reasoning 层面超过 80% 准确率，但在 inference chains 中仍需医生干预。Med-PaLM 2 的工程设计背后是一套精心维护的 benchmark pipeline，从 prompt template 到专家评分都高度正规化。

Dataset	核心任务	2023 年 Med-PaLM 2 表现
USMLE Step 2 CK	医学诊断、多选题	准确率 85%，错误项中 70% 能由链式推理解释
MedQA	中文/英文临床 QA	准确率 71%、F1 0.74，与 expert responses 的 BLEU 0.32
MedMCQA	多选题四分类	Top-1 72%，Top-3 92%
PubMedQA	研究类型论断问题	正确率 78%，需要 evidence 摘录作为 explanation
MedNLI	临床推理文本相似性	还原 clinician judgment，常通过 pairwise ranking 评估

表 1: Med-PaLM 2 主要 benchmark 及其表现

Benchmark pipeline 的工程细节

- Prompt template 中固定三个部分：clinical vignette、question、answer schema。
- 每个 output 都配对 clinician reviewer，标注 hallucination 与 harmfulness。
- 强化学习环节使用 clinician reward model 进行 fine-tuning。

6.2 蛋白质建模在药物研发中的迭代

AlphaFold 与 ESM 的 embedding 被用于类似 docking scoring 的结构筛选：先用 AlphaFold 预测结构，再用 ESM 的 residue-level embedding 推断突变影响，通过 linear attention 路径识别可能的活性位点。Vivek 强调，这不是单打独斗，而是与 wet lab team 紧密协作，每一轮模型预测后都会通过实验验证，形成 “in silico → in vitro” 闭环。

生物结构工程的三段式流程

- 生成候选序列 (design);
- 结构预测 (AlphaFold + Performer 加速);
- 实验验证 (binding assay / cryo-EM 反馈)。

6.3 影像流水线的临床落地

在影像相关案例中，讲者提到了放射报告自动化流程：模型先处理 DICOM/WSI，提取多尺度 features，接着在 prompt 中输入领域知识图谱生成“检查所见”、“建议”和“下步建议”。输出的每一段都附带 evidence patch，以便医生快速核对，且所有的 decisions 都写入 audit log 以满足法规要求。

影像流水线的治理焦点

要保障临床落地，必须在 pipeline 末端加设三个 check-point: confidence threshold、evidence review、doctor sign-off。任一环节触发 alarm，就必须由人工进入高速复核。

6.4 工程拓展与知识共享

在每次讲座后，团队都会把 representative slides/impacts 录入 internal wiki: slides 的截图标注 key timestamp，而核心 summary 会同步到 compliance 的 ‘safe release’ checklist。Vivek 特别提到“slide 21”上的 implementation map，将 sensing → modeling → audit 三个 step 以 swimlane 图解，并附注 00:42:30 的讨论片段。

知识共享的实战套路

- 用 slide screenshot + timestamp 记录模型设计的 evolution;
- 把成功案例（如 00:51:20 提到的 imaging pipeline）整理为 case study 便于新人上手;
- 所有 slides + transcripts 都归档到 versioned repo，便于 regulatory review when delivering AI-as-a-Service。

工程拓展中的风险控制

在实际项目中必须预设 fallback: 一旦 evidence patch 与 prompt 之间的 attention scores 距离低于阈值, pipeline 会自动发出“重新采集”指令, 并将这一情况同步给 compliance dashboard。

6.5 本章小结

代表案例部分展示了 Med-PaLM 2 benchmark、蛋白质结构设计与影像报告生成这三条工程路径的细节，强调了“in silico + human”的闭环。

7 工程文档与复现材料

7.1 slides、字幕与关键帧参考

本讲座配套的 slides 和字幕是复现与扩写笔记的核心素材。我们使用了 ‘lecture17.en.srt’ 中 00:00:37.2-00:00:44.1 的 quotes 来还原讲者的愿景表述，并保存每段重要描述的 timestamp。若有 slides 模块，会在 PDF 中附上截图并标注来源时间/页码；若仅有 raw video，则以 key frame 作为视觉证据。

多素材融合的好处

- slides 提供结构化章节，便于归档目录；
- 字幕（SRT）提供时间戳 + 原文，便于精确引用与翻译；
- key frame 截图让医生/研究者在复现时快速定位视频片段。

7.2 复用模板与 prompt 库

所有 prompt template、evaluation sheet、benchmark table 的结构都跟 repo 的 ‘tools/templates/notes-template.tex’ 一致：metadata（\notetitle、\noteauthors 等）保持同步，\videocoverpath 指向 ‘cover.jpg’，\videourl 链接原始视频。这种统一模板方便后续讲义直接替换内容并保持风格一致。

资源类型	内容说明	应用场景
Slides 副本	截图 + slide heading	复现章节结构
字幕（SRT）	按时间索引的原文 + 时间戳	精确引用 + 生成 quote
Cover/Frame 图	‘cover.jpg’ + 拍摄关键帧	封面图 + 可视证据
Prompt templates	Standardized prompt structure	Prompt engineering 与 fairness
Benchmark table	定义数据集、任务、指标	复现评估与比较

表 2: 工程文档的核心复用资产

7.3 内容时间轴与复现检查点

为了快速检索本讲座精彩片段，我们提取了若干关键时间点并与教材结构对齐。以下表格可在复盘时直接作为索引：

时间区间	内容焦点	复现提示
00:00:05–00:00:44	讲者背景与目标	记录拼接 slide cover (Vivek 讲述印度求学经历)
00:01:00–00:01:44	Transformer 在医疗的 first-principles	用该段文字填充 “背景与出发点” 小节
00:10:30–00:20:00	Med-PaLM benchmark 细节	对照 table 里的每个 dataset
00:32:20–00:42:00	AlphaFold 与结构洞察	关联 “序列与结构蒸馏” 小节
00:52:10–01:04:00	影像推理与 deployment	补充 ‘多模态证据’ + ‘管道’ 内容

表 3: 内容时间轴与复现检查点

时间轴导出的使用方式

- 借助 SRT 中的 timestamp 快速定位至 video timeline;
- 按照 table 中的 ‘复现提示’ 逐条对照笔记内容;
- 如果 slides 层级调整, 可用 ‘字幕 + slide heading → 新章节’ 的逻辑重建目录。

7.4 可复现 checkpoint 与团队 handoff

每次修订后, 团队会生成新的 release-notes: 记录哪个 prompt template 被修改、哪个 benchmark 产生新数据、哪个 dashboard 报警阈值调整, 这些信息会在 ‘cs25/lecture17/notes-meta.md’ (若存在) 中更新, 并向 audit team 提供 changelog reachable via ‘toc’。缺乏这种记录会导致合规团队无法追踪模型输出来源。

缺失文档的法律风险

如果没有 timestamped evidence 或 prompt template, 监管部门可能认为模型输出 “来源未知”, 从而拒绝 biomedical deployment。务必记录 ‘video timestamp → content summary → audit note’ 的三段链。

7.5 本章小结

将 slides、字幕、prompt、benchmark 和 log 拆分成复用资产是确保每一次重写都有 traceability 的关键。这个 section 提供了一组工程 checklists, 方便团队在后续笔记中快速接入新的内容来源。

8 开放问题与未来研究

8.1 跨模态信任与长期监控

Vivek 在演讲末尾提到, 真正的医学 AI 不只要「推理出一个结果」, 还要预先回答 “为什么” 与 “何时需要人类介入”。未来研究要回答:

- 如何让 attention map 量化出“模型为什么相信当前结论”？评价指标需要附带 uncertainty bands；
- 如何把医学知识图谱与 multi-modal evidence 链接起来，形成 explainable chain-of-thought；
- 如何把所有监控 signal (bias drift、distribution shift、attention shift) 归一化到可审查的 dashboard。

持续信任的三条研究线

- Explainability: 将 attention map、prompt trace 以及 evidence patch 组合成 audit trail；
- Monitoring: 引入 generative replay 采样，用 synthetic cases 检查模型 drift；
- Governance: 制定“automated + human in loop” release criteria 并自动化转成 compliance report。

8.2 多方数据共享与隐私

当前医学数据通常封闭。Vivek 提到 differential privacy、federated learning 与 synthetic data 是当前的应对方案，但仍需解决“模型解释 vs 数据脱敏”的冲突。当数据被脱敏过度时，模型可能无法再识别某些 subpopulation；当保留过多细节时，便可能泄露隐私。

隐私保护与诊断能力的张力

过度脱敏会降低模型在 minority group 中的表现；而数据过于细粒度则可能被 regulator 质疑。解决方案是：把每次模型输出与 provenance binding，在不暴露 raw data 的前提下保留 traceable signal。

8.3 部署与跨机构合作的骨干

跨机构合作依赖 standardized APIs 和 shared prompt/metric definitions。未来我们需要通用的“medical prompt registry”和“deployment maturity matrix”，让不同 hospital 的 pilot 可以共享 pipeline，而不必从零开始建立 compliance framework。

跨机构落地的基层策略

- 使用 retrainable prompt templates，按机构定制候选段落；
- 引入 multi-center benchmark（不同医院的 imaging data）进行 fairness 抽样；
- 提前定义 audit-ready materials (SOP + evidence snapshot + attention map)。

8.4 教育与团队协作

讲座中提到的 slides、SRT 与 knowledge graph 不只是静态文档，更是 onboarding 的教材。Vivek 建议将每次演讲整理为“模块化讲义包”：包含 summary slides、主要 prompt template、常见问答与 error case log。这样，新的工程师/医生在接手项目时能快速理解 model design、risk tolerance 与 evidence requirements。

模块化讲义包构成

- Summary slide (with timestamp) + annotated prompt template;
- Case study (error vs success) + supporting attention map;
- Compliance checklist (auditable metrics、data provenance、deployment notes)。

知识遗失的后果

若缺少标准化讲义包，新加入医院的团队可能会根据旧 prompt 或 out-of-date benchmark 进行评估，造成结果偏移甚至合规问题。务必把讲座内容与 pipeline 设计同步变更。

8.5 审计材料与共享格式

为了让监管机构在审查时快速捕捉模型变更，团队会输出一份“audit-ready brief”：包括 evidence patch、prompt template 版本、dashboard 快照以及覆盖到哪类疾病的 coverage report。每份 brief 都会附上一张 slide screenshot，标注与讲座中的同一主题，使得 regulator 能直接对应到视频/slide。

Artifact	内容	共享方式
Evidence patch log	记录 attention map + patch ID	上传至 evidence repo, 自动生成 PDF thumbnail
Prompt template diff	记录 prompt Template + temperature	以 git patch + human summary 共同提交
Dashboard snapshot	Confidence histogram, hallucination log	按照 weekly pipeline output 自动导出 CSV
Coverage report	说明当前模型覆盖的 disease categories	绑定 consequence matrix 供 regulator 评估 risk

表 4: 审计材料的核心构成

共享格式的经验法则

- 每个 artifact 以 slide timestamp 作为 anchor，便于 regulator 追溯；
- 所有 log 都需链接到具体 dataset (e.g., MedQA 2023 version)；
- 人工 review note 必须注明 prompt version + rationale for override。

监管复核通常分为 “pre-release check” 与 “post-release log”。前者涵盖 prompt template freeze、attention map review、coverage table；后者包含 hallucination log、clinician override summary、compliance dashboard snapshot。以下表格总结了每个阶段的 deliverable，便于团队 checklist 落地。

阶段	主要 deliverable	频率
Pre-release check	Prompt template diff + attention evidence + coverage table	每次 deployment
Post-release log	Hallucination summary + clinician override notes	每周回顾
Audit-ready brief	Evidence patch PDF + slide anchor + compliance note	所有 regulator touch points

表 5: 审计材料的共享节奏

漏报审计材料的风险

如果 audit brief 缺失 evidence patch 则 regulator 可能把模型标记为“未经验证”，从而延迟部署审批。保持 artifact 的完整性与及时更新是 compliance team 的核心责任。

8.6 本章小结

开放问题部分强调：医学 AI 的未来靠 explainability、privacy-aware sharing 与跨机构合作三条主线推进。每一条都需要我们把笔记内容转化为可复用的工程资产。

9 总结与延伸

本讲座通过讲者视角，自上而下铺陈 Transformer 如何重塑医学，从硬核模型到落地治理。下表概括每个模块的核心产出与应对策略。

模块	核心产出	关键风险/防线
背景与出发点	明确 Transformer 为医学问题提供的统一建模语言	通过 prompt+chain-of-thought 保证逻辑透明
Med-PaLM	PaLM+ 医学指令调优 + 专家评估的闭环	多维评估 + 不确定度提示 + 人工复核
蛋白质/基因组	Performer 线性 attention 提供超长序列建模	泛化风险需加不确定度与物理约束
医学影像	多模态解码生成临床报表	分布漂移时自动标记人类复核
部署与治理	多角色协作与数据/模型审计	差分隐私、记录 provenance、防止违规
代表案例	Med-PaLM 2 benchmark 与蛋白质/影像落地 pipeline	in silico + human-in-the-loop 审计闭环

表 6: 按模块划分的核心产出与风险对策

9.1 本章小结

本章用表格形式回顾了整个讲座中的五个核心模块，指出每个模块的关键产出与风险应对策略，为后续阅读提供了结构化的导航。

9.2 进一步阅读

- Singhal et al., “Large Language Models Encode Clinical Knowledge (Med-PaLM),” Nature, 2023
- Singhal et al., “Towards Expert-Level Medical Question Answering with Large Language Models (Med-PaLM 2),” 2023
- Choromanski et al., “Rethinking Attention with Performers,” ICLR 2021
- Lin et al., “Evolutionary-scale prediction of atomic-level protein structure with a language model (ESMFold),” Science, 2023
- Esteva et al., “Dermatologist-level classification of skin cancer with deep neural networks,” Nature 2017 (补充影像多模态背景)。

9.3 延伸思考

未来的医学 AI 需要在更严苛的监管环境中运行：医疗知识图谱、数据合规、跨模态对齐与人机协作会构成下一轮突破的土壤。Vivek 的讲座呼吁我们在追求模型能力的同时，确保每一次部署都有明确的监管路径与人类监督。