


课程笔记

[CS25] Neuroscience-Inspired AI — Trenton Bricken, Anthropic

基于公开课程资料整理

2023



视频作者/频道: Stanford CS25

发布日期: 2023

视频时长: 约 70 分钟

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1	引言：注意力近似稀疏分布式记忆	2
2	稀疏分布式记忆 (SDM)	2
2.1	基本原理	2
2.2	高维空间的几何直觉	2
2.3	本章小结	2
3	从 SDM 到 Transformer 注意力	3
3.1	数学对应关系	3
3.2	两种记忆视角	3
3.3	本章小结	3
4	神经科学联系：认知地图	3
4.1	海马体与网格细胞	3
4.2	从空间到语义	4
4.3	本章小结	4
5	总结与延伸	4
5.1	拓展阅读	4

1 引言：注意力近似稀疏分布式记忆

Trenton Bricken 来自 Anthropic，介绍了他的研究工作“Attention Approximates Sparse Distributed Memory”。这项工作建立了 Transformer 中的注意力机制与神经科学中**稀疏分布式记忆** (Sparse Distributed Memory, SDM) 之间的深层联系。

核心贡献

- 证明 Transformer 中的 softmax 注意力可以用高维向量的**超球面交集**来近似
- SDM 早在 1988 年就被提出，可以被视为注意力的“先驱”——超前了约 30 年
- 这一联系为注意力机制提供了**生物学合理性**的理论基础

2 稀疏分布式记忆 (SDM)

2.1 基本原理

SDM 的工作原理

SDM 是一种**内容可寻址的联想记忆**：

1. 存储的“模式”是高维二值向量
2. 查询时，输入一个查询向量
3. 返回与查询最相似的存储模式（基于汉明距离）
4. 关键特性：在高维空间中，**超球面的交集**自然实现了类似 softmax 的加权检索

2.2 高维空间的几何直觉

高维空间中的奇异几何

在高维空间（如 $d = 1000$ ）中：

- 随机向量几乎都是**近似正交**的
- 两个随机向量的余弦相似度集中在 0 附近
- 以某点为中心的“帽”（超球面上的一小块区域）占总面积的极小比例
- 两个帽的交集面积与它们中心的距离呈**指数衰减**——这就是 softmax 的来源

2.3 本章小结

SDM 利用高维空间的几何性质实现了一种自然的联想记忆，其核心操作与 Transformer 的 softmax 注意力有深层对应。

3 从 SDM 到 Transformer 注意力

3.1 数学对应关系

SDM $\approx$ Attention 的形式化

SDM 的读取操作：

1. 给定查询 q ，计算它与每个存储地址 k_i 的距离
2. 距离越近的地址贡献越大——权重随距离**指数衰减**
3. 加权求和所有匹配地址的存储值

这与注意力的形式完全对应：

$$\text{SDM}(q) \approx \sum_i \frac{\exp(\text{sim}(q, k_i))}{\sum_j \exp(\text{sim}(q, k_j))} \cdot v_i = \text{Attention}(q, K, V)$$

3.2 两种记忆视角

- **短期记忆 (Attention)**：所有模式存储在 KV 缓存中，精确计算距离。优点是高保真度，缺点是上下文窗口有限
- **长期记忆 (权重)**：模式被“压缩”进网络权重。优点是容量大，缺点是检索精度较低

为什么 Transformer 有上下文窗口限制？

从 SDM 的角度看，注意力需要**显式存储**所有模式 (KV 对)，因此上下文窗口大小受限于内存。这解释了为什么 Transformer 的上下文长度是有限的——这是精确联想记忆的代价。

3.3 本章小结

SDM 和 Transformer 注意力在数学上高度对应，这为理解注意力机制提供了新的视角。

4 神经科学联系：认知地图

4.1 海马体与网格细胞

Trenton 将这些理论与神经科学联系起来：

大脑中的“注意力”

- **海马体**：大脑的记忆中枢，存储情节记忆——类似于 KV 缓存
- **内嗅皮层的网格细胞**：编码空间位置——类似于位置编码
- **认知地图**：大脑不仅编码物理空间，还编码**概念空间**中的关系

4.2 从空间到语义

认知地图的扩展

神经科学研究表明：

- 大脑的空间导航系统（网格细胞、位置细胞）也参与**抽象推理**
- 在视觉皮层中，低层更关注物理相似性，高层更关注**语义相似性**
- 例如：熨衣板和熨斗在语义空间中相近（功能相关），尽管外观不同
- 这种“概念空间中的导航”可能与 Transformer 中的表示学习有类似机制

4.3 本章小结

大脑的记忆和空间编码系统与 Transformer 的注意力和位置编码有惊人的功能对应，暗示着共同的计算原理。

5 总结与延伸

Trenton Bricken 的演讲建立了 Transformer 注意力机制与神经科学中稀疏分布式记忆之间的桥梁。这不仅为注意力机制提供了生物学合理性的理论支撑，也为未来的架构设计提供了灵感——或许我们可以从大脑的记忆机制中学到更多关于如何构建更好的 AI 系统。

5.1 拓展阅读

- Bricken & Pehlevan, “Attention Approximates Sparse Distributed Memory,” NeurIPS 2021
- Kanerva, “Sparse Distributed Memory,” MIT Press, 1988
- Whittington et al., “The Tolman-Eichenbaum Machine: Unifying Space and Relational Memory through Generalization in the Hippocampal Formation,” Cell, 2020
- Moser et al., “Place cells, grid cells, and the brain’s spatial representation system,” Annual Review of Neuroscience, 2008