


课程笔记

[CS25] How I Learned to Stop Worrying and Love the Transformer — Ashish Vaswani

基于公开课程资料整理

Fall 2023

Self-Attention



Stanford

视频作者/频道: Stanford CS25: Transformers United

发布日期: Fall 2023

视频时长: ~1.5h

视频链接: 项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1 引言：从达特茅斯会议到 Transformer	2
2 注意力机制的起源与演化	2
2.1 从 LSTM 到注意力	2
2.2 Scaled Dot-Product 的设计考量	2
2.3 多头注意力	2
2.4 本章小结	2
3 位置编码与长上下文	2
3.1 正弦位置编码	2
3.2 旋转位置编码 (RoPE)	3
3.3 本章小结	3
4 注意力的效率问题	3
4.1 二次复杂度	3
4.2 稀疏注意力与局部窗口	3
4.3 Flash Attention	3
4.4 本章小结	3
5 Transformer 的通用性	4
5.1 跨领域成功	4
5.2 本章小结	4
6 对未来的展望	4
7 总结与延伸	4
7.1 拓展阅读	4

1 引言：从达特茅斯会议到 Transformer

Ashish Vaswani 是 Transformer 架构的共同发明人之一 (“Attention Is All You Need”, 2017)。本讲以 1956 年达特茅斯会议为起点，回顾了 AI 发展的历史脉络，讨论了 Transformer 的设计哲学、架构演变及未来方向。

达特茅斯会议的启示

1956 年 AI 先驱们的目标是“用一个夏天解决智能问题”。虽然他们严重低估了难度，但提出的方向（学习、语言、抽象）至今仍是核心研究主题。讲者引用此例来强调：即使最聪明的人也可能对进展速度判断错误。

2 注意力机制的起源与演化

2.1 从 LSTM 到注意力

Vaswani 回顾了注意力机制的发展线索：RNN/LSTM 的信息瓶颈问题催生了 Bahdanau 注意力 (2014)，再到完全基于注意力的 Transformer (2017)。

Transformer 的核心洞察

注意力机制的本质是一种“软寻址”：Query 查询与所有 Key 的相似度，据此加权聚合 Value。Transformer 的突破在于完全去掉递归结构，仅用注意力实现序列建模，从而获得完全并行化的能力。

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V$$

2.2 Scaled Dot-Product 的设计考量

$\sqrt{d_k}$ 缩放因子的作用是防止内积在高维空间中变得过大，导致 softmax 梯度消失。这一看似简单的工程选择对训练稳定性至关重要。

2.3 多头注意力

多头注意力允许模型在不同的表示子空间中并行捕获不同类型的依赖关系（如句法关系、语义关系、指代关系等）。

2.4 本章小结

Transformer 通过自注意力机制实现了全局依赖建模与高效并行，奠定了现代深度学习的架构基础。

3 位置编码与长上下文

3.1 正弦位置编码

原始 Transformer 使用正弦/余弦函数编码位置信息。Vaswani 解释了选择正弦编码的直觉：不同频率的正弦波提供了一种类似“二进制计数器”的位置表示。

3.2 旋转位置编码 (RoPE)

RoPE 与长上下文扩展

旋转位置编码 (RoPE) 通过调整基频来扩展模型处理更长序列的能力。当遇到比训练时更长的序列时，可以通过调整基频参数使模型不会退化——这是当前 LLM 长上下文方案的核心技术之一。

3.3 本章小结

位置编码是 Transformer 将“集合运算”转化为“序列运算”的关键，RoPE 等改进使得长上下文成为可能。

4 注意力的效率问题

4.1 二次复杂度

自注意力的计算复杂度为 $O(n^2)$ ，其中 n 为序列长度。当序列变得很长时，不仅计算量爆炸，logits 的数值稳定性也会出现问题。

4.2 稀疏注意力与局部窗口

讲者回顾了多种降低注意力计算量的方法：

- **局部窗口注意力**：限制每个 token 只关注局部邻域（如 Sparse Transformer）
- **分块注意力**：将序列分割为块，在块内和块间分别计算注意力
- **线性注意力**：用核函数近似 softmax，将复杂度降至 $O(n)$

注意力机制的双重角色

注意力层的功能可从两个角度理解：(1) 信息路由——决定哪些 token 之间需要信息交换；(2) 归纳头 (Induction Head) ——学习复制模式。前馈层则是真正“存储知识”的地方。许多研究者过度关注注意力层的效率，却忽略了前馈层同样是计算瓶颈。

4.3 Flash Attention

Flash Attention 通过优化 GPU 内存访问模式（分块计算、避免实体化完整注意力矩阵），在不改变数学结果的情况下大幅加速注意力计算。

4.4 本章小结

注意力效率是 Transformer 扩展到超长序列的核心挑战，解决方案涵盖算法、系统和硬件多个层面。

5 Transformer 的通用性

5.1 跨领域成功

Vaswani 强调 Transformer 的一大独特之处是跨领域的通用性——最初为机器翻译设计，后被成功应用于：

- 计算机视觉 (ViT、DINO)
- 蛋白质结构预测 (AlphaFold)
- 语音识别 (Whisper)
- 代码生成 (Codex)
- 机器人控制 (RT-2)

通用近似器

Transformer 的成功可部分归因于其作为“序列到序列映射”的通用性——几乎所有问题都可以编码为 token 序列，而 Transformer 提供了学习任意序列映射的强大框架。

5.2 本章小结

Transformer 的架构简洁性和通用性是其统治性成功的根基。

6 对未来的展望

Vaswani 分享了几个前瞻性思考：

- **人机交互闭环**：产品化带来用户反馈，用户反馈驱动模型改进——这种闭环是纯研究无法替代的
- **思想多样性**：深度学习的进步受益于多样化的想法和方向，构建产品同样需要多样化
- **硬件协同设计**：如果架构足够确定，可以将其硬编码到芯片中以获得更高效率

7 总结与延伸

本讲由 Transformer 的发明者亲自回顾了从注意力机制到现代大模型的完整历史脉络。核心观点：Transformer 的成功源于简洁架构 + 规模化的深刻力量；未来的关键在于长上下文、高效推理、以及人机闭环学习。

7.1 拓展阅读

- Vaswani et al., “Attention Is All You Need”, NeurIPS 2017
- Su et al., “RoFormer: Enhanced Transformer with Rotary Position Embedding”, 2021
- Dao et al., “FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness”, 2022