

课程笔记

# [CS25] Recipe for Training Helpful Chatbots — Nazneen Rajani, HuggingFace

基于公开课程资料整理

Fall 2023



## Recipes for Training Helpful Chatbots

Stanford

视频作者/频道: Stanford CS25: Transformers United

发布日期: Fall 2023

视频时长: ~1h

视频链接:

项目主页: <https://github.com/hqhq1025/ai-course-notes>

# 目录

|                          |          |
|--------------------------|----------|
| <b>1 引言：H4 项目背景</b>      | <b>2</b> |
| <b>2 监督微调 (SFT)</b>      | <b>2</b> |
| 2.1 数据选择 . . . . .       | 2        |
| 2.2 SFT 训练细节 . . . . .   | 2        |
| 2.3 本章小结 . . . . .       | 2        |
| <b>3 奖励建模</b>            | <b>2</b> |
| 3.1 偏好数据收集 . . . . .     | 2        |
| 3.2 数据规模 . . . . .       | 3        |
| 3.3 本章小结 . . . . .       | 3        |
| <b>4 RLHF：强化学习微调</b>     | <b>3</b> |
| 4.1 PPO 训练流程 . . . . .   | 3        |
| 4.2 DPO：直接偏好优化 . . . . . | 3        |
| 4.3 本章小结 . . . . .       | 3        |
| <b>5 蒸馏与合成数据</b>         | <b>4</b> |
| 5.1 知识蒸馏 . . . . .       | 4        |
| 5.2 本章小结 . . . . .       | 4        |
| <b>6 评估方法</b>            | <b>4</b> |
| 6.1 自动评估 . . . . .       | 4        |
| 6.2 人类评估 . . . . .       | 4        |
| 6.3 本章小结 . . . . .       | 4        |
| <b>7 总结与延伸</b>           | <b>4</b> |
| 7.1 拓展阅读 . . . . .       | 5        |

# 1 引言：H4 项目背景

Nazneen Rajani 是 HuggingFace 的研究科学家，曾领导 H4 团队。H4 代表 **H**elpful、**H**armless、**H**onest 和 **H**uggy——目标是在开源预训练模型之上复现 ChatGPT 的对齐“秘方”。

## 对齐三步曲

OpenAI 在 InstructGPT 论文中提出的经典三步流程：

1. **监督微调 (SFT)**：在高质量指令-响应对上微调预训练模型
2. **奖励建模 (RM)**：训练奖励模型学习人类偏好
3. **强化学习 (RLHF)**：用 PPO 算法根据奖励模型优化策略

## 2 监督微调 (SFT)

### 2.1 数据选择

SFT 阶段的核心问题是“用什么数据”。H4 团队系统评估了多个开源指令数据集：

- **Open Assistant**：社区众包的多轮对话数据
- **Databricks Dolly**：员工编写的指令-响应对
- **Self-Instruct / Alpaca**：模型生成的合成指令数据

### 数据质量 > 数据数量

实验表明，1 万条高质量人工标注数据的效果可以超过 10 万条低质量合成数据。质量体现在：指令多样性、响应准确性、格式一致性。

### 2.2 SFT 训练细节

使用 LLaMA 系列模型作为基座，关键超参数包括：学习率  $2e-5$ 、batch size 64、1–3 epoch（避免过拟合）。

### 2.3 本章小结

SFT 是对齐的基础，数据质量是决定性因素。

## 3 奖励建模

### 3.1 偏好数据收集

奖励模型的训练需要人类偏好数据：给定同一 prompt，由多个模型生成响应，人类标注员选择更好的那个。

### Bradley-Terry 模型

奖励模型通过 Bradley-Terry 模型将偏好排序转化为标量奖励：

$$P(y_w \succ y_l | x) = \sigma(r(x, y_w) - r(x, y_l))$$

其中  $r(x, y)$  是奖励模型对 prompt  $x$  和响应  $y$  的打分， $\sigma$  为 sigmoid 函数。

## 3.2 数据规模

### 奖励模型需要大量数据

SFT 可能只需 1 万条数据，但奖励模型通常需要 10 万条以上的偏好对比数据。这是因为 RLHF 的采样效率较低——奖励模型需要在足够多样的响应对上学习细粒度的偏好信号。

## 3.3 本章小结

奖励建模将主观的“好坏”判断量化为可优化的标量信号。

## 4 RLHF：强化学习微调

### 4.1 PPO 训练流程

1. 从 SFT 模型采样响应
2. 用奖励模型打分
3. 用 PPO 算法更新策略模型
4. 加入 KL 散度惩罚，防止策略偏离 SFT 模型太远

$$\mathcal{L}_{\text{RLHF}} = \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_\theta} [r(x, y) - \beta \cdot D_{\text{KL}}(\pi_\theta \| \pi_{\text{ref}})]$$

其中  $\beta$  控制 KL 惩罚强度， $\pi_{\text{ref}}$  是 SFT 参考模型。

### 4.2 DPO：直接偏好优化

#### DPO 简化了 RLHF

直接偏好优化（DPO）将 RLHF 的两步（训练奖励模型 + PPO 优化）合并为一步：直接在偏好数据上优化策略模型，无需显式的奖励模型。DPO 的训练稳定性更好，超参数更少。

## 4.3 本章小结

RLHF 是对齐流程的核心环节，DPO 等方法正在简化这一过程。

## 5 蒸馏与合成数据

### 5.1 知识蒸馏

用更强的模型（如 GPT-4）生成响应，再用这些数据训练较小的模型。这种“蒸馏”方法在 Alpaca、Vicuna 等项目中被广泛使用。

#### 蒸馏的局限性

蒸馏模型往往在风格上模仿教师模型（如生成流畅的长回答），但在事实准确性上可能没有真正提升。Chatbot Arena 等评估表明，蒸馏模型的用户偏好得分可能被“风格分”抬高。

### 5.2 本章小结

蒸馏是快速获取对齐能力的捷径，但不能替代真正的知识获取。

## 6 评估方法

### 6.1 自动评估

- **MT-Bench**: 多轮对话基准，GPT-4 作为裁判
- **AlpacaEval**: GPT-4/Claude 进行成对比较，报告胜率
- **Chatbot Arena**: 公开众包的 ELO 排行榜 (LMSYS)

#### 用 LLM 评估 LLM 的偏差

GPT-4 作为评估器存在系统性偏差：偏好更长、更详细的回答，即使这些回答可能包含不准确的信息。人类评估与 GPT-4 评估的相关性约为 80%，仍有显著差距。

### 6.2 人类评估

H4 团队与 Scale AI 合作进行人类评估：生成所有模型组合的响应对 ( $\binom{n}{2}$ )，由人类标注员逐一比较，计算 ELO 评分。

### 6.3 本章小结

评估仍是对齐研究的最大瓶颈，自动指标和人类判断之间存在 gap。

## 7 总结与延伸

本讲系统介绍了开源社区复现 ChatGPT 对齐流程的实践经验。核心教训：(1) SFT 数据质量比数量重要；(2) RLHF 需要大量偏好数据且训练不稳定；(3) 评估仍是最大挑战。DPO 等新方法正在简化流程，但根本问题——“什么是好的回答”——仍需更深入的研究。

## 7.1 拓展阅读

- Ouyang et al., “Training Language Models to Follow Instructions with Human Feedback” (InstructGPT), 2022
- Rafailov et al., “Direct Preference Optimization: Your Language Model is Secretly a Reward Model”, 2023
- Zheng et al., “Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena”, 2023