


课程笔记

[CS25] No Language Left Behind / Machine Translation — Angela Fan, Meta

基于公开课程资料整理

Fall 2023



视频作者/频道: Stanford CS25: Transformers United

发布日期: Fall 2023

视频时长: ~1h

视频链接: 项目主页: <https://github.com/hqhq1025/ai-course-notes>

目录

1 引言：语言多样性与翻译	2
2 多语言翻译的挑战	2
2.1 数据稀缺	2
2.2 语言选择	2
2.3 本章小结	2
3 数据获取策略	2
3.1 多源数据整合	2
3.2 数据质量与规模的权衡	3
3.3 本章小结	3
4 模型架构	3
4.1 稀疏混合专家模型	3
4.2 课程学习	3
4.3 本章小结	3
5 评估与发现	3
5.1 FLORES-200 基准	3
5.2 关键发现	3
5.3 本章小结	4
6 总结与延伸	4
6.1 拓展阅读	4

1 引言：语言多样性与翻译

Angela Fan 是 Meta AI Research 的研究科学家。虽然生成式 AI 近年聚焦于英语，但全球有超过 3000 种书写语言。翻译是生成式 AI 中商业化最成功的应用之一——Google Translate 覆盖约 130 种语言，Microsoft Translate 约 110 种。但这远不足以涵盖全球语言多样性。

NLLB 的目标

No Language Left Behind (NLLB) 旨在为 200 种语言构建高质量机器翻译系统，其中许多是此前几乎无数据可用的低资源语言。这不仅是技术挑战，更是社会公平问题。

2 多语言翻译的挑战

2.1 数据稀缺

低资源语言的困境

对于 Wolof、Luganda 等低资源语言，可用的平行语料可能只有几千句（主要来自《圣经》翻译）。而高资源语言（如法语、中文）有数百万句高质量平行数据。这种极端的数据不平衡是多语言翻译的核心挑战。

2.2 语言选择

NLLB 团队基于以下标准选择了 200 种目标语言：

- 使用人口数
- 语言家族的多样性覆盖
- 数据可获取性
- 社区需求

2.3 本章小结

多语言翻译的核心矛盾是：最需要翻译服务的语言往往数据最少。

3 数据获取策略

3.1 多源数据整合

NLLB 使用了多种数据来源：

1. **FLORES 基准**：每种语言约 6000 句高质量人工对齐数据
2. **公开双语文本**（如 OPUS）：质量参差不齐，许多语言仅有圣经文本
3. **网络挖掘数据**：通过句子编码器从网页中挖掘对齐句对，依赖编码器质量
4. **回译数据**（Back-translation）：用已有模型生成“银标”数据进行增强

回译 (Back-translation)

回译是机器翻译中经典的数据增强技术：先用目标 → 源方向的模型将目标语言单语数据翻译回源语言，再用这些“伪平行对”扩充训练数据。质量取决于基础翻译模型的好坏。

3.2 数据质量与规模的权衡

高资源语言拥有数千万句训练对，而低资源语言可能只有几千句。团队通过上采样低资源语言数据和温度采样来缓解这种不平衡。

3.3 本章小结

数据策略是 NLLB 成功的基石——结合高质量种子数据、网络挖掘和回译实现规模化。

4 模型架构

4.1 稀疏混合专家模型

NLLB 使用 MoE 架构

NLLB 采用稀疏混合专家 (Sparse Mixture of Experts) Transformer：每一层有多个前馈“专家”子网络，每个 token 只路由到其中少数专家进行处理。这使模型在参数量大幅增加的同时保持推理 FLOPs 基本不变。最大模型达到 54B 参数。

MoE 架构特别适合多语言翻译：不同的专家可以隐式地“专攻”不同的语言或语言家族，实现高效的参数共享和专业化。

4.2 课程学习

训练过程中采用课程学习策略：先训练高资源语言对，再逐步引入低资源语言对，避免低资源数据被高资源数据淹没。

4.3 本章小结

MoE + 课程学习使 NLLB 在保持计算效率的同时覆盖 200 种语言。

5 评估与发现

5.1 FLORES-200 基准

FLORES-200 为每种语言提供了 1012 个句子的开发集和测试集，由专业翻译人员标注，是当前最全面的多语言翻译评估基准。

5.2 关键发现

- NLLB 在 200 种语言上平均 BLEU 分数相比前代模型提升了 44%
- 低资源语言的提升最为显著

- 某些语言方向的翻译质量已接近人类水平

基础模型改进如何惠及翻译

随着基础语言模型质量的提升，对特定领域微调的依赖逐渐减少。这与“一个强大的基础模型胜过多个专用模型”的趋势一致——翻译研究者、摘要研究者和问答研究者正逐渐被统一的 LLM 范式所融合。

5.3 本章小结

NLLB 显著推进了低资源语言翻译的前沿，但距离全覆盖仍有差距。

6 总结与延伸

本讲展示了如何通过数据工程、模型架构创新和系统化评估，将机器翻译从少数高资源语言扩展到 200 种语言。核心启示：(1) 数据策略比模型架构更重要；(2) MoE 是多语言场景的天然选择；(3) 多语言公平性是技术问题也是伦理问题。

6.1 拓展阅读

- NLLB Team, “No Language Left Behind: Scaling Human-Centered Machine Translation”, 2022
- Costa-jussà et al., “FLORES-200: Open Evaluation Benchmark for 200 Languages”, 2022
- Fan et al., “Beyond English-Centric Multilingual Machine Translation”, 2020