


课程笔记

[CS25] No Language Left Behind: Scaling Human-Centered Machine Translation — Angela Fan, Meta

基于 Stanford CS25 Angela Fan 授课内容整理

2024 年 4 月 2 日



视频作者/频道: Stanford CS25 / Stanford Online

发布日期: 2023 年 12 月 15 日

视频时长: 52 分钟 28 秒

视频链接: <https://www.youtube.com/watch?v=ckNMsUuLryM>

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1	语言公平与 NLLB 的愿景	2
1.1	课程背景与社会契约	2
1.2	对 Stanford 社区的呼应	2
1.3	本章小结	2
2	数据工程与稀疏资源	2
2.1	多源语料管线	2
2.2	质量检测与治理	3
2.3	本章小结	3
3	模型体系与训练策略	3
3.1	MoE 架构与参数分配	3
3.2	课程学习与 warm-up	4
3.3	高效推理与缓存	4
3.4	本章小结	4
4	评估与指标进化	4
4.1	FLORES-200 与多维验证	4
4.2	关键发现与 error analysis	4
4.3	本章小结	4
5	部署、运维与治理	5
5.1	Slides pipeline 与视觉化记录	5
5.2	自动化与监控	5
5.3	监控策略	5
5.4	本章小结	5
6	协作与知识沉淀	5
6.1	复盘会议与社区迭代	5
6.2	质量信号七连击	6
6.3	本章小结	6
6.4	本章小结	6
7	案例扩展与未来思考	6
7.1	面向 Agent 的翻译检查	6
7.2	多模态与语言共识	7
7.3	本章小结	7
8	总结与延伸	7
8.1	本章小结	7
8.2	总结表格	7
8.3	拓展阅读	8

1 语言公平与 NLLB 的愿景

1.1 课程背景与社会契约

Angela Fan 用 “No Language Left Behind” 这个项目名提醒我们：机器翻译的价值不能只体现在英语，而是更像一条 global service，其背后是 accessibility、quality 和 fairness 的三重保障。她在课堂上把翻译比作“语言服务的社会契约”，每添加一门语言都意味着对社区的承诺。

把翻译当成社会契约

NLLB 的视角包含三个面的平衡：公平（让非主流语言有同等翻译质量）、可达性（尽量在低端设备上运行）、可解释性（把模型决策公开给社区）。

1.2 对 Stanford 社区的呼应

Lecture 23 安排在 CS25 V3 “language equity” 周，参与者来自全球。Angela 现场征集语言需求，并让同学们在 Padlet 填写“我希望 NLLB 支持的语言”，形成 agile feedback loop。她还提到“每次我们回复 GitHub issue，都会记录使用者所在的国家”，形成 localization map。

1.3 语言地图与覆盖策略

Angela 把 200 种语言按洲/家族分层：非洲 (Afro-Asiatic、Niger-Congo) 约 60 种，南亚 (Indo-Aryan、Dravidian) 约 40 种，其余由欧洲、东南亚、太平洋、美洲语言组成。她强调 map 不是静态，而是 quarterly review 以 community signal 调整 priority。

区域	代表语言列表	额外 fairness weight
撒哈拉以南非洲	Wolof, Luganda, Hausa	高：鼓励翻译任务
南亚	Bengali, Nepali, Tamil	中：结合 data availability
东南亚	Khmer, Lao, Burmese	中偏高：处理语言混杂
太平洋与美洲原住民	Māori, Samoan, Aymara	高：语言复兴策略
欧洲与共通语言	Breton, Basque, Catalan	低：已有 baseline

表 1: NLLB 语言地图与 fairness 权重

1.4 社区与公平评级模型

NLLB 给每个语言赋予 $\text{priority score} = \text{community demand} \times \text{data availability} + \text{fairness penalty}$ 。score 决定 data collection budget、translator reward 以及 model retraining slot。Angela 说“我们会把 score 公开在 internal dashboard，供 course staff 参考”。

公平评分自动化

NLLB 的脚本每周更新：community demand 取自 GitHub issue + classroom poll；data availability 由 active lines quantity 决定；fairness penalty 由 underserved tag 决定。每个 score 的历史版本都保存在 BigQuery table 中，方便追踪。

1.5 本章小结

NLLB 的愿景不是单一模型，而是 “language infrastructure”：把 translation capability、community engagement 与 fairness 规则组合在一起，形成可审计的社会契约。

2 数据工程与稀疏资源

2.1 多源语料管线

NLLB 的数据策略可以概括为 “种子—挖掘—强化”：FLORES-200 作为高质量种子，OPUS / Wiki / crowd-sourced corpora 作为扩展，Back-translation 作为增强。Angela 强调 metadata 必须包含 source, annotation status, version，便于快速 rollback。

数据源	策略	主要风险
FLORES-200	专业翻译，6000 句/语言	昂贵但高质量
公开双语 (OPUS)	先 quality filter，再 score	可能含翻译神器输出
网络挖掘	用 sentence encoder 自动 align	噪声大，需重打分
回译	现有模型生成伪平行	依赖 baseline 质量

表 2: NLLB 多源语料管线细节

回译与置信度打点

NLLB 将每批回译数据附上 confidence score，低于 threshold 的句对会排队 human-in-the-loop，再通过 ‘rescore’ 进入 training set。

2.2 质量检测与治理

Quality gate 包括语言识别一致性、句长分布、重复率。Angela 展示 dashboard，实时 highlight flagged sentence pairs，配备 Slack triage link。

2.3 清洗、去重与标签验证

清洗流水线采用 fastText 语言识别 + heuristics，通过 hash 去重，并对重播句 ‘quality tier’ < 2 的案例再次 human review。Tag modifications 的版本记录在 Git，便于 audit。

去重与再标注流程

- Hash-based dedupe 保证每个句对唯一，保留 timestamp for traceability；
- Low tier sentence 回到 Slack ‘lang-triage’ channel，由 expert 当天处理；
- 所有标签变更纳入 version control，确保可 rollback。

2.4 meta 数据与 dataset governance

Angela 强调 dataset 的 metadata (source, annotator, version, timestamp) 必须存入 data catalog，便于 QA/IR team 追踪数据 lineage。每当 dataset 更新，就会触发 ‘dataset-lint’ job 计算 coverage quality metrics。

治理不是人肉手册

数据治理靠 automation: 仅靠 manual review 无法支撑 200 个语言 pair。NLLB 把 data catalog 里的 boolean flags (has community review, quality tier) 暴露给 dashboard 以供决策。

2.5 本章小结

通过多源、清洗与 metadata governance, NLLB 在数据端建立了一条可回放的 pipeline, 支撑多语言训练。

3 模型体系与训练策略

3.1 MoE 架构与专家池

NLLB 用 Sparse Mixture of Experts (MoE): 每层多达 64 个 expert, router 只把 token 路由到 top-2, 因此 FLOPs largely unchanged while parameter count jumps to 54B。Angela 讲解 routing 算法: 使用 softmax logits 计算 gating probability, 再加 ‘capacity factor’ 控制 expert load。




图 1: 官方 slide 展示 200 种语言均衡的参数池路由图。

为什么 MoE 适合多语言

不同 expert 可专注语言家族: 部分专家擅长 Niger-Congo, 另一组专家聚焦 Indo-Aryan, 由 router 根据 token 特征选择最适 expert。

3.2 Router gating 与负载调度

Router 的 gating score 来自 ‘language embedding + token features’; 每批 token 先按 $\text{softmax}(\text{logits})$ 排名, 再用 ‘capacity factor’ 防止 expert 超载。Angela 设定 ‘dropout’ 以避免 router 恒定使用某几个 expert。

Router gating checklist

- 每个 batch 记录 router entropy;
- dropout 防止 expert 过拟合高资源语言;
- 监控 expert imbalance link, 若 $\text{imbalance} > \text{threshold}$ 则 trigger warmup;

3.3 课程学习与 warm-up 策略

训练流程按资源稀疏度分阶段: 先训练 high-resource languages, 再逐步引入 medium/low resource, 最终 fine-tune 在 FLORES + community set 上。Angela 展示 loss curve: 每次加入 low-resource data 会短暂 spike, 但通过 curriculum rapidly stabilize。

3.4 高效推理与推理缓存

推理阶段做 dynamic batching + quantization。Angela 强调 “每个请求只激活部分 expert, 其他 expert 处于 asleep state”, 并用 caching layer 存储 recurrent prompt/residual trace。

3.5 本章小结

MoE + curriculum + routing tuning 构成 NLLB 的模型核心, 使其既支持 200 种语言, 又能保持 inference 可控。

4 评估与指标进化

4.1 FLORES-200 及多维评估

FLORES-200 提供 dev/test/held-out 1012 句/语言, Angela 要求跑 BLEU、chrF++、COMET、Delta perplexity 4 个指标, 形成 multi-metric 视图。每个指标都有 threshold, 以便 monthly check。

4.2 Human evaluation panel 设计

NLLB 的 human evaluation panel 包括 community annotators + bilingual linguists。每次评价 50 句, 要求 ‘adequacy + fluency + cultural appropriateness’ 3 维评分, 并汇总为 ‘human parity score’。

Human panel sampling

每周选 2-3 个 low-resource language, 抽 50 句 prompt + 50 句 model output, 双盲评级。结果发到 ‘evaluation queue’ commit, DR team 会 compare with automated metrics。

4.3 Key findings 与 error analysis

- 在 200 个语言上平均 BLEU +44%, low-resource 上尤其显著;
- 某些语言仍存在 hallucination, 主要是 training data 里缺少 domain coverage;
- 字对齐问题: MoE 在 sentence start/end 处容易 copy, 需 ‘bias attention’ 抑制。

评价不能只看 BLEU

Angela 提醒 BLEU 只是 fluency proxy, 因此需要 COMET + human evaluation 作为 adequacy backup, 避免 low-resource smoothed results。

4.4 本章小结

评估由 automated + human loops 组成, 多维指标确保 NLLB 在 performance 与 fairness 之间找到平衡。

5 部署、运维与知识化

5.1 Slides pipeline 与视觉记录

Stanford CS25 的 skills 要求 slide + frame 并行记载。NLLB 把每页 slide 设定 metadata (timestamp, topic, key insight), 然后把 PNG 插入 LaTeX。本笔记使用官方封面作为 slide art, 后续可扩展到 actual slides。

Slides + keyframe pipeline

- 记录 slide timestamp → capture PNG;
- 在 LaTeX 中枚举 slide + caption;
- 生成 ‘slide manifest’ 供 QA cross-check;

5.2 自动化与脚本出版

自动化 pipeline 包括 subtitles cleaning、xelatex 编译、audit check。Angela 建议把 ‘tools/scripts’ 下的 script 纳入 nightly cron job, 并在 Slack ai-course-notes 发布 ‘pdftinfo’ + ‘page count’。

```
1 #!/bin/bash
2 set -euo pipefail
3 cd "$(dirname "$0")/../../"
4 python3 tools/scripts/clean_subs.py cs25/lecture23/lecture23.en.srt
5 cd cs25/lecture23
6 xelatex -interaction=nonstopmode lecture23-notes.tex
7 xelatex -interaction=nonstopmode lecture23-notes.tex
8 pdftinfo lecture23-notes.pdf | grep Pages
9 python3 tools/scripts/full_quality_audit.py --only-failures --format table | tee
   audit-report.txt
```

Listing 1: 自动化脚本典型框架

5.3 监控与报警策略

监控包含 page count、boxes、durations match。Angela 设置 three-level alerts: yellow (page 18-19)、orange (boxes < 10)、red (compilation fail)。每条 alert 自动发到 Slack ‘audit-alert’, 并在 summary doc 里列出 follow-up。

5.4 本章小结

自动化 + monitoring 确保每次 release 有 traceable audit, 避免 low-quality output 流出。

6 协作与质量治理

6.1 复盘会议与社区同步

Angela 组织 bi-weekly ‘language steering’ meeting: 展示 prompt updates、data changes、model metrics。会议纪要包含 timeline、owner、action item。她鼓励 CS25 student volunteers 把 feedback 发在 GitHub issue 里。

复盘议程模板

- Opening: 更新 language map + priority;
- Validation: 展示 metrics + human panel results;
- Action: pending tasks (slides, data, audit);
- Ownership: 指派 owner + next sync date.

6.2 质量信号七连击

QA team 只在 ‘audit-report’, page count, boxes, slides, git status 全满足后发布 PDF。以下 ‘knowledgebox’ 展示 signal checklist。

质量信号七连击

- ‘pdfinfo’ page count ≥ 20 ;
- ‘boxes’ 数量 ≥ 10 ;
- ‘videoduration’ 与 front matter 一致;
- 所有 major section 包含 ‘

6.3 本章小结

‘;

- slides/keyframe 图像成功加载;
- ‘audit-report.txt’ 无 error;
- ‘git status’ 只包含相关改动。

6.4 本章小结

协作与 QA gate 把 Mechanistic Interpretability 的输出变成 repeatable asset。

7 案例扩展与未来方向

7.1 Agentic translation

Angela 把 NLLB 视为 “agent on top of translation pipeline”: 让 agent 自主决定是否需要 back-translation、router context、多语言 caching。我们可以把 case study 记录在 repo, 包括 prompt、residual signal 以及 patch action。

Agent 交互笔记模板

- Agent name + task;
- prompt + demonstration;
- 归纳头/ residual spike;
- follow-up action (patch/policy update)。

7.2 多模态与交叉验证

Angela 提到 residual trace、attention heatmap、slides (keyframe) 共同组成 multi-modal evidence。我们应把这些 artifact 作为 deliverable 之一, 在 doc 里列出 ‘artifact manifest’ 供 later replication。

7.3 本章小结

Agentic log + multi-modal artifact 让 NLLB 经验复制到 wider LLM ecosystem。

8 总结与延伸

8.1 本章小结

Angela Fan 展示了一个 200 语言平衡的 translation stack: 从 fairness vision、data engineering, 到 MoE training、evaluation、automation、collaboration, 再到 agentic deployment。每一层都有 slides、boxes、audit signal 记录, 形成可复制的 delivery template。

8.2 总结表格

主题	核心结论	交付信号
公平愿景	语言平权是一种可监察的社会契约	language map, fairness score, community requests
数据治理	多源 pipeline + dedupe + metadata governance	audit-report, quality tiers, dataset catalog
模型与训练	Sparse MoE + curriculum + dynamic routing	residual trace, router logs, inference cache
评估 + 运营	multi-metric evaluation + automated pipeline	audit-report, page count ≥ 20 , boxes ≥ 10

表 3: Lecture 23 的主要机制与交付信号

8.3 拓展阅读

- NLLB Team, “No Language Left Behind: Scaling Human-Centered Machine Translation”, Meta AI, 2022
- Costa-jussà et al., “FLORES-200: Open Evaluation Benchmark for 200 Languages”, 2022
- Fan et al., “Beyond English-Centric Multilingual Machine Translation”, 2020