

课程笔记

[CS25] Beyond LLMs: Agents, Emergent Abilities — Instructors

基于公开课程资料整理

Fall 2023



视频作者/频道: Stanford CS25: Transformers United

发布日期: Fall 2023

视频时长: ~1h

视频链接: 项目主页: <https://github.com/hqhq1025/ai-course-notes>

目录

1 引言	2
2 涌现能力 (Emergent Abilities)	2
2.1 定义与现象	2
2.2 涌现的争议	2
2.3 本章小结	2
3 中间引导推理	2
3.1 思维链提示 (Chain-of-Thought)	2
3.2 BabyLM Challenge	2
3.3 本章小结	3
4 AI 智能体 (Agents)	3
4.1 智能体的定义	3
4.2 计算机交互智能体	3
4.3 安全与可靠性	3
4.4 本章小结	3
5 总结与延伸	3
5.1 拓展阅读	4

1 引言

本讲由 CS25 课程讲师联合主讲，涵盖两大主题：涌现能力与中间引导推理（由 Seonghee 讲授）和 AI 智能体（由 Div 讲授）。

2 涌现能力 (Emergent Abilities)

2.1 定义与现象

涌现能力的定义

涌现能力是指在大模型中出现、但在小模型中不存在的能力，且无法通过小模型性能的外推来预测。表现为“相变” (phase transition)：性能在某个临界规模突然跃升。

Wei et al. (2022) 发现多种任务（模运算、单词重组、多步推理等）在训练 FLOPs 达到约 10^{22} – 10^{23} 时出现性能跃迁。

2.2 涌现的争议

涌现可能是评估指标的假象

Stanford 2023 年的研究指出，涌现现象可能是评估指标非线性（如精确匹配）的产物：如果使用连续评估指标，性能提升看起来是渐进的而非突变的。这引发了关于“涌现到底是模型的属性还是指标的属性”的深入讨论。

2.3 本章小结

涌现能力的存在性仍有争议，但规模化确实带来了质的变化。

3 中间引导推理

3.1 思维链提示 (Chain-of-Thought)

思维链的核心思想

让模型在给出最终答案前先生成中间推理步骤。通过在 few-shot 示例中加入推理过程，模型学会“展示思考过程”，显著提升数学和逻辑推理能力。CoT 本身也是一种涌现能力——仅在大模型中有效。

3.2 BabyLM Challenge

用少量数据训练语言模型

BabyLM Challenge 探索一个有趣的问题：人类儿童在约 1 亿词的语言输入下就能习得语言能力，而 LLM 需要数万亿 token。能否用类似人类学习量（~100M 词）的数据训练出高效的语言模型？

3.3 本章小结

中间推理引导和小数据效率是提升 LLM 推理能力的两个互补方向。

4 AI 智能体 (Agents)

4.1 智能体的定义

将 LLM 从“回答问题的工具”升级为“在环境中行动的系统”。

神经计算单元类比

可以把 LLM 类比为“神经 CPU”——它是核心处理单元，但完整的智能体还需要：

- **记忆**：短期（上下文窗口）和长期（向量数据库）
- **规划**：任务分解和策略选择
- **工具**：搜索引擎、计算器、代码执行器
- **行动**：在数字或物理环境中执行操作

4.2 计算机交互智能体

讲者展示了一个能控制计算机的智能体 demo：通过自然语言指令，智能体可以操作网页浏览器、文件系统等。这相当于一个“通用 API”——不需要为每个应用编写接口，一个智能体就能完成所有操作。

4.3 安全与可靠性

智能体的安全挑战

- **错误纠正**：智能体难以自动检测和修复推理错误
- **用户权限**：需要分层权限系统（如禁止访问银行账户，但允许访问购物网站）
- **沙箱隔离**：确保智能体不会误删重要文件或在高风险场景中造成不可逆损害
- **不可逆操作**：金融交易、数据删除等操作需要额外确认机制

4.4 本章小结

AI 智能体是 LLM 落地的关键范式，但安全性和可靠性仍需大量基础设施建设。

5 总结与延伸

本讲覆盖了当前 LLM 研究的两大前沿：涌现能力（及其争议）和 AI 智能体。涌现与规模化的关系仍在研究中；智能体从“对话”走向“行动”，但可靠性是实际部署的最大障碍。

5.1 拓展阅读

- Wei et al., “Emergent Abilities of Large Language Models”, 2022
- Wei et al., “Chain-of-Thought Prompting Elicits Reasoning in Large Language Models”, 2022
- Schaeffer et al., “Are Emergent Abilities of Large Language Models a Mirage?”, 2023
- Warstadt et al., “BabyLM Challenge: Sample-Efficient Pretraining on a Developmentally Plausible Corpus”, 2023