


课程笔记

# [CS25] Beyond LLMs: Agents, Emergent Abilities — Instructors

五道口纳什 & Codex

2026 年 3 月 29 日



视频作者/频道: Stanford CS25: Transformers United

发布日期: Fall 2023

视频时长: ~1h

视频链接: 未填写

# 目录

|                                        |          |
|----------------------------------------|----------|
| <b>1 引言</b>                            | <b>2</b> |
| <b>2 涌现能力 (Emergent Abilities)</b>     | <b>2</b> |
| 2.1 定义与现象 . . . . .                    | 2        |
| 2.2 涌现的争议 . . . . .                    | 2        |
| 2.3 本章小结 . . . . .                     | 2        |
| <b>3 中间引导推理</b>                        | <b>2</b> |
| 3.1 思维链提示 (Chain-of-Thought) . . . . . | 2        |
| 3.2 BabyLM Challenge . . . . .         | 2        |
| 3.3 本章小结 . . . . .                     | 3        |
| <b>4 AI 智能体 (Agents)</b>               | <b>3</b> |
| 4.1 智能体的定义 . . . . .                   | 3        |
| 4.2 计算机交互智能体 . . . . .                 | 3        |
| 4.3 安全与可靠性 . . . . .                   | 3        |
| 4.4 本章小结 . . . . .                     | 3        |
| <b>5 总结与延伸</b>                         | <b>3</b> |
| 5.1 拓展阅读 . . . . .                     | 4        |

# 1 引言

本讲由 CS25 课程讲师联合主讲，涵盖两大主题：涌现能力与中间引导推理（由 Seonghee 讲授）和 AI 智能体（由 Div 讲授）。

## 2 涌现能力 (Emergent Abilities)

### 2.1 定义与现象

#### 涌现能力的定义

涌现能力是指在大模型中出现、但在小模型中不存在的能力，且无法通过小模型性能的外推来预测。表现为“相变” (phase transition)：性能在某个临界规模突然跃升。

Wei et al. (2022) 发现多种任务（模运算、单词重组、多步推理等）在训练 FLOPs 达到约  $10^{22}$ – $10^{23}$  时出现性能跃迁。

### 2.2 涌现的争议

#### 涌现可能是评估指标的假象

Stanford 2023 年的研究指出，涌现现象可能是评估指标非线性（如精确匹配）的产物：如果使用连续评估指标，性能提升看起来是渐进的而非突变的。这引发了关于“涌现到底是模型的属性还是指标的属性”的深入讨论。

### 2.3 本章小结

涌现能力的存在性仍有争议，但规模化确实带来了质的变化。

## 3 中间引导推理

### 3.1 思维链提示 (Chain-of-Thought)

#### 思维链的核心思想

让模型在给出最终答案前先生成中间推理步骤。通过在 few-shot 示例中加入推理过程，模型学会“展示思考过程”，显著提升数学和逻辑推理能力。CoT 本身也是一种涌现能力——仅在大模型中有效。

### 3.2 BabyLM Challenge

#### 用少量数据训练语言模型

BabyLM Challenge 探索一个有趣的问题：人类儿童在约 1 亿词的语言输入下就能习得语言能力，而 LLM 需要数万亿 token。能否用类似人类学习量（~100M 词）的数据训练出高效的语言模型？

### 3.3 本章小结

中间推理引导和小数据效率是提升 LLM 推理能力的两个互补方向。

## 4 AI 智能体 (Agents)

### 4.1 智能体的定义

将 LLM 从“回答问题的工具”升级为“在环境中行动的系统”。

#### 神经计算单元类比

可以把 LLM 类比为“神经 CPU”——它是核心处理单元，但完整的智能体还需要：

- **记忆**：短期（上下文窗口）和长期（向量数据库）
- **规划**：任务分解和策略选择
- **工具**：搜索引擎、计算器、代码执行器
- **行动**：在数字或物理环境中执行操作

### 4.2 计算机交互智能体

讲者展示了一个能控制计算机的智能体 demo：通过自然语言指令，智能体可以操作网页浏览器、文件系统等。这相当于一个“通用 API”——不需要为每个应用编写接口，一个智能体就能完成所有操作。

### 4.3 安全与可靠性

#### 智能体的安全挑战

- **错误纠正**：智能体难以自动检测和修复推理错误
- **用户权限**：需要分层权限系统（如禁止访问银行账户，但允许访问购物网站）
- **沙箱隔离**：确保智能体不会误删重要文件或在高风险场景中造成不可逆损害
- **不可逆操作**：金融交易、数据删除等操作需要额外确认机制

### 4.4 本章小结

AI 智能体是 LLM 落地的关键范式，但安全性和可靠性仍需大量基础设施建设。

## 5 总结与延伸

本讲覆盖了当前 LLM 研究的两大前沿：涌现能力（及其争议）和 AI 智能体。涌现与规模化的关系仍在研究中；智能体从“对话”走向“行动”，但可靠性是实际部署的最大障碍。

## 5.1 拓展阅读

- Wei et al., “Emergent Abilities of Large Language Models”, 2022
- Wei et al., “Chain-of-Thought Prompting Elicits Reasoning in Large Language Models”, 2022
- Schaeffer et al., “Are Emergent Abilities of Large Language Models a Mirage?”, 2023
- Warstadt et al., “BabyLM Challenge: Sample-Efficient Pretraining on a Developmentally Plausible Corpus”, 2023