


课程笔记

[CS25] Retrieval Augmented Language Models — Douwe Kiela

五道口纳什 & Codex

2026 年 3 月 29 日



视频作者/频道: Stanford CS25: Transformers United

发布日期: Fall 2023

视频时长: ~1h

视频链接: 未填写

目录

1 引言：语言模型的前世今生	2
2 为什么需要检索增强	2
2.1 LLM 的根本局限	2
2.2 RAG 的核心范式	2
2.3 本章小结	2
3 检索方法	2
3.1 稀疏检索：BM25	2
3.2 密集检索：DPR	3
3.3 向量索引	3
3.4 本章小结	3
4 端到端检索增强模型	3
4.1 REALM	3
4.2 RAG (Lewis et al., 2020)	3
4.3 Atlas	3
4.4 Fusion-in-Decoder (FiD)	3
4.5 本章小结	4
5 幻觉与事实性	4
5.1 可调节的“幻觉旋钮”	4
5.2 不同的“真相来源”	4
5.3 本章小结	4
6 总结与延伸	4
6.1 拓展阅读	4

1 引言：语言模型的前世今生

Douwe Kiela 是 Contextual AI 的 CEO 兼斯坦福大学符号系统系兼职教授，曾任 HuggingFace 研究主管和 Facebook AI Research 研究科学家。本讲全面介绍检索增强生成（RAG）的原理、方法与前沿。

语言模型不是 OpenAI 发明的

语言模型的核心思想——将序列概率分解为条件概率的乘积——已有数十年历史，可以追溯到 Claude Shannon 的信息论工作。这一历史视角提醒我们：当前的 LLM 革命建立在深厚的学术基础之上。

2 为什么需要检索增强

2.1 LLM 的根本局限

参数化记忆 vs 非参数化记忆

LLM 的所有知识都“烤入”（baked in）了模型参数中，这带来三个根本问题：

1. **知识过时**：训练截止后的信息无法获取
2. **幻觉**：模型可能自信地生成虚假信息
3. **不可溯源**：无法验证生成内容的来源

检索增强通过引入外部知识库（非参数化记忆），补充和修正参数化记忆的不足。

2.2 RAG 的核心范式

RAG workflow

1. **检索**（Retrieve）：根据查询从外部知识库中找到相关文档
2. **增强**（Augment）：将检索到的文档拼接到 LLM 的输入中
3. **生成**（Generate）：LLM 基于增强后的上下文生成回答

2.3 本章小结

RAG 是应对 LLM 幻觉和知识过时最实用的方案。

3 检索方法

3.1 稀疏检索：BM25

BM25 是经典的基于词频的检索算法，简单高效，至今仍是许多系统的强基线。

3.2 密集检索: DPR

Dense Passage Retrieval (DPR)

DPR 使用双编码器架构: 查询和文档分别通过 BERT 编码为向量, 通过内积计算相似度。优势在于可以捕获语义相似性 (而非仅仅词面匹配)。训练数据来自问答对。

3.3 向量索引

密集检索需要高效的近似最近邻搜索。FAISS 等工具使用量化和分区技术, 在数十亿文档中实现毫秒级检索。

3.4 本章小结

稀疏和密集检索各有优势, 实践中常结合使用。

4 端到端检索增强模型

4.1 REALM

REALM: 首个端到端检索增强预训练模型

REALM (Retrieval-Augmented Language Model pre-training) 在预训练阶段就引入检索: 掩码语言模型不仅依赖上下文, 还检索相关文档来预测被掩码的 token。检索器和语言模型联合端到端训练。

REALM 的挑战在于: 每次模型更新后, 文档编码器也发生变化, 需要周期性重新编码整个语料库。这在计算上非常昂贵。

4.2 RAG (Lewis et al., 2020)

RAG 论文提出了两种变体:

- **RAG-Sequence**: 对整个生成序列使用同一组检索文档
- **RAG-Token**: 每生成一个 token 都可以检索不同的文档

4.3 Atlas

Atlas: Few-shot RAG

Atlas 将 RAG 范式扩展到 few-shot 设置, 证明了: 一个带检索的 11B 模型可以在 few-shot 任务上超越不带检索的 540B PaLM。这说明检索增强可以部分替代模型规模。

4.4 Fusion-in-Decoder (FiD)

FiD 将多个检索文档分别编码后在解码器中融合。这种设计允许模型处理大量检索结果而不受注意力长度限制。

4.5 本章小结

端到端训练使检索器和生成器协同优化，但计算成本是主要瓶颈。

5 幻觉与事实性

5.1 可调节的“幻觉旋钮”

幻觉并非总是坏事

在创意写作中，我们希望模型“幻觉”出新颖的想法；在事实查询中，我们希望它严格依据证据。理想的系统应该有一个可调节的旋钮——控制模型对检索文档的依赖程度。温度参数只影响采样策略，并不能真正控制事实性。

5.2 不同的“真相来源”

用户可以定义不同的信任边界：只信任 arXiv、只信任同行评审论文、或只信任特定企业知识库。这种灵活的“真相源”定义是 RAG 系统的重要设计维度。

5.3 本章小结

RAG 为控制幻觉提供了最直接的机制——外部知识作为事实锚点。

6 总结与延伸

本讲全面覆盖了检索增强语言模型的理论基础和实践方案。核心观点：(1) RAG 是当前最实用的减少幻觉方案；(2) 检索器和生成器的端到端训练是发展方向；(3) 检索可以部分替代模型规模；(4) 系统设计需要考虑可溯源性和可控性。

6.1 拓展阅读

- Lewis et al., “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”, 2020
- Guu et al., “REALM: Retrieval-Augmented Language Model Pre-Training”, 2020
- Izacard et al., “Atlas: Few-shot Learning with Retrieval Augmented Language Models”, 2022
- Izacard & Grave, “Leveraging Passage Retrieval with Generative Models for Open Domain QA” (FiD), 2021