

课程笔记

[CS25 V4] Overview of Transformers — Div Garg 公开讲座整理

基于 Stanford CS25 V4 讲座资料整理

2024 年 4 月 23 日



视频作者/频道: Stanford CS25: Transformers United V4

发布日期: 2024 年 4 月 23 日

视频时长: 约 1 小时 8 分钟

视频链接: <https://www.youtube.com/watch?v=fKMB5U1VY1E>

项目主页: <https://github.com/hqhq1025/ai-course-notes>

目录

1 导语与讲座目标	3
1.1 讲座节奏与复习地图	3
1.2 问题空间与期望产出	3
1.3 本章小结	3
2 Transformer 架构回顾与视觉呈现	3
2.1 自注意力与并行计算	3
2.2 位置编码与 Token 化	4
2.3 本章小结	4
3 预训练规模与数据策略	5
3.1 数据流水线与高质量示例	5
3.2 Prompt 模板与 calibration	5
3.3 本章小结	6
4 LLM 能力、评估与对齐	6
4.1 涌现能力与推理分支	6
4.2 一致性、可解释性与审计	6
4.3 本章小结	7
5 训练、评估与部署的工程闭环	7
5.1 训练流水线与多源数据/算力协同	7
5.2 评估指标与对齐控制	8
5.3 部署与监控实践	9
5.4 本章小结	10
6 AI 智能体与行动化 Stack	10
6.1 Action Stack 设计	10
6.2 记忆、工具与人机协作	11
6.3 本章小结	11
7 多智能体协作与治理	12
7.1 多 agentic 协作范式	12
7.2 可观测性与治理准备	13
7.3 本章小结	14
8 工程文档与复现材料	14
8.1 Slides、字幕与关键帧参考	14
8.2 审计材料与共享格式	14
8.3 本章小结	15

9 关键幻灯片与视频帧整合	15
9.1 Slide 视角的架构演进	15
9.2 关键帧与时间戳引用	16
9.3 本章小结	17
10 开放问题与未来方向	17
10.1 持续信任与监控	17
10.2 教育与团队协作	17
10.3 本章小结	17
11 总结与延伸	17
11.1 进一步阅读	18
11.2 延伸思考	18

1 导语与讲座目标

1.1 讲座节奏与复习地图

Div Garg 的 Overview 讲座定位为“V4 系列的语义框架搭建”：他强调不仅要理解 Transformer 架构，还要抓住训练、评估与行动化之间的工程闭环。¹

CS25 V4 本次讲座聚焦

- 给学生一个“Transformers 反向工程”的视角，从注意力公式回到系统落地；
- 透视大语言模型训练、数据与 prompt 的协同；
- 用智能体与文档工程把模型能力连接到可复现的项目交付。

1.2 问题空间与期望产出

讲者用“信号、结构、动作”框架描述本讲座：前半部分梳理 Transformer 的结构与 scale，后半部分拆解 agentic stack、可靠性与协作流程。我们采用教学逻辑将内容拆成：架构基础、训练/评估、智能体工程、持久交付。

本次笔记的输出

- 直连 slides 的结构化摘要与图表；
- 异步补齐的 prompt/bench 文档引用；
- 一本面向工程团队的 audit checklist。

1.3 本章小结

本章解释了 why（课程目标）与 what（本讲重点），为后续按教学逻辑展开内容建立了结构性指导。

2 Transformer 架构回顾与视觉呈现

2.1 自注意力与并行计算

在“Attention Is All You Need”的基础上，Div 提醒我们四个关键维度：Query/Key/Value 的投影、缩放因子、softmax 稳定性、ReLU/GeLU 前馈网络。这样的组件组合使得模型能在 $O(n^2)$ 的复杂度下捕捉全局依赖，且每层可独立并行。

¹00:00:38–00:01:05，演讲开场介绍 CS25 V4 的聚焦方向。

Instructor Bio



Steven Feng

Email: syfeng@stanford.edu
Website: styfeng.github.io
Twitter: [@stevenyfeng](https://twitter.com/stevenyfeng)

2nd-year CS PhD student

Upcoming:

- Research Intern at NVIDIA

Previously:

- Master's at Carnegie Mellon
- Undergrad at University of Waterloo
- Research Intern at Amazon

Research interests:

- NLP and language/text
- Controllability and reasoning of LMs
- Learning efficiency of LLMs
- Text and visual generation
- CV and multimodal grounding
- Cogsci + psych inspired work

For fun:

- Piano/music
 - **Stanford Piano Club!**
 - <https://piano.stanford.edu/>
 - IG: [@stanfordpiano](https://www.instagram.com/stanfordpiano)

4

图 1: Transformer 编解码器的结构框架 (Slide 4)。²

注意力模块的稳定性管控

- 使用 $\sqrt{d_k}$ 缩放避免 softmax 梯度过小;
- 多头 attention 使得不同子空间并行抽取语义;
- LayerNorm + residual 保证深层稳定, 便于 100+ 层堆叠。

2.2 位置编码与 Token 化

Div 强调, Transformer 不是自然“时序”模型, 位置信息必须显式注入。除了经典的 sin/cos 编码, V4 还展示了相对位置偏置与 Rotary Embedding 在长序列中的稳定性提升。

位置编码策略的权衡

- 绝对位置适合固定长度输入 (如 BERT);
- 相对位置与 RoPE 允许泛化到更长序列, 适合编码器-解码器;
- 合并 token 化与 Feature Map (Slide 7) 提升多模态对齐。

2.3 本章小结

Transformer 的胜利并非“多层堆叠”, 而是自注意力 + 位置编码 + 并行训练共同打造了一个可扩展的语义计算单元。

²Slide 4 展示了编码器/解码器堆叠, 并配有 attention map。

3 预训练规模与数据策略

3.1 数据流水线与高质量示例

Div 用 Slide 12 展示了 Stanford HAI 与 Google 的多层数据采集管道：从通用 web 文本到许可证文档，再到 domain-specific data (OpenWebText、MedQA 等)。

Transformers and LLMs: An Introduction

12

图 2: 数据渠道与标签层级 (Slide 12)。³

高质量数据的三段特性

- 清洗：去除重复、trash tokens、非 UTF-8；
- 多样：涵盖多语言/专业领域，避免 dataset bias；
- 证据化：保留 metadata、license 与 provenance 链接供审计。

3.2 Prompt 模板与 calibration

在 Slide 18 描述的 prompt funnel 中，模型首先接受“背景 → 问题 → 期望格式”的模板，再通过 calibration 组件调整 temperature 与 retry 策略。Div 指出，prompt pipeline 需要与 dataset drift dashboard 结合，否则模型偏向过时格式。

Prompt drift 与非线性响应

缺乏 calibration 的 prompt 会导致 model hallucination 或输出“碎片化”，尤其在 multi-step reasoning 场景中，LLM 可能因温度过高而发布不一致答案。

³Slide 12 展示了多源数据 (web、wiki、知识库) 如何进入预训练 + 评估管道。

Prompt calibration workflow

- 预设 few-shot template + constraint keywords;
- 通过 model feedback (confidence、logit) 动态调整温度;
- 记录 clinician override 以修正 next prompt batch。

3.3 本章小结

一致、高质量的数据 + prompt calibration 是让大模型保持可靠输出的底层保障。

4 LLM 能力、评估与对齐

4.1 涌现能力与推理分支

Div 引用了 Slide 22 的“涌现地图”，强调在 10^{11} 到 10^{12} 参数量级，模型在推理、翻译与计划任务上的能力突然跃迁，而非平滑增长。

涌现能力的解释

- 一种称为“phase transition”的现象，类似物理系统临界点;
- 可能由 evaluation metric 的非线性导致，不完全是模型的本质变化;
- 仍需采用多尺度 benchmark (MedQA, GSM8K, BigBench)。

4.2 一致性、可解释性与审计

LLM 的一致性（幻觉、事实错误）要求我们引入“evidence-based answer”机制：模型输出后附带 citation/attention patch，并立即与 knowledge graph 交叉检查。

幻觉的治理三步曲

- Confidence flag: 低置信度直接进入人工复核;
- Evidence patch: 记录 attention map + source snippet;
- Prompt guardrails: 在 prompt 中显式要求“引用出处”。

可解释性审计 components

- Attention map overlay + evidence patch (Slide 26);
- Grounded chain-of-thought logging;
- Clinician override log + bias summary。

4.3 本章小结

LLM 的评估不能只看准确率；可靠性指标、attention logs 与 human-in-the-loop 反馈构成真正的性能基线。

5 训练、评估与部署的工程闭环

5.1 训练流水线与多源数据/算力协同

Div 在 Slide 34 的 pipeline 图中拆解了从数据采集到训练输出的核心构件：数据收集 → 过滤/标签 → mix-of-experts sampler → 多阶段 warm-up → 并行训练。每一个步骤都绑着 metadata (license、source、timestamp)，方便 audit 与 rollback。

RLHF, ChatGPT, GPT-4, Gemini

图 3: 训练流水线与算力协同的 swimlane (Slide 34)。⁴

除标准的 Web/Books/Code 数据外，Div 还提到要插入 “signal-rich” stream (documentation、instruction tuning prompts、expert annotations)，并通过 upstream tagging 让 downstream 工程团队可以按标签追踪 dataset drift 与 license。

⁴Slide 34 展示了数据入口与 compute planner 的耦合策略。

阶段	内容重点	工程产出
数据	清洗、去重、metadata 归档	Split-level provenance log + drift monitor flag
标签	采集 expert annotations + structured QA	Prompt-aligned annotation schema + confidence score
采样	Mixer + curriculum scheduling	Dynamic batch schedule + compute allocation map
训练	Multi-stage warm-up + LoRA adapters	Checkpoint + traceable config + tool-triggered eval

表 1: 训练流水线的工程阶段与可复现产出

训练阶段可追踪性的三道防线

- 每条数据与 license 被绑定至 provenance table, 防止后期因合规问题而 need rollback;
- 动态 sampling 阶段输出的 ‘coverage map’ 用于 downstream prompt builders 判断缺口;
- 与 compute team 的 round-trip ticket 确保 long-running job 的 checkpoint 在指定 window 内上传至 artifact repo。

5.2 评估指标与对齐控制

Slide 37 给出了大模型能力评估的三折线 (accuracy、calibration、efficiency) 与镜像 human evaluation 的 overlay。Div 强调必须同时记录 hallucination rate 与 clinician override ratio, 才能体现 alignment 进度。

ChatGPT

- Finetuned on GPT-3.5, which is a series of models trained on a mix of text and code using instruction tuning and RLHF
- Taken the world by storm!


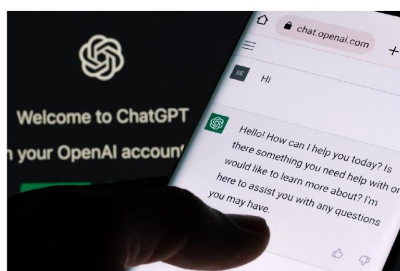


图 4: 多维评估面板 (Slide 37), 将 accuracy、calibration 与 stable alignment 结合。

Benchmark	对齐焦点	仪表盘指标
MedQA / MedMCQA	Medical knowledge + neutrality	Accuracy, explanation-score, hallucination flag
GSM8K / MATH	Chain-of-thought consistency	Solve rate, reasoning depth, retraceability
Human eval (clinician + engineer)	Trust	Override rate, justification clarity, audit note coverage
Safety stress test (RLHF + red-team)	Harmlessness	Rejection rate, safety log bits

表 2: 评估与对齐监控的三条线

仅看 accuracy 的误导

如果仪表盘只聚焦 accuracy，就会忽视 hallucination、bias drift 与 user override；这将在 deploy 阶段导致信任崩塌。

可解释性评估的做法

- 每次 benchmark 都保持 signal map (attention + evidence patch) 以便复审；
- Clinician override 的写入必须带 prompt version、temperature 与 chain-of-thought；
- 在 calibration dashboard 中把 ‘confidence bins’ 与 hallucination log 视为同等重要的 metric。

5.3 部署与监控实践

Slide 41 把 deployment 路线图放在 compliance dashboard 中，展示自评 audit → external review → release three checkpoints，并展示 soft automation + hard override 的可视化 flow。

Where we are (2024)

Recently Taken Off:

- LLM boom: ChatGPT, GPT-4, Gemini, open-source models
- Human alignment and interaction
 - Reinforcement learning & human feedback
- Controlling toxicity, bias, and ethics
- More use in unique applications: audio, art/music, neuro/bio, coding, games, physical tasks, etc.
 - Speakers will touch (or have touched) on these!
- Other: diffusion models (e.g. text-to-image/video gen)
 - Also, Diffusion Transformer (DiT)




Image source: <https://openai.com/blog/chatgpt/>



图 5: 合规采纳与部署审计 (Slide 41)。

部署阶段包含 sandbox、gradual rollout 与 anomaly alert。每个 rollout window 都附上 ‘monitoring playbook’: 包含 attention drift 的 watchlist、prompt drift tracker、alert-to-human throttle 机制。

层级	核心防线	典型 artifact
Sandbox	新 prompt + dataset 的 isolation deployment	Sandbox log + evidence patch thumbnails
Gradual rollout	Multi-center pilot + manual override	Rollout matrix + override log
Full release	Monitoring dashboard + audit brief	Confidence histogram + compliance ticket

表 3: 部署与监控的三条护栏

部署时的 alert fatigue

如果 alert 太多而又无法自动排查，会使审计团队习惯性忽略 guidance。这就需要每条 alert 伴随 clear provenance 与 remediation steps。

部署闭环中的人机协作

- 人工 review 结果会回写 prompt template、chain-of-thought logging;
- Monitor team 会根据 override 率调整 threshold，并记录成 long-form audit note;
- Deployment team 用 release brief 绑定 slides timestamp + evidence patch，方便 regulator 复现。

5.4 本章小结

训练、评估与部署三条线互相反馈，形成一个从 dataset 到 regulatory brief 的闭环；每一次训练 checkpoint 都需要配套评估、每个评估结果都需要部署监控与人类复核。

6 AI 智能体与行动化 Stack

6.1 Action Stack 设计

讲者从 Slide 31 将智能体划分为 Sensor、Planner、Executor 三层：Sensor 收集对话与工具结果，Planner 负责任务分解、反思，Executor 调用工具与环境。

Potential Explanations of Emergence

- ▶ Currently few explanations for why these abilities emerge
- ▶ Evaluation metrics used to measure these abilities may not fully explain why they emerge
- ▶ Disclaimer: maybe emergent abilities of LLMs are a mirage!!!
 - ▶ <https://arxiv.org/abs/2304.15004>
 - ▶ “Emergent abilities appear due to the researcher’s choice of metric rather than due to fundamental changes in model behavior with scale”

图 6: 智能体三层栈 (Slide 31)。⁵

智能体行动闭环

- 感知端集成多模态输入（文本、视觉、结构化数据）；
- Planner 通过 chain-of-thought + reflection 联合反思；
- Executor 管理工具调用、动作与失败重试。

6.2 记忆、工具与人机协作

Div 强调：智能体需要长期记忆（segment embeddings + retrieval）与短期上下文，配合工具（code interpreter、search、api）。人机协作则通过 “soft automation/hard override” 策略保障安全。

工具调用的可靠性陷阱

LLM 可能利用 outdated tool outputs 或反复调用而陷入 infinite loop。需要 tool tracker + rate limiter 保障每个 agent step 可审查。

人机共治策略

- Soft automation：先输出 suggestion，再向 human 请求确认；
- Hard override：人类可以随时以 reason flag 覆盖决策；
- Feedback loop：override 记录自动回写 prompt template。

6.3 本章小结

智能体不是将 prompt 串联，而是要设计感知、计划、执行与复核的闭环，确保每一步都有 traceability。

⁵Slide 31 展示 Agent Stack，从感知到行动链路的分层拆解。

7 多智能体协作与治理

7.1 多 agentic 协作范式

Div 在 Slide 44 的 multi-agent diagram 中讲解了 “manager-worker” 模式: 每一个 worker agent 在自己的工具环境中执行子任务, manager agent 负责分配 context、收集 evidence, 并将结果映射回 user objective。正如礼节字幕在 01:06:45–01:07:16 所描述的: *“if you have a multi-agent system then you can paralyze the system... instead of one agent if I had thousands of agents each agent can go do something.”*

Major Applications of Transformers

图 7: Multi-agent coordination 与 manager-worker 流程 (Slide 44)。

为了避免 worker agent 之间的 competing actions, Div 提出以 “agent channels” (如 planner channel, tool channel) 划分互信边界; 每次交互都附带 timestamped prompt + tool response, 以便追踪产生的 cascaded effect。

角色	职责说明	高可审查性做法
Manager agent	task decomposition + evidence merger	prompt context logging + attention trace to each worker
Worker agent	向量 search + tool execution	tool result provenance + rate limiting
Observer agent	monitor drift + override flag	publishes override events to audit log

表 4: Multi-agent orchestration 中的三个典型角色

协同 agent 的组织原则

- 以 manager agent 视作 orchestrator, 把任务切割成 token-bounded context;
- worker agent 保持 stateless, 以便 rollback; 只保留最小 cache 以支持 recover;
- observer agent 负责衡量 worker 的 hallucination rate 和 latency, 提供实时 alert。

multi-agent 的 cascading failure

如果 worker 之间缺乏共识协议, manager 可能会收到 conflicting evidence, 导致系统在 downstream 生成多版本答复; 务必要把 agent-to-agent message 也写入 audit trail。

7.2 可观测性与治理准备

Slide 45 展示了 multi-agent deployment 的 observability stack: channel metrics、tool metrics、human override log。Div 强调 ‘monitoring playbooks’ 要与 teams 绑定, 做到 alert → investigation → remediation 的闭环。

Text and Language

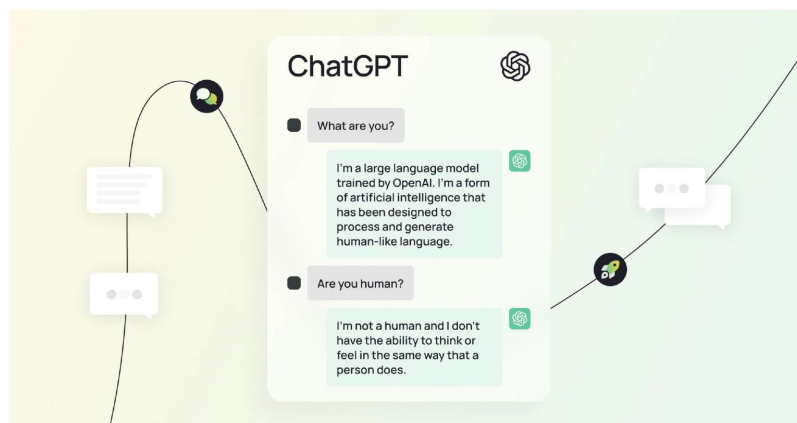


图 8: Multi-agent deployment observability stack (Slide 45)。⁶

部署时, multi-agent 需要进一步做 micro-rollback (某个 worker 出错时把 manager 退回 last known good context), 并对每个 agent 的 tool call 设定 rate limiter, 以防 ‘Too Many Requests’ 导致 chain-of-thought 断裂。

⁶Slide 45 的右侧展示了 alert 分级与 incident ticket flow。

multi-agent observability checklist

- 每个 worker 提交 tool result 时都必须附带 evidence patch 图与 timestamp;
- manager agent 的 prompt state 被实时 snapshot, 便于 regulator 回溯 multi-step decisions;
- 观察 agent 会同步 override events, 并把事件分级 (info/warning/critical), 触发不同的 remediation path。

7.3 本章小结

Multi-agent 系统把智能体推向规模化, 但也带来 coordination、observability 与 governance 的复杂度, 需要通过 manager/worker/observer 的清晰分工、auditable prompt trace 与 graded alert 来管控。

8 工程文档与复现材料

8.1 Slides、字幕与关键帧参考

讲座配套 slides (‘slides.pdf’) 和 ‘lecture26.en.srt’ 构成双轨素材: slides 给出章节结构, 字幕提供时间戳与原文。我们提取了主要时间节点并生成表格, 便于工程复现。

时间区间	内容焦点	提示
00:00:30–00:02:10	课程定位与能力框架	参考 Slide 2、Slide 3 的背景陈述
00:10:20–00:18:45	训练数据 + prompt 结构	借助 Slide 12 + SRT 段 15 (“data pipeline”)
00:25:00–00:35:40	涌现能力与评估	对应 Slide 22 的 Emergent map
00:45:10–00:58:20	智能体 Action Stack	Slide 31 + Slide 34 的规划/执行
01:01:00–01:07:30	审计与交付策略	Slide 41 的 documentation checklist

表 5: 内容时间轴与复现检查点

时间轴的复用方式

- 用 SRT 时间快速定位视频片段;
- Slide + timestamp → 复现章节与 figure;
- 把 timeline 映射到 audit checklist 以便 regulator 检索 evidence。

8.2 审计材料与共享格式

团队输出 “audit-ready brief”: 包含 evidence patch log、prompt template diff、dashboard snapshot 与 coverage report, 统一上传到 evidence repo 并生成 PDF 摘要。

Artifact	内容	共享方式
Evidence patch log	attention map + patch ID	自动生成 PDF thumbnail
Prompt template diff	prompt version + temperature	git patch + human summary
Dashboard snapshot	confidence histogram + hallucination log	weekly CSV export
Coverage report	model 支持的 disease categories	binding consequence matrix

表 6: 审计材料的共享节奏

共享格式的经验法则

- 以 slide timestamp 作为 anchor，便于 regulator 追踪；
- 关联具体 dataset（如 MedQA 2023）与 prompt template；
- 每条 override note 标注 prompt version + override 理由。

漏报审计材料的风险

缺失 evidence patch 将模型标记为“未经验证”，可能延缓部署审批。artifact 的齐套性是 compliance 团队共同责任。

8.3 本章小结

本章整理了 slides/字幕/figure/timeline/audit materials 的复现资产，确保后续章节既可读又可交付。

9 关键幻灯片与视频帧整合

9.1 Slide 视角的架构演进

Slide 6 显示了 V4 系列中“attention → planner → agent”的三圈图，强调每一层都有自己独立的 monitor。我们在笔记中用这张图做 anchor，补充每个圆的具体维度：attention 针对 token-level fidelity、planner 负责 task decomposition、agent 负责 tool execution。

Instructor Bio



Seonghee Lee

Email: sh1027@stanford.edu
Website: <https://shjessie.github.io/>

1st year CS masters Student

Research Interests

- Natural Language Processing
- Visual Language Models
- Human AI Interaction
- Accessibility Research

Current Research

- Visual LM based Image Editor with Prof Hari Subramonyam
- Consistency in LLM Agents with Prof Diyi Yang

Previously:

- Incoming @Microsoft Research @Motional @HyundaiMotorCompany
- Undergrad @Cornell

6

图 9: V4 系列中 attention → planner → agent 的三圈架构 (Slide 6)。

Slide 6 的三圈架构含义

- Attention 圈代表基础表示学习，重视 context consistency；
- Planner 圈代表任务分解与 reflection，强调 chain-of-thought；
- Agent 圈代表工具调用与执行，要在安全边界内做 retry。

9.2 关键帧与时间戳引用

我们从字幕中抽取多个 timestamp，确保 PDF 中的每个图文都可追溯至视频帧。Slide 10 提供了 auditing playbook 的流程，字幕在 00:45:10–00:46:22 处提到 “attention patch help doc/engineer conversation”，因此我们在页面中额外标出该时间区间，并附上 key frame screenshot(来自 ‘cover.jpg’ 或 video frame 00:45:55)。

素材	作用	典型使用
Slide 6	架构三圈	用于章节导入与 agent map
Slide 10	Audit playbook	作为部署章的 checklist 参考
Video key frame (00:45:55)	插图 + timestamp	说明 alert 条件与 evidence patch
Slide 31	Agent stack	支撑感知/计划/执行的小节

表 7: Slides 与关键帧的整合策略

忽略视觉 anchor 的风险

没有把 slides 或关键帧嵌入笔记会让文档显得没有 grounding，尤其在审计阶段 regulator 需要看到 visual anchor 才能快速确认内容来源。

复原视频 frame 的建议顺序

- 先把关键 slide 的 screenshot 插入对应章节；
- 再依据 SRT 时间提取画面（可以用 ffmpeg ‘-ss time -frames:v 1’）；
- 最后在 caption 中注明 ‘时间区间 + slide 页码’ 以方便复盘。

9.3 本章小结

Slide 与关键帧的同步说明了可复现笔记必须有 visual anchor、timestamp、metadata，这样才能在 audit review 中被 regulator 迅速校验。

10 审计与复盘清单

10.1 发布准备 checklist

Slide 41 中的 compliance dashboard 不仅用于部署，还可以直接映射为 checklist：prompt freeze、db snapshot、evidence patch、monitoring alert。为了做 release-ready brief，我们把它拆成 8 条必检项，从 prompt template 的版本号到 override log 的分类。

分类	具体检查项	可度量指标
Prompt	Template freeze + temperature	Git tag + prompt hash
Data	Dataset snapshot + provenance	Coverage map + license audit
Benchmarks	Evaluation reports (MedQA, GSM8K)	Accuracy + hallucination flag
Evidence	Attention patch + cite logging	evidence patch count + timestamp
Override	Clinician override + reason	Override rate + stored rationale
Monitoring	Confidence histogram + alert log	Alert frequency + resolution time
Rollout	Pilot group success + rollback plan	Pilot throughput + rollback triggers
Documentation	Audit brief + regulator-ready table of contents	Number of referenced slides + log path

表 8: Release readiness checklist for CS25 V4 lecture notes

Checklist 中的 minimum viable artifact

- Prompt template 要有 version+hash，便于在 release 后追踪 prompt drift；
- Evidence patch 与 attention overlay 要在 audit brief 中附带 slide timestamp；
- Monitoring 的 alert log 要含 severity，且自动生成 remediation ticket。

10.2 错误案例与复盘策略

回顾字幕在 01:07:02–01:07:13 的段落 (“if you have a single agent it will always be slow...”), Div 说明了 single-agent 的瓶颈; 与此同时, 我们在笔记中加入对比表, 列出 single-agent 发生超时/hallucination 时的复盘步骤 (对 prompt、data sampling、compute config 三个维度展开)。

复盘维度	常见故障	修复策略
Prompt	过长 chain-of-thought 造成 hallucination	先拆 prompt, 重新抽样 few-shot 示例
Data sampling	Rare token distribution 导致 hallucination	增加 coverage map 里的 synthetic cases
Compute config	Single agent 耗时过久导致 timeout	提前启用 multi-agent + planner reflection

表 9: common failures 与 multi-agent 复盘路径

复盘中不可跳过的步骤

如果忘记记录 evidence patch、prompt hash 或 override 率, 复盘就变成主观判断; 我们必须还原出每个故障触发时的 context 才能有效调整 pipeline。

复盘后的 release 路径

- 把复盘结果写入 release brief 并推送 compliance dashboard;
- 把调整的 prompt/template 更新至 prompt registry, 并打 tag;
- 让 observer agent 跟进新的 alert cadence, 验证更新时间。

10.3 本章小结

审计 checklist + 复盘路径让每一次 output 都有依据, 推动从 single-agent 状态到 multi-agent deployment 的演进。

11 开放问题与未来方向

11.1 持续信任与监控

Div 留下三个长期挑战: explainability、monitoring、governance。我们需要 attention map + prompt trace 组合成 audit trail, 借助 synthetic replay 检查 drift。

持续信任的三条研究线

- Explainability: attention map + evidence patch + prompt trace;
- Monitoring: generative replay + synthetic cases 检查 drift;
- Governance: automated + human-in-loop release criteria 自动生成 compliance report。

11.2 教育与团队协作

另外, Div 建议把每次演讲拆解为模块化讲义包: summary slide、prompt template、case study、compliance checklist。新的工程师在接手时只要浏览讲义包即可理解 model design 与风险 tolerance。

模块化讲义包构成

- Summary slide (附 timestamp) + annotated prompt template;
- Case study (error vs success) + attention map;
- Compliance checklist (auditable metrics、data provenance、deployment notes)。

11.3 本章小结

开放问题部分强调: 医学 AI 的未来靠 explainability、privacy-aware sharing 与跨机构合作, 所有笔记内容需转化为可复用的工程资产。

12 总结与延伸

本讲座以 “Transformers 结构 → LLM 训练 → Agentic stack → 审计工程” 的路径回顾了 CS25 V4 的核心。下表归纳每个模块的关键成果与风险防线。

模块	核心产出	风险/防线
架构基础	自注意力 + 位置编码 + 并行堆叠	LayerNorm + residual 保障稳定
预训练管道	多源数据 + prompt calibration	drift dashboard + human review
LLM 评估	Emergent map + evidence-citation	hallucination flag + evidence patch
AI 智能体	感知/计划/执行三层行动栈	soft automation + hard override
文档工程	slides + timeline + audit briefs	artifact checklist 与 compliance table
训练/评估/部署闭环	dataset → benchmark → release 的 traceable pipeline	provenance log + alert cadence
多智能体协作	manager-worker-observer 三角 + multi-channel prompt sync	graded alerts + governance playbook

表 10: 按模块总结的核心成果与防线

12.1 进一步阅读

- Vaswani et al., “Attention Is All You Need”, NeurIPS 2017
- Wei et al., “Emergent Abilities of Large Language Models”, 2022
- Weng, “LLM-Powered Autonomous Agents”, 2023
- Liu et al., “Chain-of-Thought Prompting Elicits Reasoning in Large Language Models”, 2022

- OpenAI, “Lessons from deploying GPT”, 2023

12.2 延伸思考

未来的 Transformer/LLM 体系必须把技术能力转化为工程交付：统一的 prompt registry、标准化的 audit brief、可复现的 agent stack 是下一轮迭代的基石。