

课程笔记

[CS25 V4] Transformer 概览 — Div Garg 等（课程讲师）

基于公开课程资料整理

Spring 2024



视频作者/频道: Stanford CS25: Transformers United

发布日期: Spring 2024

视频时长: ~1h

项目主页: <https://github.com/hqhq1025/ai-course-notes>

目录

1 引言：CS25 课程背景	2
2 注意力机制与 Transformer 架构	2
2.1 从 RNN 到注意力	2
2.2 多头注意力	2
2.3 本章小结	2
3 大语言模型与涌现能力	2
3.1 训练范式与涌现	2
3.2 小模型的潜力	3
3.3 本章小结	3
4 AI 智能体	3
4.1 为什么需要智能体	3
4.2 智能体自主等级	3
4.3 记忆与个性化	3
4.4 多智能体通信	3
4.5 本章小结	3
5 其他前沿方向	4
6 总结与延伸	4
6.1 拓展阅读	4

1 引言：CS25 课程背景

CS25 “Transformers United” 是斯坦福大学的研讨课程，每周邀请 AI 领域顶尖研究者分享前沿进展。第四期（V4, Spring 2024）由 Div Garg、Steven Feng、Emily Bunnapradist 和 Seonghee Lee 四位讲师联合主讲。本次开场讲座全面回顾 Transformer 的发展历程，并展望大语言模型时代的前沿方向。

课程定位

CS25 旨在将 Transformer 与大语言模型的最新研究直接呈现给学生，涵盖 NLP、计算机视觉、生物、机器人等多领域应用。

2 注意力机制与 Transformer 架构

2.1 从 RNN 到注意力

传统 RNN/LSTM 的三大局限：难以捕获长距离依赖、梯度消失/爆炸、无法并行化。2017 年 “Attention Is All You Need” 提出的 Transformer 彻底解决了这些问题。

注意力机制核心公式

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Q (Query)、 K (Key)、 V (Value) 分别由输入通过可学习矩阵投影得到； d_k 为键向量维度。

2.2 多头注意力

多头注意力在不同子空间中并行捕捉不同类型的语义关系。Transformer 通过堆叠多层自注意力和前馈网络来学习层次化表示。

2.3 本章小结

Transformer 通过自注意力实现全局依赖建模和高效并行计算，奠定了当代深度学习的架构基础。

3 大语言模型与涌现能力

3.1 训练范式与涌现

LLM 将 Transformer 扩展到数十亿参数，在海量文本上进行下一个 token 预测训练。随着规模增大，模型展现出“涌现能力”——在小模型中不存在但在大模型中突然出现的能力。

涌现能力

涌现能力表现为“相变”式的性能跃迁，难以预测。但也有研究（Stanford, 2023）认为涌现可能是评估指标非线性的产物而非模型本身的根本变化。

3.2 小模型的潜力

微软 Phi-2 (2.7B 参数) 通过“教科书级”高质量数据, 在推理任务上挑战了大 25 倍的模型, 证明数据质量可以部分替代模型规模。

3.3 本章小结

LLM 的成功源于规模化, 但数据质量、训练损失与下游表现之间的关系才是更本质的。

4 AI 智能体

4.1 为什么需要智能体

单次 LLM 调用远远不够。通过构建包含记忆、规划、工具使用和行动能力的 AI 系统, 可以解锁更复杂的应用。

智能体四要素

记忆 (短期/长期)、**规划** (任务分解、反思)、**工具使用** (计算器、搜索、代码执行)、**行动** (在数字/物理环境中执行操作)。

4.2 智能体自主等级

类比自动驾驶 L0-L5 分级: L0-L2 人类主控, L3 人类监督、智能体执行, L4-L5 完全自主。当前大部分智能体处于 L2-L3。

可靠性挑战

智能体最大问题是可靠性——LLM 是随机函数, 可能以 ϵ 概率做出意外行为。循环和计划偏离是常见问题。

4.3 记忆与个性化

将 AI 模型类比为“神经计算单元”: 输入 token、输出 token。可借鉴计算机架构设计智能体的记忆系统——通过向量嵌入实现存储与检索。个性化则需要构建长期用户记忆。

4.4 多智能体通信

多智能体系统通过并行化和专业化提升效率, 但自然语言通信天然有损。需要建立类似 HTTP 的标准化协议来可靠传输信息。

4.5 本章小结

AI 智能体是从“对话式 AI”到“行动式 AI”的范式转变, 可靠性和安全性仍是核心挑战。

5 其他前沿方向

讲座还涉及：思维链推理（Chain-of-Thought）、可解释性、幻觉问题、持续学习、RLHF 与对齐等。

6 总结与延伸

本讲全景式地回顾了 Transformer 的发展脉络：注意力机制 → 大语言模型 → AI 智能体。核心信息：简单架构 + 规模化数据与计算 = 强大模型；将模型能力转化为行动需要智能体框架；可靠性、可解释性和持续学习是通向 AGI 的关键挑战。

6.1 拓展阅读

- Vaswani et al., “Attention Is All You Need”, 2017
- Wei et al., “Emergent Abilities of Large Language Models”, 2022
- Lilian Weng, “LLM Powered Autonomous Agents”, 2023