


课程笔记

[CS25] Aligning Open Language Models

— Nathan Lambert

基于公开课程资料整理

Spring 2024



视频作者/频道: Stanford CS25: Transformers United

发布日期: Spring 2024

视频时长: ~1h

视频链接: 项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1 引言：后 ChatGPT 时代的对齐故事	2
2 自回归语言模型基础	2
2.1 自回归损失函数	2
2.2 预训练 → 微调 → 对齐	2
2.3 本章小结	2
3 ChatGPT 时代的开源爆发	2
3.1 时间线	2
3.2 本章小结	3
4 RLHF 的实践	3
4.1 奖励模型训练	3
4.2 PPO 训练的挑战	3
4.3 DPO 及其变体	3
4.4 本章小结	3
5 评估的困境	4
5.1 评估不是已解决的问题	4
5.2 Chatbot Arena	4
5.3 本章小结	4
6 合成数据与未来方向	4
7 总结与延伸	4
7.1 拓展阅读	4

1 引言：后 ChatGPT 时代的对齐故事

Nathan Lambert 是 Allen Institute for AI (AI2) 的研究科学家，专注于 RLHF 和开放语言模型对齐。本讲以 ChatGPT 发布为分水岭，系统回顾了开源社区在对齐领域的快速进展。

从 Claude Shannon 到 ChatGPT

语言模型的思想可追溯到 Claude Shannon 的字符级序列预测。Anthropic 将其模型命名为 Claude 正是致敬这一渊源。从 Shannon 到 GPT-4，核心思想始终是自回归损失函数。

2 自回归语言模型基础

2.1 自回归损失函数

$$\mathcal{L} = - \sum_{t=1}^T \log P(x_t | x_{<t}; \theta)$$

给定训练样本 “the cat sat on”，模型学习预测每个位置的下一个 token。这个简单的损失函数在足够大的数据和模型上产生了惊人的能力。

2.2 预训练 → 微调 → 对齐

现代 LLM 训练三阶段

1. **预训练**：在互联网文本上学习通用语言表示
2. **监督微调 (SFT)**：在指令-响应对上学习遵循指令
3. **对齐 (RLHF/DPO)**：根据人类偏好进一步优化

2.3 本章小结

简单的自回归目标是一切的基础，后续的 SFT 和对齐都是在此基础上的精细化调整。

3 ChatGPT 时代的开源爆发

3.1 时间线

- 2022.11: ChatGPT 发布
- 2023.02: LLaMA 开源，开启开源 LLM 时代
- 2023.03: Alpaca (Stanford)、Vicuna 等开源对齐模型涌现
- 2023.04: Open Assistant 众包数据集
- 2023.07: LLaMA 2 + RLHF
- 2024.04: LLaMA 3, 接近 GPT-4 水平

开源追赶闭源

Google 内部泄露的备忘录预测：“我们没有护城河，OpenAI 也没有。” 开源社区通过数据工程和对齐技术快速缩小了与闭源模型的差距。LLaMA 3 70B Instruct 的性能已接近 GPT-4。

3.2 本章小结

ChatGPT 之后，开源社区在不到两年内实现了惊人的追赶。

4 RLHF 的实践

4.1 奖励模型训练

奖励模型是对齐的核心

奖励模型学习预测人类偏好：给定 prompt 和两个回答，预测哪个更好。训练数据来自人类标注员的偏好对比。奖励模型的质量直接决定 RLHF 的上限。

4.2 PPO 训练的挑战

PPO 训练不稳定

PPO (Proximal Policy Optimization) 在 RLHF 中的应用面临多个挑战：

- 四个模型需要同时在内存中（策略、参考策略、奖励模型、价值网络）
- 超参数敏感——KL 系数、学习率需要精心调节
- 奖励黑客 (Reward Hacking) ——模型学会“欺骗”奖励模型而非真正改善质量
- 训练成本高，需要大量 GPU 资源

4.3 DPO 及其变体

DPO (Direct Preference Optimization) 通过重新参数化消除了显式奖励模型的需要：

$$\mathcal{L}_{\text{DPO}} = -\mathbb{E} \left[\log \sigma \left(\beta \log \frac{\pi_{\theta}(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \beta \log \frac{\pi_{\theta}(y_l|x)}{\pi_{\text{ref}}(y_l|x)} \right) \right]$$

DPO 的优势与局限

优势：训练简单、稳定、内存占用小。

局限：在某些评估上不如 PPO；可能过拟合偏好数据中的表面模式。

实际中，DPO 和 PPO 各有适用场景，社区仍在探索最佳实践。

4.4 本章小结

RLHF 有效但复杂，DPO 提供了更简便的替代方案。

5 评估的困境

5.1 评估不是已解决的问题

对齐评估缺乏可靠信号

预训练阶段有 MMLU、HellaSwag 等相对稳定的基准；但对齐评估缺乏类似的“黄金标准”。MT-Bench 和 AlpacaEval 有用但有偏差。Open LLM Leaderboard 成功的原因恰恰是因为“有一点信号总比没有好”，而非评估本身很可靠。

5.2 Chatbot Arena

LMSYS 的 Chatbot Arena 通过众包 ELO 评分提供了最接近真实用户偏好的信号，但样本量和人群偏差仍是问题。

5.3 本章小结

评估是对齐研究的最大瓶颈，目前没有完美方案。

6 合成数据与未来方向

- **合成数据生成**：使用 LLM 生成更多训练 token，缓解数据稀缺
- **Self-play**：模型与自身对弈进行训练（如 OpenAI 的超级对齐方向）
- **过程奖励**：不仅奖励最终答案，还奖励推理过程中的每一步

7 总结与延伸

本讲从历史视角全面审视了语言模型对齐的现状。核心教训：(1) 简单的自回归目标 + 规模化是基础；(2) 对齐技术（SFT/RLHF/DPO）是将原始能力转化为有用行为的桥梁；(3) 评估仍然是最大痛点；(4) 合成数据可能是下一个突破口。

7.1 拓展阅读

- Lambert et al., “RLHF Workflow: From Reward Modeling to Online RLHF”, 2024
- Rafailov et al., “Direct Preference Optimization”, 2023
- Touvron et al., “LLaMA 2: Open Foundation and Fine-Tuned Chat Models”, 2023
- Interconnects Blog: <https://www.interconnects.ai>