

课程笔记

[CS25] Near-Shallow Architectures — Jake Williams

五道口纳什 & Codex

2026 年 3 月 29 日



视频作者/频道: Stanford CS25: Transformers United

发布日期: Spring 2024

视频时长: ~1h

视频链接: 未填写

目录

1	引言：计算语言学视角	2
2	重新审视自注意力	2
2.1	标准自注意力的问题	2
2.2	自注意力前馈单元 (SAFU)	2
2.3	本章小结	2
3	初始化与小数据效率	3
3.1	去除随机化的影响	3
3.2	上下文建模	3
3.3	本章小结	3
4	与主流架构的对比	3
4.1	理论优势	3
4.2	实际挑战	3
4.3	本章小结	3
5	总结与延伸	3
5.1	拓展阅读	4

1 引言：计算语言学视角

Jake Williams 是 Drexel 大学信息科学系副教授，具有物理学和数学背景。他的研究从计量语言学 (Quantitative Linguistics) 角度切入，运用数学和统计方法分析语言现象。本讲介绍了一种“近浅层” (Near-Shallow) Transformer 架构——SAFU (Self-Attentive Feed-forward Unit)。

计量语言学视角

计量语言学关注语言的统计规律（如 Zipf 定律），将语言视为一种可量化分析的现象。这种视角为重新思考 Transformer 架构提供了独特的理论框架。

2 重新审视自注意力

2.1 标准自注意力的问题

标准 Transformer 中，每一层的自注意力都需要在当前层的动态表示上计算 QK^T ，复杂度为 $O(n^2d)$ 。Williams 提出了一个关键观察：

静态词嵌入的预计算优势

如果词嵌入是静态的（即不随层变化），那么 token 之间的注意力权重可以预计算并缓存。这将自注意力的成本从二次降至线性——因为不需要在每次前向传播时重新计算向量比较。

2.2 自注意力前馈单元 (SAFU)

SAFU 的核心设计思想：

1. 使用静态（或近静态）词嵌入
2. 预计算注意力权重矩阵
3. 推理时直接从缓存加载权重，无需实时计算
4. 前馈层仍正常训练和运行

推理效率提升

由于注意力权重可以预计算，SAFU 模型在推理时：

- 不需要为嵌入层追踪梯度
- 不需要在线计算向量比较
- 内存和计算成本大幅降低

训练成本也部分降低，因为嵌入层更新频率可以大幅减少。

2.3 本章小结

SAFU 通过分离“静态比较”和“动态变换”两个功能，在概念上简化了自注意力机制。

3 初始化与小数据效率

3.1 去除随机化的影响

好的初始化胜过大数据

Williams 发现，当使用预计算的注意力权重（消除随机初始化的影响）时，即使在小数据上训练，SAFU 模型也能表现出不错的效果。这挑战了“必须用海量数据训练 Transformer”的假设。

3.2 上下文建模

注意力窗口 vs 块大小

标准 Transformer 使用固定的注意力窗口或序列长度。SAFU 探索了动态块大小：根据文档自然边界而非固定长度来分割序列。这保留了真实的上下文模型，而非人为截断。打包 (Packing) 策略虽然高效，但破坏了原始的上下文关系。

3.3 本章小结

SAFU 在小数据和推理效率方面展现了潜力，但需要更多大规模实验验证。

4 与主流架构的对比

4.1 理论优势

- 推理时自注意力成本从 $O(n^2)$ 降至 $O(n)$ （因为预计算）
- 训练时部分成本降低（嵌入层更新频率低）
- 对小数据更友好

4.2 实际挑战

- 尚未在大规模数据上充分验证
- 评估基础设施需要从头搭建（不能直接复用 GPT-2 等标准评估框架）
- 静态嵌入假设可能限制模型的表达能力

4.3 本章小结

SAFU 是一个有趣的研究方向，但距离实用仍有距离。

5 总结与延伸

本讲提供了一种非主流但启发性的视角来重新思考 Transformer 架构。核心洞察：自注意力中“比较”和“变换”的功能可以解耦；静态嵌入可以大幅降低推理成本。这些思想可能在特定应用场景（如边缘设备、延迟敏感任务）中发挥价值。

5.1 拓展阅读

- Williams, “Self-Attentive Feed-forward Units in Near-Shallow Architectures” (预印本)
- Zipf, “Human Behavior and the Principle of Least Effort”, 1949
- Vaswani et al., “Attention Is All You Need”, 2017