


课程笔记

[CS25] From LLMs to Multimodal Models — Ming Ding, Zhipu AI

五道口纳什 & Codex

2026 年 3 月 29 日



视频作者/频道: Stanford CS25: Transformers United

发布日期: Spring 2024

视频时长: ~1h

视频链接: 未填写

目录

1 引言：从大语言模型到多模态	2
2 大语言模型发展简史	2
2.1 为什么 LLM 能成功	2
2.2 预训练实践技巧	2
2.3 本章小结	2
3 多模态理解：视觉-语言模型	2
3.1 主流架构范式	2
3.2 CogVLM	3
3.3 GLM-4V 的简化架构	3
3.4 CogAgent: GUI 智能体	3
3.5 本章小结	3
4 多模态生成：文生图与文生视频	3
4.1 CogView 系列	3
4.2 CogVideo	3
4.3 扩散模型 vs 自回归模型	4
4.4 本章小结	4
5 物理世界理解	4
6 总结与延伸	4
6.1 拓展阅读	4

1 引言：从大语言模型到多模态

Ming Ding (丁铭) 是智谱 AI (Zhipu AI) 的研究科学家，清华大学博士。他领导或参与了多个多模态模型研究，包括 CogView (文生图)、CogVideo (文生视频)、CogVLM (视觉语言模型) 和 CogAgent (GUI 智能体)。本讲从 LLM 发展史出发，全面介绍多模态模型的技术路线。

2 大语言模型发展简史

2.1 为什么 LLM 能成功

LLM 成功的三大支柱

1. **Transformer 架构**：并行计算 + 全局注意力
2. **规模化 (Scaling Laws)**：更大的模型 + 更多数据 = 更好性能
3. **自回归预训练目标**：简单但通用的下一个 token 预测

2.2 预训练实践技巧

大模型训练的工程挑战

训练百亿级参数模型需要：

- 数据并行 + 张量并行 + 流水线并行 (3D 并行)
- 混合精度训练 (FP16/BF16 + FP32 主参数)
- 梯度检查点 (节省显存，以计算换空间)
- 仔细的学习率调度和热身策略

2.3 本章小结

LLM 的成功建立在简洁架构与工程规模化的结合之上。

3 多模态理解：视觉-语言模型

3.1 主流架构范式

当前视觉-语言模型 (VLM) 的主流架构：

1. 视觉编码器 (如 ViT) 提取图像特征
2. 投影层将视觉特征映射到语言模型的嵌入空间
3. 大语言模型处理文本和视觉 token 的混合序列

3.2 CogVLM

CogVLM 的关键创新

CogVLM 在 Transformer 的每一层为视觉 token 引入独立的 QKV 参数 (视觉专家), 而非简单地将视觉特征投影到语言嵌入空间。这种“深度融合”使视觉信息在每一层都被充分处理, 而不仅仅在输入层。

3.3 GLM-4V 的简化架构

高分辨率输入的处理

智谱最新的 GLM-4V 采用了更简洁的架构——类似 LLaVA, 但用步幅卷积 (stride convolution) 替代线性投影来处理高分辨率输入。这在保持简洁性的同时支持了更精细的视觉理解, 特别在 OCR 相关任务上表现突出。

3.4 CogAgent: GUI 智能体

CogAgent 是一个能操作计算机界面的视觉智能体: 输入屏幕截图, 输出操作指令 (点击、输入文本等)。

- 输入: 屏幕截图 + 自然语言任务描述
- 输出: 具体的界面操作序列
- 应用: 自动化网页操作、表单填写、信息检索

3.5 本章小结

VLM 架构正在从复杂走向简洁, 深度融合和高分辨率处理是关键技术方向。

4 多模态生成: 文生图与文生视频

4.1 CogView 系列

CogView 是中国最早的大规模文生图模型之一, 基于自回归 Transformer 架构。随后的版本逐步转向扩散模型 (Diffusion Model)。

4.2 CogVideo

文生视频的核心挑战

视频生成比图像生成难得多:

- 时间一致性: 帧间必须连贯
- 计算成本: 视频序列长度远大于单张图像
- 物理真实性: 物体运动应符合物理规律

CogVideo 通过时间注意力机制和帧间差分编码来保持时间一致性。

4.3 扩散模型 vs 自回归模型

两种生成范式

自回归：逐 token 生成，天然适合文本，但用于图像/视频时序列过长。

扩散：从噪声逐步去噪，适合连续信号（图像、视频），但不擅长离散符号。

当前趋势是融合两者：用自回归模型处理离散部分（文本指令），用扩散模型处理连续部分（图像/视频）。

4.4 本章小结

多模态生成正在从纯文本扩展到图像和视频，扩散模型成为主要范式。

5 物理世界理解

当前多模态模型的局限

现有的图像/视频理解模型本质上是在处理标注过的数据。对于未标注的海量视频数据（蕴含丰富的物理世界知识），我们缺乏有效的自监督学习方法来提取知识。这是通向真正的物理世界理解的关键瓶颈。

6 总结与延伸

本讲全景展示了从 LLM 到多模态模型的技术演进路线。核心观点：(1) VLM 架构趋向简洁，深度融合是关键；(2) 视频生成的时间一致性仍是开放问题；(3) 从未标注视频中学习物理世界知识是下一个前沿。

6.1 拓展阅读

- Ding et al., “CogView: Mastering Text-to-Image Generation via Transformers”, NeurIPS 2021
- Wang et al., “CogVLM: Visual Expert for Pretrained Language Models”, 2023
- Hong et al., “CogAgent: A Visual Language Model for GUI Agents”, 2023
- Hong et al., “CogVideo: Large-scale Pretraining for Text-to-Video Generation”, 2022