

课程笔记

[CS25] New Training Objectives — Hyung Won Chung, OpenAI

基于公开课程资料整理

Spring 2024



视频作者/频道: Stanford CS25: Transformers United

发布日期: Spring 2024

视频时长: ~40min

视频链接: 项目主页: <https://github.com/hqhq1025/ai-course-notes>

目录

1 引言：从历史中学习未来	2
2 指数驱动力：计算能力的增长	2
2.1 摩尔定律与 GPU 革命	2
2.2 规模化与苦涩教训	2
2.3 本章小结	2
3 归纳偏置的生命周期	2
3.1 什么是归纳偏置	2
3.2 添加容易、移除困难	3
3.3 本章小结	3
4 Encoder-Decoder vs Decoder-Only 的历史分析	3
4.1 原始 Transformer (2017)	3
4.2 BERT 的选择 (2018)	3
4.3 GPT 的选择 (2018)	3
4.4 为什么 Decoder-Only 最终胜出	3
4.5 本章小结	4
5 对当前趋势的审视	4
5.1 当前的“捷径”	4
5.2 硬件协同设计	4
5.3 本章小结	4
6 总结与延伸	4
6.1 拓展阅读	4

1 引言：从历史中学习未来

Hyung Won Chung 是 OpenAI ChatGPT 团队的研究科学家，此前在 Google Brain 工作。他的代表作包括 Flan-T5/PaLM（大规模指令微调）和 T5X（PaLM 的训练框架）。本讲不讨论具体的新训练目标，而是通过分析 Transformer 架构的历史演变，建立一个“统一视角”来理解和预测 AI 研究的趋势。

核心论点

AI 进步的根本驱动力是指数级增长的计算能力。理解这一驱动力，可以帮助我们看清看似无关的技术事件之间的深层联系，并据此推断未来方向。

2 指数驱动力：计算能力的增长

2.1 摩尔定律与 GPU 革命

计算成本的指数下降

从 1970 年代至今，计算成本以指数速度下降。GPU 的出现进一步加速了这一趋势——NVIDIA GPU 的 FLOPS/\$ 每两年翻一番。这种指数增长是 AI 研究所有重大进展的底层驱动力。

2.2 规模化与苦涩教训

这一指数驱动力正是 Rich Sutton “苦涩教训”（The Bitter Lesson）的物质基础：能够充分利用更多计算的通用方法（搜索、学习），最终总会超越依赖人类领域知识的方法。

2.3 本章小结

理解指数驱动力是建立统一视角的前提。

3 归纳偏置的生命周期

3.1 什么是归纳偏置

归纳偏置

归纳偏置是我们在数据或计算不足时，人为加入模型的结构性假设。例如：

- 卷积 = “局部性”假设
- 双向注意力 = “可以看到全部输入”假设
- 掩码语言模型 = “可以并行训练所有位置”假设

这些假设在资源有限时是有益的捷径，但在资源充足时反而限制了模型的通用性。

3.2 添加容易、移除困难

学术界的激励不对称

学术界擅长“添加结构”——提出新的归纳偏置可以发论文。但“移除结构”（证明某个假设已不再需要）缺乏发表激励。这导致许多过时的归纳偏置在研究中存留过久。Chung 呼吁社区更多关注“减法研究”。

3.3 本章小结

归纳偏置有其最佳适用期，及时移除与及时添加同样重要。

4 Encoder-Decoder vs Decoder-Only 的历史分析

4.1 原始 Transformer (2017)

原始 Transformer 使用 encoder-decoder 架构用于机器翻译：

- **编码器**： N 层双向自注意力 + 前馈网络
- **解码器**： N 层因果自注意力 + 交叉注意力 + 前馈网络
- **连接**：交叉注意力让解码器关注编码器的输出

4.2 BERT 的选择 (2018)

BERT 只用编码器 + 双向注意力 + 掩码语言模型 (MLM) 目标。当时双向注意力确实更强：能看到完整上下文，训练效率高（每个位置独立预测）。

4.3 GPT 的选择 (2018)

GPT 只用解码器 + 因果注意力 + 自回归目标。当时看起来不如 BERT，但这个选择引入了最少的结构性假设。

4.4 为什么 Decoder-Only 最终胜出

统一视角下的分析

1. **双向注意力**是一种归纳偏置——假设可以看到完整输入。在规模较小时有用，但阻止了模型作为通用生成器
2. **交叉注意力**是另一种归纳偏置——假设编码和解码需要不同处理。随规模增大被证明不必要
3. **掩码语言模型目标**假设可以并行预测所有被掩码的位置——这比自回归目标更高效但更受限
4. **KV 缓存**：因果注意力天然支持 KV 缓存（已处理的 token 可复用），而双向注意力不支持。这在多轮对话场景中是巨大的工程优势

4.5 本章小结

Decoder-only 架构的胜出是“苦涩教训”的又一例证：最少假设 + 最多计算 = 最好结果。

5 对当前趋势的审视

5.1 当前的“捷径”

Chung 认为当前仍有许多“结构性捷径”有待被移除：

- 低精度训练 (FP16/BF16) ——虽然有用，但本质上是计算受限时的权宜之计
- 固定的 tokenizer——人为设计的 token 切分规则可能不是最优的
- 固定的训练数据配比——可能随模型规模变化而需要调整

5.2 硬件协同设计

如果架构足够确定（如 Transformer），可以将其硬编码到芯片中以获得更高效率。当前 GPU “太通用”了——这既是优势也是浪费。

机器辅助的芯片设计

Chung 半开玩笑地预测：AI 很快将在芯片设计方面超越人类。届时，AI 可以帮助设计专门优化 Transformer 推理的硬件，形成“AI 设计 AI 硬件”的正反馈循环。

5.3 本章小结

保持“减法思维”——持续审视哪些假设可以被移除——是推动进步的关键心态。

6 总结与延伸

本讲通过历史分析建立了一个强大的思维框架：(1) AI 进步由计算能力的指数增长驱动；(2) 归纳偏置是资源不足时的权宜之计；(3) 随着资源增加，应系统地移除不必要的假设；(4) 最简单、最通用的方法在长期内总会胜出。这一框架不仅解释了过去，也为思考未来提供了指导。

6.1 拓展阅读

- Sutton, “The Bitter Lesson”, 2019
- Vaswani et al., “Attention Is All You Need”, 2017
- Devlin et al., “BERT: Pre-training of Deep Bidirectional Transformers”, 2019
- Chung et al., “Scaling Instruction-Finetuned Language Models”, 2022