

课程笔记

[CS25 V5] RL as a Co-Design of Product and Research — Karina Nguyen, OpenAI

五道口纳什 & Codex

2026 年 3 月 29 日



视频作者/频道: Stanford CS25: Transformers United V5

发布日期: Spring 2025

视频时长: ~1h

视频链接: 未填写

目录

1 引言：AI 的创造力愿景	2
2 两大扩展范式	2
2.1 下一个 Token 预测（预训练扩展）	2
2.2 思维链上的强化学习（推理扩展）	2
2.3 本章小结	2
3 前沿产品研究方法论	3
3.1 两种产品-研究路径	3
3.2 产品飞轮与研究飞轮	3
3.3 本章小结	3
4 后训练中的行为塑造	3
4.1 过度拒绝问题	3
4.2 拒绝分类学	3
4.3 评估体系构建	4
4.4 本章小结	4
5 RL 在真实世界任务中的应用	4
5.1 从学术任务到真实任务	4
5.2 社会智能的缺失	4
5.3 本章小结	4
6 总结与延伸	5
6.1 拓展阅读	5

1 引言：AI 的创造力愿景

Karina Nguyen 目前就职于 OpenAI，此前曾在 Anthropic 工作，横跨产品与研究两个领域。本次讲座的核心主题是**强化学习如何成为产品与研究的协同设计工具**，以及 AI 实验室中前沿产品研究（Frontier Product Research）的方法论。

讲座以一系列令人振奋的 AI 应用场景开场，展示当前 AI 能力的广度：

- **教育民主化**：ChatGPT 可以个性化地解释复杂概念（如高斯分布），并通过 Canvas 生成可视化代码
- **论文理解**：截图一篇论文的内容，模型可以在独立的 Canvas 窗口中逐步解释
- **个人工具创造**：任何人都可以让 AI 生成前端代码来构建个性化工具、游戏
- **创意增强**：图像生成模型让素描变为高质量图像，AI 成为创意伙伴

Karina 的核心信念

AI 应当增强人类的创造力，而非取代它。每个人都可以利用 AI 工具成为创作者、艺术家或构建者，创造出之前不可能实现的东西。

2 两大扩展范式

2.1 下一个 Token 预测（预训练扩展）

第一个范式是经典的**下一个 token 预测**——模型通过在海量文本上预测下一个 token 来学习世界知识。这种方式使模型成为一台“世界构建机器”，能够在大规模上理解世界。

但它也有局限性：如果模型在生成早期预测了一个错误的 token，整个叙述的连贯性可能会丢失——这在长文本写作中尤为突出。

2.2 思维链上的强化学习（推理扩展）

第二个范式是在**思维链**（Chain-of-Thought）上进行强化学习，这是 OpenAI 推理工作（o1/o3 系列）的核心。这种方法使模型能够处理更复杂的、需要多步推理的真实世界任务。

RL 扩展是独立的新范式

RL 在思维链上的扩展是一个独立于预训练扩展的新范式。基于此训练的 Agent（如 Operator、Deep Research）能够执行之前不可能完成的真实世界任务。

2.3 本章小结

预训练扩展为模型提供知识基础，RL 扩展为模型赋予推理和行动能力，两者共同推动 AI 从对话工具向行动工具的转变。

3 前沿产品研究方法论

3.1 两种产品-研究路径

Karina 基于在 Anthropic 和 OpenAI 的经验，总结了两种构建研究驱动型产品的路径：

1. **为陌生能力创造熟悉的形态**：当模型具备用户不了解的新能力时，产品的任务是将其包装成用户熟悉的交互形式。
2. **为熟悉需求创造新形态**：当用户有明确的需求但现有交互方式受限时，产品需要突破既有范式来满足需求。

Canvas 就是第二种路径的典型示例——ChatGPT 最初是纯对话界面，但随着用户大量使用它进行代码生成和长文写作，对话形式变得过于局限，Canvas 应运而生，允许用户与 AI 进行更细粒度的协作。

3.2 产品飞轮与研究飞轮

产品驱动研究的飞轮效应

产品发布 → 用户使用产生真实数据 → 数据揭示模型弱点 → 研究改进模型 → 更好的产品。
这个飞轮使得产品和研究相互加速，而非独立发展。

3.3 本章小结

前沿产品研究要求研究者同时理解模型能力和用户需求，在两者之间找到创新的结合点。

4 后训练中的行为塑造

4.1 过度拒绝问题

Karina 以 Claude 2.1 的**过度拒绝**（Over-refusal）问题为案例，详细讲解了后训练中的行为调试方法。Claude 2.1 会拒绝一些表面上听起来有害但实际上无害的请求（例如创意写作中的虚构犯罪场景）。

调试原则包括：

- 模型应对用户请求做**善意解读**（Charitable Interpretation），而非假设最坏意图
- 使用**非暴力沟通**原则：用“我”陈述代替“你”判断
- 模型应明确自己的边界，并以同理心表达拒绝

4.2 拒绝分类学

为系统化解过度拒绝问题，团队构建了一套拒绝分类体系：

- 对无害提示的拒绝
- 创意写作中的拒绝
- 工具调用/函数调用中的错误拒绝（如模型声称“无法看到”用户上传的文件）

- 长文档附件的错误拒绝
- 对用户意图的误判性拒绝

4.3 评估体系构建

对于主观性强的行为改进，评估体系至关重要：

- 从产品飞轮中收集真实的过度拒绝案例
- 合成生成处于“有害”与“有帮助”边界的测试提示
- 利用开源基准（如 XSTest、WildChat 等）

行为调试的复杂性

模型行为的问题往往不是由单一数据源引起的。修复过度拒绝需要同时考虑数据清洗、SFT 数据、偏好数据和奖励模型等多个环节，类似于调试复杂软件系统。

4.4 本章小结

后训练中的行为塑造需要精细的分类学、系统化的评估体系，以及对模型行为进行类似软件调试的方法论。

5 RL 在真实世界任务中的应用

5.1 从学术任务到真实任务

传统 RL 训练模型的任务（如数学、编程竞赛）正在向真实世界任务转变：

- **Deep Research**：自主进行深度网络研究
- **Operator**：在真实网站上执行操作任务
- **Canvas**：与用户协作进行代码编写和文档编辑

这些产品的背后是 RL 在思维链上的扩展——模型学会了规划、搜索、纠错等高级认知能力。

5.2 社会智能的缺失

Karina 认为当前 AI 成为真正“协作伙伴”的最大瓶颈不是技术能力，而是**社会智能**：

- 能否实时理解用户的意图和情感状态？
- 能否判断何时应该主动帮助、何时应该退让？
- 能否通过语音、手势等多模态通道进行自然交互？

5.3 本章小结

RL 正在从学术基准走向真实世界应用，而社会智能和多模态交互是下一个需要突破的前沿。

6 总结与延伸

本讲展现了一个从 OpenAI/Anthropic 一线研究者视角看到的全景：AI 产品与研究不再是独立的过程，而是通过 RL 紧密耦合的共同设计。核心洞见包括：

1. **两大扩展范式**：预训练扩展提供知识，RL 扩展提供推理和行动能力。
2. **产品即研究**：真实用户数据是改进模型行为最有价值的信号源。
3. **行为塑造是工程**：后训练中的行为调优需要分类学、评估体系和系统化调试方法。
4. **创造力是方向**：AI 的终极价值在于增强人类的创造力和想象力。

6.1 拓展阅读

- OpenAI, “Learning to Reason with LLMs” (o1 Blog Post), 2024
- Anthropic, “Claude’s Character”, 2024
- Karina Nguyen, “Moral Progress” (Substack Blog Post)
- Bai et al., “Training a Helpful and Harmless Assistant with RLHF”, 2022