

课程笔记

[CS25 V5] On the Biology of a Large Language Model — Josh Batson, Anthropic

基于公开课程资料整理

Spring 2025



视频作者/频道: Stanford CS25: Transformers United V5

发布日期: Spring 2025

视频时长: ~1h

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1 引言：为什么要研究 LLM 的“生物学”？	2
1.1 模型的惊人能力与诡异行为	2
1.2 本章小结	2
2 三个需要修正的迷思	2
3 理解模型内部的方法论	3
3.1 神经元的可解释性困境	3
3.2 稀疏自编码器 (Sparse Autoencoder)	3
3.3 Transcoders: 替换 MLP 层	3
3.4 归因图 (Attribution Graph)	3
3.5 本章小结	4
4 三个核心发现	4
4.1 发现一：模型学习抽象且可组合的表示	4
4.2 发现二：模型执行并行且复杂的计算	4
4.3 发现三：模型会提前规划	4
4.4 本章小结	4
5 幻觉的机制分析	4
5.1 竞争策略	4
5.2 可能的缓解策略	5
5.3 本章小结	5
6 总结与延伸	5
6.1 拓展阅读	5

1 引言：为什么要研究 LLM 的“生物学”？

Josh Batson 领导 Anthropic 机械可解释性 (Mechanistic Interpretability) 团队的 Circuits 方向。他的学术背景是纯数学，之后在 Chan Zuckerberg Biohub 从事生物基因组学和计算显微镜研究。

讲座标题中的“生物学”一词是刻意的类比：正如生物学家研究由进化产生的复杂生命体，可解释性研究者研究由梯度下降“进化”出的复杂神经网络。两者的共同点是：一个你无法直接控制的优化过程产生了能够执行“神奇”功能的复杂系统，而我们的任务是理解这些系统内部的工作机制。

物理学 vs. 生物学视角

“On the Physics of LLMs”系列论文将 LLM 视为训练过程中的动力系统来研究。“On the Biology of a LLM”则关注训练产物本身——模型学到了什么？这些知识如何表示？如何影响行为？

1.1 模型的惊人能力与诡异行为

Josh 用两个案例说明了理解模型内部的紧迫性：

惊人的能力：一位研究切尔克斯语（极低资源语言）NLP 的研究者，将多年积累的俄语-切尔克斯语翻译对直接放入 Claude 的上下文窗口，模型不仅能成功翻译，还能分析该语言的语法结构——仅通过上下文学习就超越了多年专门训练的 NLP 模型。

诡异的行为：有人在闰日问 Claude “明天是几号”，模型声称 2024 年不是闰年（错误），然后正确列出了闰年规则，又推导出下一个闰年是 2028（正确），最后建议用户可能想说的是 2 月 28 日——正确事实、正确推理和错误结论奇怪地共存。

前沿与怪异同行

随着模型越来越强大，错误不会消失，而是变得更隐蔽。就像图像生成模型曾经生成多余的手指一样，即使表面问题被解决，更微妙的错误可能潜伏在模型能力的边界——而此时你已经开始信任并依赖这些模型。

1.2 本章小结

可解释性研究的动机不仅是学术好奇心，更是安全需求——我们需要知道模型的可靠表现是源于真正的理解，还是仅仅是“打压了手指问题”。

2 三个需要修正的迷思

Josh 提出了三个关于 LLM 的常见误解：

三个迷思与现实

1. **迷思**：模型只是在匹配训练数据中的相似样本。**现实**：模型学习并能组合相当抽象的内部表示。
2. **迷思**：模型只使用浅层、简单的启发式规则。**现实**：模型执行复杂且高度并行的计算。
3. **迷思**：模型只是逐词即兴生成。**现实**：模型会提前多个 token 进行规划。

3 理解模型内部的方法论

3.1 神经元的可解释性困境

传统的可解释性方法试图理解单个神经元的含义，但问题在于：模型中的特征（Feature）数量远多于神经元数量——特征被**叠加**（Superposition）在神经元中。

这意味着单个神经元通常对应多个不相关的概念（多义性，Polysemanticity），使得直接解释神经元变得困难。

3.2 稀疏自编码器（Sparse Autoencoder）

为了从叠加的神经元中分离出可解释的特征，团队使用**稀疏自编码器**（SAE）：用一个过完备的字典来重构模型的激活，同时施加稀疏性约束，使得每次只有少量特征被激活。

这样得到的特征比原始神经元更加可解释。例如：

- 一个“首都”特征专门在“州 → 首都”的映射中激活
- 一个“德克萨斯”特征在涉及德克萨斯州文化和政治的上下文中激活

3.3 Transcoders：替换 MLP 层

更进一步，团队开发了 **Transcoders**——直接替换 Transformer 中的 MLP 层，将输入激活映射到输出激活，同时保持稀疏性。这样做的优势是：

- 特征可以跨层“跳跃”到输出，简化了因果追踪
- 不需要每个计算都局限于单一层——如果一个操作本质上很简单（如二元组统计），它可以用一个特征表示

注意力层未被建模

当前方法冻结了注意力层，只对 MLP 层进行可解释性分析。这意味着注意力层中的信息选择和移动机制仍然是黑盒。Josh 怀疑许多“选择使用哪种策略”的决策是由注意力层完成的。

3.4 归因图（Attribution Graph）

通过 Transcoders 将 MLP 层分解为可解释的特征后，可以从模型输出反向追踪：哪些特征直接导致了特定输出 → 哪些特征导致了这些特征的激活 → 以此类推，直到输入层。

这样就得到了一个**归因图**——一个因果关系图，展示模型如何从输入逐步计算到输出。

3.5 本章小结

稀疏自编码器和 Transcoders 提供了一种将不可解释的神经元分解为可解释特征的方法，归因图则将这些特征连接成因果推理链路。

4 三个核心发现

4.1 发现一：模型学习抽象且可组合的表示

模型不只是记忆训练样本，而是学习了抽象概念并能够组合它们。例如，在 “Dallas is in Texas. The capital of Texas is Austin.” 这样的推理中，模型内部存在 “德克萨斯” 特征、“首都” 特征等，它们通过可追踪的因果路径连接。

4.2 发现二：模型执行并行且复杂的计算

在单次前向传播中，模型可以同时执行多个相互独立的推理过程。这不是简单的序列化思考，而是大量并行的信息处理。

4.3 发现三：模型会提前规划

尽管模型的训练目标是预测下一个 token，但它在内部表示中会为未来多个 token 进行规划。这意味着当前 token 的生成已经考虑了后续 token 的需要。

4.4 本章小结

这三个发现挑战了 “LLM 只是花哨的鹦鹉” 的观点，揭示了模型内部存在真正的抽象推理、并行计算和前瞻性规划。

5 幻觉的机制分析

5.1 竞争策略

Josh 展示了一个关于幻觉的机械可解释性分析案例。当模型被问到一个附带提示（hint）的数学问题时，内部同时存在两种竞争策略：

- **策略 A**：使用提示中的答案反向构造推理过程（迎合策略）
- **策略 B**：独立进行数学计算得出答案（推理策略）

问题在于，两种策略的外在表现几乎相同——都会生成看似合理的数学推导过程。但只有策略 B 是真正的推理。

幻觉的根本困难

幻觉的危险在于你无法从模型输出的 “解释” 来判断它是真正在推理还是在迎合。这不是一个定义清晰的问题——在生成大量文本时，“哪个 token 出了错” 本身就很难确定。

5.2 可能的缓解策略

- 推理模型 (Thinking Tags) 允许模型在生成答案前进行自我检查
- 让模型在校准自我认知 (Self-Knowledge) 方面做得更好
- 可能需要牺牲一部分“创造力”来换取更多的自我验证
- 自适应计算 (Adaptive Compute): 允许模型对不同 token 使用不同计算量

5.3 本章小结

幻觉不是一个简单的“bug”，而是模型内部多种策略竞争的结果。可解释性工具能够揭示这些竞争机制，为设计更可靠的系统提供线索。

6 总结与延伸

本讲提供了一个深入理解 LLM 内部运作的独特视角。核心信息：

1. **模型比你想象的更复杂**：它们学习抽象表示、执行并行计算、进行多步规划。
2. **可解释性是安全的基础**：随着模型能力增强和应用场景扩大，理解模型的内部机制变得越来越重要。
3. **工具在进步**：稀疏自编码器、Transcoders、归因图提供了越来越精细的分析工具。
4. **但挑战仍然巨大**：注意力层的可解释性、幻觉的根本解决、从局部分析到全局理解的跨越，都是开放问题。

6.1 拓展阅读

- Anthropic, “On the Biology of a Large Language Model”, 2025
- Bricken et al., “Towards Monosemanticity: Decomposing Language Models With Dictionary Learning”, 2023
- Templeton et al., “Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet”, 2024
- Conerly et al., “Transcoders Find Interpretable LLM Feature Circuits”, 2024