

课程笔记

[CS25 V5] Transformers in Diffusion Models — Sayak Paul, HuggingFace

五道口纳什 & Codex

2026 年 3 月 29 日



视频作者/频道: Stanford CS25: Transformers United V5

发布日期: Spring 2025

视频时长: ~1h

视频链接: 未填写

目录

1 引言：扩散模型中的 Transformer 革命	2
2 扩散模型基础	2
2.1 核心思想	2
2.2 系统组件概览	2
2.3 训练与推理	2
2.4 本章小结	3
3 早期架构：U-Net 时代	3
3.1 U-Net 的主导地位	3
3.2 本章小结	3
4 DiT：扩散 Transformer 的诞生	3
4.1 DiT 架构	3
4.2 adaLN：条件注入的核心	3
4.3 初始化策略	4
4.4 Scaling 特性	4
4.5 本章小结	4
5 从类别条件到文本条件	4
5.1 PixArt- α ：文本条件 DiT 的先驱	4
5.2 adaLN 调制的重要演进	4
5.3 本章小结	4
6 MM-DiT 与 Stable Diffusion 3	5
6.1 MM-DiT 架构	5
6.2 本章小结	5
7 结构化控制与视频生成	5
7.1 结构化控制	5
7.2 视频扩散模型	5
7.3 本章小结	6
8 下一代架构：上下文学习与统一生成	6
8.1 扩散模型中的上下文学习	6
8.2 本章小结	6
9 总结与延伸	6
9.1 拓展阅读	6

1 引言：扩散模型中的 Transformer 革命

Sayak Paul 是 HuggingFace 的工程师，主要负责 Diffusers 库的开发与维护，专注于扩散模型的训练、评估和应用。本讲系统梳理了 Transformer 如何逐步取代 U-Net 成为扩散模型的核心骨干网络。

讲座范围说明

- 不会详细推导扩散或 Flow Matching 的数学原理，仅给出快速概览
- 讨论的架构对扩散和 Flow Matching 是通用的
- 以图像生成为主要示例，但这些架构也适用于音频等连续模态

2 扩散模型基础

2.1 核心思想

扩散模型的核心思想是：从随机噪声出发，通过**迭代去噪**过程逐步生成逼真图像。与 GAN（一步生成）不同，扩散模型是**序列化的**——需要多步去噪才能完成生成。

当以文本作为条件时，去噪过程被引导向文本描述的方向，从而实现文本到图像的生成。

2.2 系统组件概览

一个完整的文本到图像系统包含以下组件：

1. **文本编码器**：将文本提示转换为嵌入向量（当前最先进模型通常使用多个文本编码器，如 Stable Diffusion 3 使用三个）
2. **噪声潜变量**：从高斯分布采样的初始噪声
3. **时间步**：控制去噪过程进度的调度参数
4. **核心扩散网络**：执行去噪的主体网络（本讲重点）
5. **解码器**：将去噪后的潜变量转换为最终图像

潜空间 vs. 像素空间

当前最先进的扩散模型几乎都在**潜空间**（Latent Space）而非像素空间中操作，因为像素空间的计算成本过高。这就是为什么输入是“噪声潜变量”而非原始像素。

2.3 训练与推理

训练：给定原始图像 x_0 ，从标准高斯分布采样噪声 ϵ ，从均匀分布采样时间步 t ，通过噪声调度器混合得到含噪样本 x_t 。训练目标是让网络预测噪声（或速度向量）。

推理：从纯噪声出发，按时间步序列依次调用网络进行去噪，最终得到生成样本。

2.4 本章小结

扩散模型通过迭代去噪实现高质量图像生成，其系统由文本编码器、核心扩散网络和解码器组成。

3 早期架构：U-Net 时代

3.1 U-Net 的主导地位

在 Transformer 进入之前，扩散模型几乎清一色使用 **U-Net** 作为核心网络——这是一种具有下采样-上采样结构和跳跃连接的卷积网络，最初为医学图像分割而设计。

U-Net 的局限性包括：

- 感受野受限于卷积核大小
- 扩展性不如 Transformer（难以利用 Scaling Laws）
- 缺乏成熟的大规模训练基础设施

3.2 本章小结

U-Net 虽然在扩散模型早期取得了巨大成功，但其架构特性限制了进一步扩展。

4 DiT：扩散 Transformer 的诞生

4.1 DiT 架构

DiT (Diffusion Transformer) 是将 Transformer 引入扩散模型的里程碑工作。其核心设计：

1. **Patchify**：将图像分割为 patch 并线性投影为 token 序列
2. **标准 Transformer 编码器**：多头自注意力 + MLP
3. **自适应层归一化** (Adaptive Layer Norm, adaLN)：用于注入条件信息
4. **Unpatchify**：单层解码器将输出 token 重新组装为图像

4.2 adaLN：条件注入的核心

自适应层归一化优于交叉注意力

在 DiT 中，条件信息（时间步嵌入 + 类别嵌入之和）通过 adaLN 注入，**而不是**通过交叉注意力。实验表明 adaLN 在性能和计算效率上都明显优于交叉注意力。原因是：

- 当条件信息相对简单（如类别标签）时，交叉注意力是浪费计算
- 在连续模态中，adaLN 对条件依赖的建模更为高效

通过标准层归一化加上额外的调制参数（从条件空间学习），adaLN 控制了 Transformer 块内部的“风格”信息流。

4.3 初始化策略

DiT 使用标准 ViT 初始化，但有两个关键修改：

- 每个 Transformer 块初始化为恒等映射（类似 ResNet 中将 BatchNorm 的 β 初始化为零）
- 这有助于训练稳定性

4.4 Scaling 特性

DiT 展示了优雅的扩展性——随着计算量增加，性能持续提升，且所有基于 ViT 的训练技术都可以直接应用。

4.5 本章小结

DiT 证明了 Transformer 可以有效替代 U-Net 作为扩散模型的核心网络，adaLN 是高效条件注入的关键。

5 从类别条件到文本条件

5.1 PixArt- α ：文本条件 DiT 的先驱

将 DiT 从类别条件扩展到文本条件的关键问题是如何嵌入自然语言提示。PixArt- α 是早期探索这一方向的重要工作。

文本条件的引入需要：

- 使用预训练文本编码器（如 T5、CLIP）生成文本嵌入
- 在 Transformer 块中引入**交叉注意力层**来建模文本与视觉 token 的交互

adaLN 与交叉注意力的适用场景

对于简单条件（类别标签、时间步），adaLN 足够且更高效。但对于复杂的文本条件，交叉注意力变得必要——文本序列的可变长度和丰富语义需要更灵活的交互机制。

5.2 adaLN 调制的重要演进

不同工作探索了如何在 Transformer 各层之间调制条件信息：

- 共享 adaLN 参数（计算高效但表达力受限）
- 每层独立的 adaLN 参数（表达力更强）
- adaLN-Zero 变体（更高效的调制方式）

5.3 本章小结

从类别条件到文本条件的扩展需要引入交叉注意力，而 adaLN 仍然在控制去噪过程的风格化方面发挥重要作用。

6 MM-DiT 与 Stable Diffusion 3

6.1 MM-DiT 架构

MM-DiT (Multimodal DiT) 是 Stable Diffusion 3 使用的架构, 其核心创新是将文本 token 和视觉 token 放入同一个注意力计算中:

- 文本和图像各自有独立的 adaLN 和 MLP
- 但在注意力计算中, 文本和图像 token 被拼接在一起进行联合自注意力
- 这使得文本和图像之间的信息流动更加自然

6.2 本章小结

MM-DiT 通过联合自注意力统一了文本和视觉 token 的交互方式, 是当前最先进的文本到图像架构之一。

7 结构化控制与视频生成

7.1 结构化控制

除了文本条件外, 实际应用中还需要更精细的控制:

- **姿态控制**: 让生成的图像遵循特定的人体姿态
- **分割图控制**: 基于语义分割图生成图像
- **深度图控制**: 基于深度信息引导生成

实现方式包括:

- **ControlNet**: 学习辅助网络来编码结构信号并注入基础模型
- **Flux Control**: 增加输入通道以接受额外控制信号
- **适配器网络**: 学习小型网络来建模条件与噪声 token 的依赖关系

空间对应性问题

结构化控制 (如姿态、分割图) 具有空间对应性, 但其他任务 (如主题驱动生成、图像编辑) 可能没有直接的空间对应关系。这是一个活跃的研究方向。

7.2 视频扩散模型

将扩散 Transformer 扩展到视频领域面临的挑战:

- 注意力计算从 2D 扩展到 3D, 计算量急剧增加
- 分解注意力 (如空间 + 时间分别处理) 效果不佳
- RoPE 位置编码在视频场景中工作良好

7.3 本章小结

从图像到视频，从文本条件到结构化控制，扩散 Transformer 正在向更通用、更可控的方向发展。

8 下一代架构：上下文学习与统一生成

8.1 扩散模型中的上下文学习

如何在扩散模型中实现类似语言模型的零样本/少样本学习？基本思路是：

- 从预训练 LLM 出发，添加组件使其具备图像生成能力
- **Transfusion**：同时在离散 token 上进行自回归生成，在连续 token 上进行扩散生成
- 类似 Bagel、Show-o 等工作探索了统一的理解与生成框架

8.2 本章小结

下一代架构正在探索将语言理解和视觉生成统一到单一模型中，这将极大扩展扩散模型的能力边界。

9 总结与延伸

本讲系统梳理了 Transformer 在扩散模型中的演进历程。核心信息：

1. **DiT 是转折点**：证明了 Transformer 可以替代 U-Net 并带来更好的扩展性。
2. **adaLN 是核心技巧**：高效的条件注入机制，在多种架构变体中都不可或缺。
3. **Scaling 有效**：扩散 Transformer 与语言模型一样，随着规模增长性能持续提升。
4. **统一生成是未来**：将语言理解与视觉生成统一到单一 Transformer 中是最具前景的方向。

9.1 拓展阅读

- Peebles & Xie, “Scalable Diffusion Models with Transformers (DiT)”, ICCV 2023
- Chen et al., “PixArt- α : Fast Training of Diffusion Transformer for Photorealistic Text-to-Image Synthesis”, 2023
- Esser et al., “Scaling Rectified Flow Transformers for High-Resolution Image Synthesis (SD3)”, 2024
- Zhou et al., “Transfusion: Predict the Next Token and Diffuse Images with One Multi-Modal Model”, 2024
- HuggingFace Diffusers 库：<https://github.com/huggingface/diffusers>