

课程笔记

[CS25 V5] Transformers for Video Generation (Movie Gen) — Andrew Brown, Meta

基于公开课程资料整理

Spring 2025



视频作者/频道: Stanford CS25: Transformers United V5

发布日期: Spring 2025

视频时长: ~1h

项目主页: <https://github.com/hqhq1025/ai-course-notes>

目录

1 引言：视频生成的飞速进步	2
1.1 个人动机	2
1.2 本章小结	2
2 视频生成的历史背景	2
2.1 两个里程碑事件	2
2.2 本章小结	2
3 时间自编码器 (Temporal Autoencoder)	3
3.1 为什么需要压缩?	3
3.2 TAE 的设计	3
3.3 本章小结	3
4 Flow Matching 训练框架	3
4.1 什么是 Flow Matching?	3
4.2 推理过程	4
4.3 本章小结	4
5 模型架构：Llama 3 用于视频生成	4
5.1 为什么选择 Llama 架构?	4
5.2 三个必要的修改	4
5.3 模型规模	5
5.4 本章小结	5
6 训练策略	5
6.1 渐进式训练	5
6.2 图像-视频联合训练	5
6.3 数据的重要性	5
6.4 本章小结	5
7 视频编辑能力	6
7.1 指令驱动编辑	6
7.2 本章小结	6
8 总结与延伸	6
8.1 拓展阅读	6

1 引言：视频生成的飞速进步

Andrew Brown 是 Meta GenAI 团队的研究科学家，专注于视频生成。他在牛津大学 VGG 组 (Andrew Zisserman 指导) 完成 PhD 后加入 Meta，先后参与了 Emu Video 和 Movie Gen 等前沿视频生成项目。

本讲的核心信息可以用一句话概括：**对简单 Transformer 进行数据、计算和模型参数的扩展，在视频生成领域同样有效。**

视频生成的惊人进步

2022 年 9 月的最先进模型只能生成模糊、不自然的短视频。仅仅两年后 (2024 年 10 月)，Movie Gen 就能生成几乎无法与真实视频区分的高质量内容——包括复杂运动、奇幻场景，甚至镜面反射等物理效果。这种进步速度在机器学习各子领域中都是空前的。

1.1 个人动机

Andrew 分享了他进入视频生成领域的契机：2019 年在牛津听了 MIT Antonio Torralba 教授关于 GAN Dissection 的讲座。当时的图像生成模型只能产生模糊的厨房场景，但研究者发现可以通过激活/去激活特定神经元来让窗户出现或消失——更令人震惊的是，模型自动学会了“窗户会透光并在大理石台面上产生反射”这一物理常识。

1.2 本章小结

视频生成在两年内经历了从“模糊可辨”到“以假乱真”的飞跃，Transformer + 扩展是实现这一进步的核心策略。

2 视频生成的历史背景

2.1 两个里程碑事件

视频生成领域在 2022-2024 年间经历了两个关键转折：

里程碑一：扩散模型进入视频生成 (2022)。整个社区开始采用扩散建模方法进行视频生成，取代了之前的 GAN 和 VAE 方法。

里程碑二：Sora 的发布 (2024 年 2 月)。OpenAI 的 Sora 展示了令人震惊的视频生成质量，改变了整个领域的研究格局和公众预期。

视频生成方法的汇聚

在 Sora 之前，不同团队使用不同架构和训练策略，方法差异很大。Sora 之后，几乎所有团队都汇聚到了相似的方法——基于 Transformer 的扩散/Flow Matching 模型。Movie Gen 也是在这一趋势下的产物。

2.2 本章小结

扩散模型的引入和 Sora 的发布是视频生成领域的两个分水岭事件。

3 时间自编码器 (Temporal Autoencoder)

3.1 为什么需要压缩？

视频数据量极大：一段 16 秒、768×768 分辨率的视频包含约 $768 \times 768 \times 30 \times 16 \approx 2.83 \times 10^8$ 个像素。直接在像素空间训练扩散模型计算上不可行，必须先进行压缩。

3.2 TAE 的设计

Movie Gen 使用时间自编码器 (Temporal Autoencoder, TAE) 将视频压缩到紧凑的潜空间：

- **空间压缩**：8×8 (每个 8×8 像素块变成一个 token)
- **时间压缩**：8× (每 8 帧变成 1 帧的 token)
- 总压缩比约 512×

TAE 的训练使用了**对抗损失** (GAN Loss)，这是一个重要的技术细节：

对抗损失提升压缩率

传统 VAE 仅使用 L1 重建损失训练时，能实现的压缩比非常有限。VQ-GAN (2021) 发现，引入 GAN 判别器的对抗损失后，解码器获得了更大的“自由度”——不需要精确重建每个像素，只需要生成看起来“真实”的结果。这使得压缩比提升了约 2 倍。

3.3 本章小结

时间自编码器通过 512× 的压缩比使视频扩散模型的训练成为可能，对抗损失是实现高压缩比的关键技术。

4 Flow Matching 训练框架

4.1 什么是 Flow Matching？

Movie Gen 使用 **Flow Matching** 而非传统的 DDPM 作为训练框架。Flow Matching 的核心思想：

1. 定义从噪声分布到数据分布的一条直线路径
2. 在路径上的任意点，训练模型预测**速度向量**（将样本从噪声推向数据的方向）

训练目标简单明了：

$$\mathcal{L} = \mathbb{E}_{t, x_0, \epsilon} [\|u_\theta(x_t, t, p) - v_t\|^2]$$

其中 v_t 是从含噪样本 x_t 指向数据样本 x_0 的速度向量， p 是文本条件， u_θ 是模型预测。

4.2 推理过程

推理时，从高斯噪声出发，使用 ODE（常微分方程）求解器沿时间步序列迭代去噪：

$$x_{t+\Delta t} = x_t + u_\theta(x_t, t, p) \cdot \Delta t$$

Movie Gen 使用了简单的 Euler 求解器。

4.3 本章小结

Flow Matching 提供了比 DDPM 更简洁的训练框架，其速度预测目标和 ODE 求解器使推理过程直观高效。

5 模型架构：Llama 3 用于视频生成

5.1 为什么选择 Llama 架构？

Movie Gen 使用了 **Llama 3** 的 Transformer 架构（随机初始化，不使用预训练权重）作为扩散模型的骨干网络。

选择 Llama 的原因不是因为它在视频任务上有特殊优势，而是因为：

- Meta 已经知道如何大规模训练这种架构
- 超参数调优、分布式训练基础设施都已就绪
- 架构的可扩展性已经在语言模型中得到验证

架构选择的工程考量

大规模模型训练是极其困难的工程问题。每次改变架构都需要重新探索超参数、训练稳定性等问题。选择已知如何扩展的架构（即使它最初是为其他任务设计的）往往是最务实的选择。

5.2 三个必要的修改

Llama 3 是为自回归文本生成设计的，将其用于视频 Flow Matching 需要三个修改：

1. 交叉注意力层（文本条件注入）。在自注意力层和前馈网络之间插入交叉注意力层，将文本条件注入视频生成过程。

文本表示使用三个互补的预训练编码器：

- **UL2**：侧重语义理解
- **MetaCLIP**：侧重视觉-语言对齐
- **ByT5**：字符级编码器，擅长处理细粒度文本（如拼写、特殊符号）

2. adaLN（时间步条件注入）。通过自适应层归一化将时间步信息注入每个 Transformer 块。

3. 因果注意力 → 双向注意力。Llama 3 使用因果掩码（只看之前的 token），但对于去噪任务，所有 token 之间都应相互可见，因此改为双向全注意力。

5.3 模型规模

Movie Gen 的最终模型达到 **30B 参数**——这是一个巨大的视频生成模型。

5.4 本章小结

Llama 3 架构仅需三个最小修改即可用于视频 Flow Matching，这证明了 Transformer 架构的通用性。

6 训练策略

6.1 渐进式训练

Movie Gen 采用**渐进式训练**策略，逐步提升分辨率和时长：

1. 先在低分辨率、短视频上训练
2. 逐步提升到更高分辨率和更长时长
3. 每个阶段继承前一阶段的权重

6.2 图像-视频联合训练

一个关键的训练技巧是将图像视为单帧视频，进行图像和视频的联合训练：

- 高质量图像数据量远大于视频数据
- 图像训练帮助模型学习高质量的视觉表示
- 视频训练在此基础上学习时间一致性和运动

6.3 数据的重要性

数据质量是核心

Movie Gen 的成功在很大程度上归功于高质量的训练数据。数据管道包括：

- 严格的质量过滤（去除低质量、重复、有害内容）
- 精心的文本描述（使用 LLM 为视频生成详细 caption）
- 平衡的数据分布（避免过度偏向某些类型的内容）

6.4 本章小结

渐进式训练和图像-视频联合训练是训练大规模视频生成模型的关键策略。

7 视频编辑能力

7.1 指令驱动编辑

Movie Gen 不仅能从文本生成视频，还能进行视频编辑：

- 输入原始视频 + 编辑指令（如“将跑步者变成充气恐龙”）
- 模型生成保持原视频结构但遵循编辑指令的新视频

7.2 本章小结

视频编辑能力展示了模型对视频内容的深层理解——不仅能生成，还能有意义地修改。

8 总结与延伸

本讲详细拆解了 Movie Gen 从架构到训练的每个技术细节。核心结论：

1. **Scaling 是王道**：数据、计算、参数的扩展对简单 Transformer 在视频生成领域同样有效。
2. **架构简单性**：仅对 Llama 3 做了三个修改就能进行视频生成，证明了 Transformer 的通用性。
3. **压缩是关键**：TAE 的 $512\times$ 压缩使视频扩散训练成为可能。
4. **训练策略重要**：渐进式训练、图像-视频联合训练是大规模模型训练的实用技巧。
5. **数据决定上限**：高质量数据管道是最终生成质量的关键决定因素。

8.1 拓展阅读

- Meta, “Movie Gen: A Cast of Media Foundation Models”, 2024
- Polyak et al., “Movie Gen Video”, 2024
- Singer et al., “Make-A-Video: Text-to-Video Generation without Text-Video Data”, 2022
- Esser et al., “VQ-GAN: Taming Transformers for High-Resolution Image Synthesis”, 2021
- Lipman et al., “Flow Matching for Generative Modeling”, 2023