

课程笔记

CS146S Week 9: Agents Post-Deployment (DevOps)

基于 Mihail Eric + Mayank Agarwal (Resolve CTO) 授课内容整理

2025 年 11 月

课程: Stanford CS146S

学期: Fall 2025

讲次: 1 lecture (Mon)

网站: <https://themodernsoftware.dev>

项目主页: <https://github.com/hqhq1025/ai-course-notes>

目录

1 生产环境运维的挑战	2
1.1 为什么 DevOps 是软件工程的“更难的 70%”	2
1.2 SRE 的传统职责	2
1.3 本章小结	2
2 基础设施与 DevOps 原则	2
2.1 监控的四个黄金信号	2
2.2 事件响应实战：凌晨 3:12 的数据库 500 错误	3
2.3 关键度量指标	3
2.4 本章小结	3
3 AI SRE：智能运维的新范式	3
3.1 主要工具	3
3.2 AI SRE 的核心特征	3
3.3 AI 带来的改变	4
3.4 当前局限	4
3.5 从告警系统到运维系统的演进	4
3.6 本章小结	5
4 值班室的实践手册	5
4.1 事件文档化与复盘的标准化	5
4.2 值班体系的三个阶段	5
4.3 本章小结	5
5 生产落地：怎样让 AI SRE 真正进入值班体系	6
5.1 AI SRE 首先是协作工具，而不是替班工具	6
5.2 把 AI SRE 接入值班流程的三步法	6
5.3 本章小结	6
6 实战落地：事件复盘与信任恢复	6
6.1 为什么“复盘”是 AI SRE 成熟的第二阶段	6
6.2 事件复盘的可视化流程	7
6.3 本章小结	7
7 总结与延伸	7
7.1 关键点	7
7.2 运维落地清单	8
7.3 值班角色分工表	8
7.4 Postmortem 闭环为什么更重要了	8
7.5 拓展阅读	8

1 生产环境运维的挑战

1.1 为什么 DevOps 是软件工程的“更难的 70%”

编码只占工程时间的 30%

编码仅占工程师总时间的约 30%。更难的 70% 是在生产环境中运行代码——复杂性、工具孤岛 (tool silos)、知识鸿沟和系统间的相互依赖在这里全面碰撞。

监控和维护生产系统仍然是一项关键 (mission-critical) 任务，通常由 SRE (Site Reliability Engineer) 承担。

1.2 SRE 的传统职责

- 运维监控：值班 (on-call)、故障排查 (troubleshooting)、基础设施管理和安全
- 事件解决需要从多个不同来源和团队拼凑信息
- 维护经常过时的 runbook (操作手册)
- 云原生架构 (容器化 + Kubernetes) 引入了更多数据、依赖和跨系统复杂性

SRE 的职业倦怠

SRE 经常因为频繁的值班轮班而职业倦怠 (burnout)。凌晨 3 点被 PagerDuty 叫醒处理 500 错误激增是许多 SRE 的日常。AI SRE 的一个重要价值就是减轻这种人力负担。

1.3 本章小结

生产环境运维是软件工程中最耗时且压力最大的部分。SRE 面临信息碎片化、文档过时和职业倦怠等多重挑战，这为 AI 介入创造了巨大空间。

2 基础设施与 DevOps 原则

2.1 监控的四个黄金信号

Google SRE 的四个黄金信号

1. **Latency** (延迟): 请求的响应时间
2. **Errors** (错误): 失败请求的比率
3. **Traffic** (流量): 每秒请求数 (requests/sec)
4. **Saturation** (饱和度): 资源利用率，接近极限时系统性能急剧下降

此外，还需要监控生产环境的 traces (请求追踪链路)。

2.2 事件响应实战：凌晨 3:12 的数据库 500 错误

当 PagerDuty 告警显示数据库查询出现 500 错误激增时，标准的响应流程（playbook）如下：

1. 确认与评估（Acknowledge and assess）
2. 检查数据库 + 应用（Check DB + app）
3. 识别近期变更（Identify recent changes）
4. 定位影响范围（Localize blast radius）
5. 执行缓解措施（Execute mitigations）
6. 稳定 + 监控（Stabilize + monitor）
7. 沟通（Communicate）
8. 文档记录（Document）

2.3 关键度量指标

- MTTR（Mean Time to Repair）：平均修复时间
- 参与事件的工程师数量
- 客户 SLA 合规报告

2.4 本章小结

四个黄金信号（延迟、错误、流量、饱和度）是监控生产系统的基础框架。事件响应遵循标准化的 playbook，关键度量是 MTTR 和影响范围。

3 AI SRE：智能运维的新范式

3.1 主要工具

- **Resolve AI**：本周嘉宾 Mayank Agarwal 是其 CTO
- **DataDog Bits AI Agent**：基于 DataDog 监控数据的 AI 分析
- **Splunk Observability Assistant**：Splunk 的 AI 可观测性助手

3.2 AI SRE 的核心特征

1. **动态知识图谱**：动态映射服务间的依赖关系和状态
2. **跨可观测性栈的 Agentic 系统**：横跨多个云和监控工具
3. **实时叙述生成**：生成正在发生什么的实时叙述，定位可能的根因并提供支持证据，推荐具体的修复步骤
4. **可解释性和可审计性**：重点强调预测/推理的透明性

AI SRE 解决信息孤岛问题

AI SRE 最重要的价值之一是打破组织内的知识孤岛。传统模式下，关于未文档化的依赖关系、脆弱的遗留服务和只在高压事件中暴露的系统怪癖，往往只存在于少数工程师的脑中。AI SRE 将这些分散的组织知识和服务级知识系统化，使其对整个团队可用。

3.3 AI 带来的改变

- 自动化减少审查时间，及早发现问题
- 开发者通过 AI 建议学习最佳实践
- AI 对所有代码审查应用相同标准
- AI 处理常规检查，让人类专注于复杂逻辑
- AI 系统随数据积累持续改进
- 现代 AI 代码审查工具提供上下文分析和模式识别

3.4 当前局限

AI SRE 的核心局限

- 可解决的事件**复杂度**有限——AI 目前更适合已知模式的问题
- 现代生产技术栈的**异构性**增加了 AI 理解的难度
- 基于检测结果**修复实际代码**的能力仍在早期——目前所有提供商都从根因分析入手
- 好的根因分析依赖于**好的监控基础设施**（监控园艺/monitoring gardening）
- 安全可能成为新的攻击向量

3.5 从告警系统到运维系统的演进

Week 9 的关键洞见之一是：AI SRE 不应该只是“更聪明的告警摘要器”，而应逐步演化成真正的运维协作系统。

- 第一阶段是**信息聚合**：把日志、指标、traces 和变更记录拉到同一视图
- 第二阶段是**根因推断**：给出更像工程师思路的因果链和证据
- 第三阶段是**建议执行**：推荐缓解动作、回滚路径和沟通模板
- 更长期才是**受控自动修复**：在明确边界下自动执行低风险修复动作

成熟的 AI SRE 系统首先要学会“少做错事”

在生产环境里，错误的自动化往往比慢一点的人类操作更危险。因此 AI SRE 的成熟度，不只是看它能自动做多少事，更看它能否稳定识别哪些事不该自动做。

3.6 本章小结

AI SRE 通过动态知识图谱、跨栈 Agent 系统和实时叙述生成来辅助运维。其最大价值在于打破信息孤岛、降低 MTTR。当前的局限在于只能处理中等复杂度的已知模式问题，从检测到自动修复仍有较长的路要走。

4 值班室的实践手册

4.1 事件文档化与复盘的标准化

Week 9 还有一个强调：SRE 的工作不能只靠记忆，必须把事件、假设、调试步骤、决策理由都写入文档。

- 每次 incident 产生的 alert、trace、metric spike，必须关联到一个 ticket
- 每条 ticket 记录触发时间、影响范围以及后来做出的缓解动作
- 事件结束后编写 post-mortem，标注 root cause、lessons learned、future mitigations
- AI SRE 可以自动生成初稿，但仍需人为校对、补充背景和验证

不写 post-mortem 就不算彻底经历了一次 incident

单纯把监控数字压回来的行动可能只暂时压住火苗。真正的安全能力来自把事件记录成知识——下次再发生类似问题，团队能快速知道上次是怎么处理的。

4.2 值班体系的三个阶段

将 Week 9 的思路向下分解，可以形成一个三阶段的成熟度模型：

阶段	主要任务	AI SRE 的角色
观察阶段	统一监控 + 日志、门槛告警	提供实时摘要、highlight 可疑模式
响应阶段	快速定位 root cause、执行缓解	建议命令、引用操作记录、验证方案
复盘阶段	编写 post-mortem、更新 runbook	自动整理 evidence matrix、提醒 follow-up tasks

表 1: AI SRE 在值班体系中的三阶段角色

4.3 本章小结

事件不仅要快速处理，也要写成知识。Week 9 告诉我们：AI SRE 介入值班流程时，最初的价值来自 observation + suggestion，后续再扩展到 controlled execution 和 incident learning。

5 生产落地：怎样让 AI SRE 真正进入值班体系

5.1 AI SRE 首先是协作工具，而不是替班工具

课程里一个很重要的现实判断是：短期内 AI SRE 更像“更强的副驾驶”，而不是“完全替代值班工程师的驾驶员”。

- 它最擅长的，是在高压场景下快速整合分散信息
- 它能帮助工程师更快看见依赖链、近期变更和潜在 blast radius
- 但最终是否回滚、是否扩容、是否宣布重大事故，仍然需要人类判断

值班体系中的关键问题不是“能不能自动修”，而是“什么时候绝不能自动修”

在生产环境里，少数错误自动化动作的代价可能远大于人工慢几分钟的代价。因此成熟团队会先定义自动化禁区：哪些服务、哪些时段、哪些动作、哪些权限绝不能让 AI 直接执行。

5.2 把 AI SRE 接入值班流程的三步法

阶段	AI 的角色	团队关注点
观察阶段	汇总告警、日志和 traces	看它是否真的减少排障时间，而不是制造新噪音
建议阶段	提供根因假设和缓解动作建议	建立建议的准确率、误报率和可审计性
受控执行阶段	自动做低风险、可回滚操作	明确权限边界、审批门槛和回退机制

表 2: AI SRE 进入值班体系的典型路径

没有高质量运行数据，AI SRE 很容易沦为“幻觉放大器”

如果指标命名混乱、trace 覆盖不全、变更记录缺失、runbook 过时，那么 AI 得到的不是更好的上下文，而是一堆更快被拼接起来的噪音。AI SRE 的效果上限，直接受制于团队原有 observability 基础。

5.3 本章小结

AI SRE 要真正进入生产值班体系，必须先从观察和建议做起，再逐步进入受控执行。它的上限由模型能力决定，但它的下限几乎完全由监控基础设施和组织边界决定。

6 实战落地：事件复盘与信任恢复

6.1 为什么“复盘”是 AI SRE 成熟的第二阶段

事件处理完并不意味着工作结束。关键在于“复盘和信任恢复”：

- 记录所有 Agent 交互、工具调用、自动建议和人工决策
- 分析为什么 AI 没能给出正确建议（数据缺失、prompt 注入、模型 hallucination）
- 补回缺失的文档、hooks 和监控信号
- 向团队公布经验教训，更新 runbook 和审批政策

没有复盘就没有信任

运行中的团队对 AI 的信任来自连续的成功案例和透明的错误处理路径。如果每次 AI 出问题都只是“回滚并忘记”，团队就不会允许它承担更多权限。

6.2 事件复盘的可视化流程

步骤	产出	关键指标
收集证据	命令历史 + prompt + tool outputs	覆盖率、日志完整性
归因分析	根因链 + 证据矩阵	误差区间、关联度
补救方案	新 hook / 新测试 / 调整权限	执行次数、Rollback 次数
知识沉淀	更新 runbook、加标签、分享会议	文档完成度、审计验证

表 3: 事件复盘的可视化流程

6.3 本章小结

事件处理的最后一公里是复盘与信任恢复。记录原始决策链条、分析根因、修补监控，并把教训转化为可操作的 runbook，是 AI SRE 真正进入生产的前提。

7 总结与延伸

Week 9 将视角从“写代码”转向“运行代码”。DevOps 和 SRE 是软件工程中最耗时的部分，AI SRE 正在通过知识图谱、跨栈 Agent 和实时分析来降低运维负担。

7.1 关键点

- 编码只占工程时间的 30%，运维是更难的 70%
- 四个黄金信号：延迟、错误、流量、饱和度
- 事件响应遵循标准化 playbook，核心度量是 MTTR
- AI SRE 的四大特征：动态知识图谱、跨栈 Agent、实时叙述、可解释性
- 最大价值：打破知识孤岛，降低 MTTR
- 当前从根因分析入手，自动修复仍在早期

7.2 运维落地清单

1. 先统一监控口径和日志质量，再引入 AI SRE，不要让 AI 替代混乱的数据基础
2. 把 MTTR、误报率和升级准确率作为核心指标，而不是只看模型回答是否“像样”
3. 在受控范围内自动化低风险操作，把高风险修复留给人工审批

7.3 值班角色分工表

角色	在 AI SRE 体系中的职责	不能放弃的人类责任
值班工程师	审阅 AI 汇总、决定缓解动作、协调升级	对重大操作负责最终确认
AI SRE 系统	聚合证据、给出根因假设、建议低风险动作	不能越权执行高风险修复
平台/基础设施团队	维护监控、日志、runbook 与权限边界	保证 AI 有高质量运行数据可用

表 4: AI SRE 场景下的人机角色边界

7.4 Postmortem 闭环为什么更重要了

AI SRE 并不会让事故复盘变得不重要，反而会让它更重要。因为每一次事故处理，都会同时暴露两类问题：

- 系统本身的问题：监控缺口、依赖不清、runbook 过时、权限边界模糊
- AI 系统的问题：它遗漏了哪些信号、放大了哪些噪音、在哪一步给出了不可靠建议

因此，成熟团队需要把 postmortem 的产出重新写回监控、告警规则、AI 提示词、runbook 和审批边界，让 AI SRE 不是一次性的事故助手，而是可持续进化的运维系统。

7.5 拓展阅读

- Resolve AI: <https://resolve.ai>
- Google SRE Book: <https://sre.google/sre-book/table-of-contents/>
- DataDog Bits AI: <https://www.datadoghq.com/product/platform/bits-ai/>
- “The Four Golden Signals” (Google SRE Book, Chapter 6)
- PagerDuty Incident Response Guide: <https://response.pagerduty.com>