

课程笔记

CS146S Week 9: Agents Post-Deployment (DevOps)

基于 Mihail Eric + Mayank Agarwal (Resolve CTO) 授课内容整理

2025 年 11 月

课程: Stanford CS146S

学期: Fall 2025

讲次: 1 lecture (Mon)

网站: <https://themodernsoftware.dev>

目录

1 生产环境运维的挑战	2
1.1 为什么 DevOps 是软件工程的“更难的 70%”	2
1.2 SRE 的传统职责	2
1.3 本章小结	2
2 基础设施与 DevOps 原则	2
2.1 监控的四个黄金信号	2
2.2 事件响应实战：凌晨 3:12 的数据库 500 错误	3
2.3 关键度量指标	3
2.4 本章小结	3
3 AI SRE：智能运维的新范式	3
3.1 主要工具	3
3.2 AI SRE 的核心特征	3
3.3 AI 带来的改变	4
3.4 当前局限	4
3.5 本章小结	4
4 总结与延伸	4
4.1 关键点	4
4.2 拓展阅读	5

1 生产环境运维的挑战

1.1 为什么 DevOps 是软件工程的“更难的 70%”

编码只占工程时间的 30%

编码仅占工程师总时间的约 30%。更难的 70% 是在生产环境中运行代码——复杂性、工具孤岛 (tool silos)、知识鸿沟和系统间的相互依赖在这里全面碰撞。

监控和维护生产系统仍然是一项关键 (mission-critical) 任务，通常由 SRE (Site Reliability Engineer) 承担。

1.2 SRE 的传统职责

- 运维监控：值班 (on-call)、故障排查 (troubleshooting)、基础设施管理和安全
- 事件解决需要从多个不同来源和团队拼凑信息
- 维护经常过时的 runbook (操作手册)
- 云原生架构 (容器化 + Kubernetes) 引入了更多数据、依赖和跨系统复杂性

SRE 的职业倦怠

SRE 经常因为频繁的值班轮班而职业倦怠 (burnout)。凌晨 3 点被 PagerDuty 叫醒处理 500 错误激增是许多 SRE 的日常。AI SRE 的一个重要价值就是减轻这种人力负担。

1.3 本章小结

生产环境运维是软件工程中最耗时且压力最大的部分。SRE 面临信息碎片化、文档过时和职业倦怠等多重挑战，这为 AI 介入创造了巨大空间。

2 基础设施与 DevOps 原则

2.1 监控的四个黄金信号

Google SRE 的四个黄金信号

1. **Latency** (延迟): 请求的响应时间
2. **Errors** (错误): 失败请求的比率
3. **Traffic** (流量): 每秒请求数 (requests/sec)
4. **Saturation** (饱和度): 资源利用率，接近极限时系统性能急剧下降

此外，还需要监控生产环境的 traces (请求追踪链路)。

2.2 事件响应实战：凌晨 3:12 的数据库 500 错误

当 PagerDuty 告警显示数据库查询出现 500 错误激增时，标准的响应流程（playbook）如下：

1. 确认与评估（Acknowledge and assess）
2. 检查数据库 + 应用（Check DB + app）
3. 识别近期变更（Identify recent changes）
4. 定位影响范围（Localize blast radius）
5. 执行缓解措施（Execute mitigations）
6. 稳定 + 监控（Stabilize + monitor）
7. 沟通（Communicate）
8. 文档记录（Document）

2.3 关键度量指标

- MTTR（Mean Time to Repair）：平均修复时间
- 参与事件的工程师数量
- 客户 SLA 合规报告

2.4 本章小结

四个黄金信号（延迟、错误、流量、饱和度）是监控生产系统的基础框架。事件响应遵循标准化的 playbook，关键度量是 MTTR 和影响范围。

3 AI SRE：智能运维的新范式

3.1 主要工具

- **Resolve AI**：本周嘉宾 Mayank Agarwal 是其 CTO
- **DataDog Bits AI Agent**：基于 DataDog 监控数据的 AI 分析
- **Splunk Observability Assistant**：Splunk 的 AI 可观测性助手

3.2 AI SRE 的核心特征

1. **动态知识图谱**：动态映射服务间的依赖关系和状态
2. **跨可观测性栈的 Agentic 系统**：横跨多个云和监控工具
3. **实时叙述生成**：生成正在发生什么的实时叙述，定位可能的根因并提供支持证据，推荐具体的修复步骤
4. **可解释性和可审计性**：重点强调预测/推理的透明性

AI SRE 解决信息孤岛问题

AI SRE 最重要的价值之一是打破组织内的知识孤岛。传统模式下，关于未文档化的依赖关系、脆弱的遗留服务和只在高压事件中暴露的系统怪癖，往往只存在于少数工程师的脑中。AI SRE 将这些分散的组织知识和服务级知识系统化，使其对整个团队可用。

3.3 AI 带来的改变

- 自动化减少审查时间，及早发现问题
- 开发者通过 AI 建议学习最佳实践
- AI 对所有代码审查应用相同标准
- AI 处理常规检查，让人类专注于复杂逻辑
- AI 系统随数据积累持续改进
- 现代 AI 代码审查工具提供上下文分析和模式识别

3.4 当前局限

AI SRE 的核心局限

- 可解决的事件**复杂度**有限——AI 目前更适合已知模式的问题
- 现代生产技术栈的**异构性**增加了 AI 理解的难度
- 基于检测结果**修复实际代码**的能力仍在早期——目前所有提供商都从根因分析入手
- 好的根因分析依赖于**好的监控基础设施**（监控园艺/monitoring gardening）
- 安全可能成为新的攻击向量

3.5 本章小结

AI SRE 通过动态知识图谱、跨栈 Agent 系统和实时叙述生成来辅助运维。其最大价值在于打破信息孤岛、降低 MTTR。当前的局限在于只能处理中等复杂度的已知模式问题，从检测到自动修复仍有较长的路要走。

4 总结与延伸

Week 9 将视角从“写代码”转向“运行代码”。DevOps 和 SRE 是软件工程中最耗时的部分，AI SRE 正在通过知识图谱、跨栈 Agent 和实时分析来降低运维负担。

4.1 关键点

- 编码只占工程时间的 30%，运维是更难的 70%
- 四个黄金信号：延迟、错误、流量、饱和度

- 事件响应遵循标准化 playbook，核心度量是 MTTR
- AI SRE 的四大特征：动态知识图谱、跨栈 Agent、实时叙述、可解释性
- 最大价值：打破知识孤岛，降低 MTTR
- 当前从根因分析入手，自动修复仍在早期

4.2 拓展阅读

- Resolve AI: <https://resolve.ai>
- Google SRE Book: <https://sre.google/sre-book/table-of-contents/>
- DataDog Bits AI: <https://www.datadoghq.com/product/platform/bits-ai/>
- “The Four Golden Signals” (Google SRE Book, Chapter 6)
- PagerDuty Incident Response Guide: <https://response.pagerduty.com>